

分类号：
密 级：

单位代码： 10019
学 号： SZ11060763

中国农业大学

博士学位论文

基于基因组学的鸭进化及驯化分析

Genomic analyses reveal the evolution and domestication
process of ducks

研 究 生： 刘睿

指 导 教 师： 李宁 教授

合 作 指 导 教 师： 黄银花 教授

申请学位门类级别： 理学博士

专 业 名 称： 生物化学与分子生物学

研 究 方 向： 分子进化

所 在 学 院： 生物学院

二零一六年 十月

China Agricultural University

Ph.D. Dissertation

**Genomic analyses reveal the evolution and domestication
process of ducks**

Ph.D. graduate: Rui Liu

Major: Biochemistry and Molecular Biology

Supervisor: Prof. Ning Li

Co-supervisor: Prof. Yinhua Huang

China Agricultural University

Beijing, 100193

November, 2016

独 创 性 声 明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中国农业大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

研究生签名：

时间：

年 月 日

关于论文使用授权的说明

本人完全了解中国农业大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件和磁盘，允许论文被查阅和借阅，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。同意中国农业大学可以用不同方式在不同媒体上发表、传播学位论文的全部或部分内容。

(保密的学位论文在解密后应遵守此协议)

研究生签名：

时间：

年 月 日

导师签名：

时间：

年 月 日

摘要

鸭是水禽类的重要代表，是我国第二大家禽。鸭肉和蛋是重要的食物来源，鸭绒是羽绒产品的重要原材料。鸭还是一种极具观赏价值的动物，放养在湖泊，公园等人类的休闲娱乐场所。家鸭被认为是起源于绿头野鸭或绿头野鸭与斑嘴野鸭的杂交后代。然而，野鸭和家鸭表型分化明显，比如野鸭有很强的飞行迁徙能力，家鸭则性格温顺，失去迁徙能力。北京鸭全基因组序列图谱的构建为其功能研究提供了重要的资源。但是目前在分子方面对于家鸭起源以及其表型变化遗传基础的研究依然十分有限。

我与 BGI 的合作者测定了一只斑嘴野鸭和一只绿头野鸭的全基因组序列。通过构建插入长度分别为 250 bp, 500 bp, 800 bp 的小片段文库和插入长度分别为 2 kb, 5 kb, 10 kb 和 20 kb 的大片段插入文库，获得了 275 Gb 绿头野鸭和 262 Gb 斑嘴野鸭基因组序列。使用类似于北京鸭基因组的组装策略，构建了 scaffold N50 分别达到了 2.05 Mb 和 2.48 Mb 的绿头和斑嘴野鸭的高质量基因组序列。并且发现两个野鸭基因组的杂合率 (3.59×10^{-3} , 3.53×10^{-3}) 和转座元件的含量 (10.7%, 10.5%, 136 Mb, 139 Mb) 都显著高于北京鸭 (杂合率为 2.61×10^{-3} , 转座元件含量为 7.23%, 80 Mb)。通过全基因组序列比对我们发现绿头野鸭和斑嘴野鸭基因组分别包含 4.6%, 4.9% (59.64 Mb, 66.05 Mb) 各自基因组长度的片段拷贝。这一比例与人和狗 (3.1-5.2%) 基因组中复制片段的比例相接近，但是高于北京鸭 (1%, 12 Mb) 和鸡 (1%, 11 Mb) 的比例。并且我们在绿头野鸭和斑嘴野鸭的基因组中分别预测了 21,264 个和 21,186 个蛋白编码基因，发现两种野鸭参考基因组相似度高于野鸭与家鸭对应的相似性，并鉴定了 2,589 个绿头野鸭和 2,697 个斑嘴野鸭新基因，以及 910 个绿头野鸭和 993 个斑嘴野鸭基因组中丢失的基因。

我以太湖鹅和番鸭作为外群，对 8 个家鸭品种，8 个野鸭种群进行全基因组重测序以及群体遗传学分析。通过 PCA (Principal Component Analysis), 遗传结构 (genetic structure) 和 F_{ST} 统计量等分析，结果显示家鸭并非绿头野鸭和斑嘴野鸭的直接后裔，而可能起源于另一个未知的群体。结合 $\partial a \partial i$ 和 PSMC 群体历史构建分析，我发现家鸭的祖先群体与野鸭 (绿头野鸭和斑嘴野鸭) 的祖先群体大约在末次冰期开始的时间分化 (last glacial period, LGP, 十到二十万年前)。随后野鸭的祖先群体可能得益于适应性选择，因而维持了其种群有效群体大小。受到选择的基因包括心、肺、呼吸系统相关的基因，线粒体产能等能量代谢相关的基因，以及身体形态决定相关的基因等。我们还发现这种适应性选择与鉴定的绿头野鸭和斑嘴野鸭种化基因组岛具有高度一致性，说明该群体早期适应性选择可能是导致其分化为绿头野鸭和斑嘴野鸭的主要诱因。与此相比，家鸭祖先群体并没有受到这样的适应性选择，因此其有效群体数量在整个末次冰期持续下降。我们进一步在家鸭品种当中鉴定出了 73 个近期出现的选择性清区域。这些区域所包含的基因与其求偶行为，饲喂行为，荷尔蒙的代谢和神经系统活动相关。另外，家鸭其糖类，脂类以及蛋白代谢合成相关的基因也受到选择，可能与其依附于人类环境生活，能获得较充裕的食物相关。我进一步从野鸭祖先群体当中受到选择的位点和家鸭驯化过程中受到选择的位点中挑出六个 (位于 *EFNA5*, *LYST*, *MRPS27*, *GRIK1*, *ISL1* 等 5 个基因附近) 可能对其进化过程有重要作用的潜在致因变异，利用荧光素酶报告基因的方法进行活性验证，发现其中有四个突变的调控效应具有显著差异。

综上所述,本研究首先构建得到了两个高质量的野鸭全基因组参考序列。并且通过野鸭和家鸭群体系统的重测序分析,建立了鸭的进化和驯化新模型,为动物驯化的研究提供了新的思路和资源。同时,我还估算了绿头野鸭和斑嘴野鸭物种分化时间约为两万年左右,处在物种形成的早期阶段,并且描绘了分化过程中基因组变化的全景图。为物种形成的研究提供了新的模型和重要数据。最后,我通过数据分析和实验手段揭示了非编码区域对于进化过程和物种形成过程的重要贡献。

关键字: 基因组 de novo 测序, 家鸭起源, 分子进化, 自然选择, 驯化

Abstract

The duck is one of the most economically important waterfowl as a source of meat, eggs and feathers. Duck is also a kind of highly ornamental value that is stocked in lakes, parks and other human recreational places. In general, the duck was considered to be domesticated from the mallard or the descendant of the mallard and spot-billed duck. However, domestic ducks showed significantly phenotypic diversity from these two wild populations. For example, the mallard and spot-billed make seasonal migrations. In contrast, domestic ducks are tame in behavior, and can't migrate which require the capacity for long time sustained flight, orientation and navigation. Recent Beijing duck whole genome sequence provide an important resource for functional analyses. However, The molecular genetics about ducks' origin and their phenotype variation are still poorly studied.

In this study, cooperating with BGI colleagues, I sequenced the whole genome of a female mallard and a female spot-billed duck using methods similar to those applied to the Beijing duck genome. I generated a high-quality mallard assembly and a high-quality spot-billed assembly with three short insert size libraries (250 bp, 500 bp, 800 bp) and four mate-pair libraries (2 kbp, 5 kbp, 10 kbp, 20 kbp). The contig N50 and scaffold N50 values of mallard genome assembly and spot-billed genome assembly were 37.78 kbp, 33.30 kbp and 2.05 Mb, 2.48 Mb respectively. Moreover, we found that the two wild duck genome assemblies had a high heterozygosity rate (3.59×10^{-3} , 3.53×10^{-3}) and TE (repetitive elements) content (136 Mb, 139 Mb) than Beijing duck genome (2.61×10^{-3} , 80 Mb).

Moreover, I performed whole-genome sequencing on 7 domestic breeds and 8 wild populations of duck, together with taihu geese and muscovy as outgroups. Surprisingly, my date indicated that the ancestors of domestic ducks diverged from their closely wild relative lineage (mallard and spot-billed ducks) at the last glacial period (LGP, 100~200 kilo years ago). Subsequently, the wild lineage was under the adaption selection, which might contribute to prevent the decrease in their population size. We found genes in or closet to these selective sweep regions were related to the development and morphogenesis of limb, lung, cardiac ventricle and respiratory system, energy metabolism and determination of body shape formation. Further analysis suggest that these selective sweeps might the main drive of the speciation of mallard and spot-billed. However, the domestic lineage seemed didn't advantage from such an adaption, and thus decreased continuously their population size during the LGP. Detail selective sweep analyses on domestic ducks identified 91 protein coding genes located around 73 regions that probably represent targets for selection during the initial stage of domestication. These genes were enrichment on the feeding behavior, courtship behavior and androgen metabolic process and nervous system development which might contribute to the tame behavior and ornamental value in domestic ducks. We thus proposed that the domestic ducks may have been subjected to human-derived selection for view and tame pet purpose during the initial stage of domestication.

We also found that genes related to lipid, carbohydrate and protein metabolic process were under selection. This may due to domestic ducks have the plenty of food resource after they living with human. Furthermore, we performed luciferase reporter assays on six condidate casual variants that were considered to be functional important in the evolution of ducks. Four of the six candidate casual variants showed significant different effects on luciferase reporter activity.

In summary, we generated high-quality assemblies of mallard and spot-billed respectively. I used high-coverage whole-genome sequencing to generate comprehensive genetic variation in wild and domestic duck populations. Detailed analyses suggested that ducks presented a distinct domestic model, which give an new example to understand animal domestication. Moreover, I inferred that mallard ducks diverged from spot-billed ducks at about 20 kyr which are in very recent speciation stage. I demonstrated that the genomic landscape of ducks divergence provided important resource for speciation study. In addition, I found that genetic variation in non-coding regions might accelerated genomic diversity and speciation process.

Keywords: de novo assembly, duck domestication, molecular evolution, natural selection

缩略词

缩写	英文全称	中文名称
bp	base pair	碱基对
BAC	Bacterial Artificial Chromosome	细菌人工染色体
Bj	Beijing Duck	北京鸭
CDS	Coding Sequence	编码序列
Cp	Campbell Duck	康贝尔鸭
Cv	Cherry Valley Duck	樱桃谷鸭
EST	Expressed Sequence Tags	表达序列标签
GO	Gene Ontology	基因本体
Gy	Gaoyou Duck	高邮鸭
INDEL	Insertion Deletion	小片段插入或缺失
Jd	Jingding Duck	金定鸭
Kyr	Kilo years ago	一千年以前
KEGG	Kyoto Encyclopedia of Genes and Genomes	京都基因与基因组百科全书
Lc	Lianchengbai Duck	连城白鸭
LGP	Last Glacial Period	末次冰期
LGM	Last Glacial Maximum	末次盛冰期
LINE	Long Interspersed Nuclear Elements	长散布重复序列
LTR	Long Terminal Repeats	长末端重复序列
miRNA	microRNA	小 RNA
Ma	Mallard Duck	绿头鸭
Myr	Million years ago	一百万年以前
PCA	Principal Component Analysis	主成分分析
SNP	Single Nucleotide Polymorphism	单核苷酸变异
SINE	Short Interspersed Nuclear Elements	短散布重复序列
Sp	Spot-Billed Duck	斑嘴鸭
Sx	Shaoxing Duck	绍兴鸭
Sm	Shanma Duck	山麻鸭
TE	Transposable Element	转座子元件
UTR	Untranslated Region	非翻译区

目录

摘要.....	I
Abstract.....	III
缩略词.....	V
目录.....	VI
第一章 综述.....	1
引言.....	1
1.1 测序技术的发展及其应用.....	1
1.1.1 第一代测序技术的简介.....	2
1.1.2 第二代测序技术及其应用.....	3
1.1.3 第三代测序技术简介.....	5
1.1.4 基于高通量测序技术的基因组组装.....	6
1.1.5 高通量测序带来的生物学大数据处理困难.....	8
1.2 基于基因组的群体历史推断与选择分析.....	10
1.3 利用基因组学方法研究驯化的进展.....	13
1.4 利用基因组学方法研究物种形成的过程.....	15
1.5 鸭基因组序列构建和家鸭起源与驯化的研究.....	16
第二章 实验材料及分析方法.....	18
2.1 实验仪器设备.....	18
2.2 实验试剂与溶液配制.....	18
2.2.1 常用缓冲液.....	18
2.2.2 质粒提取相关试剂.....	19
2.2.3 细胞培养试剂.....	19
2.3 用于基因组组装的样品提取与建库测序.....	19
2.4 用于重测序分析的样品的选取与基因组提取.....	22
2.5 基因组组装与功能注释的方法.....	23
2.6 遗传变异的鉴定方法.....	25
2.7 群体结构分析方法及原理.....	25
2.8 群体历史推断方法及原理.....	26

2.8.1 使用 $\partial a \partial i$ 重构家鸭与野鸭分化的群体历史	26
2.8.2 使用 psmc 重构家鸭与野鸭的群体历史	27
2.9 探测基因组受选择区域的方法	28
2.9.1 分化早期选择信号的探测方法	28
2.9.2 驯化过程中受选择区域的探测方法	30
2.10 验证受选择变异位点活性的方法	31
2.10.1 验证位点的选取	31
2.10.2 PCR 扩增	32
2.10.3 PCR 扩增产物和酶切片段的回收	32
2.10.4 连接反应	33
2.10.5 转化	33
2.10.6 菌落 PCR 鉴定	33
2.10.7 去内毒素质粒 DNA 提取	34
2.10.8 细胞复苏、传代培养及冻存	34
2.10.9 细胞转染	35
2.10.10 荧光素酶活性检测	35
第三章 分析结果	36
3.1 绿头野鸭和斑嘴野鸭基因组测序、组装与注释	36
3.1.1 数据过滤和基因组大小估计	36
3.1.2 绿头野鸭和斑嘴野鸭基因组的组装及 supperscaffold 构建	37
3.1.3 利用 EST 和 BAC 对基因组组装进行评估	38
3.1.4 重复序列, 基因结构和基因功能注释与比较基因组学分析	41
3.2 鸭种群的群体多样性和群体结构分析	43
3.3 家鸭起源分析	46
3.4 野鸭祖先群体当中受到的自然选择	52
3.5 绿头野鸭和斑嘴野鸭的种化分析	60
3.6 家鸭驯化过程中遗传改变的鉴定	64
3.7 受选择致因变异的功能验证	72
第四章 自动化分析流程的设计与实践	74
第五章 结论、讨论与展望	78

参考文献.....	80
致谢.....	85
附录.....	86
个人简历.....	114

第一章 综述

引言

鸭是最具经济价值的水禽之一，其肉，蛋是重要的食物来源，羽毛是羽绒产品的原材料。并且鸭是禽流感病毒的天然宿主，可携带除 H13 和 H16 亚型以外的所有 16 种 HA 和 9 种 NA 亚型的毒株，而通常这些病毒并不会使鸭致病 (Huang et al., 2013)。除此之外，包括鸭在内的许多水禽拥有发达的尾脂腺，能分泌大量油脂，有使羽毛润滑和防湿的作用。水禽通常还拥有强大的脂肪合成存储能力，比如填鸭的鸭肝为正常鸭肝的 2 倍，但是停止填鸭 2-3 周后鸭肝能恢复正常。因此，鸭在脂肪合成和代谢上的特异生物学特点，是肥胖，脂肪肝等相关疾病的重要研究模型。

关于家鸭的驯化起源，普遍认为是起源于绿头野鸭，或绿头野鸭与斑嘴野鸭的杂交后代。关于驯化的地点，普遍的观点是 3000 年前从亚洲或者中国驯化然后传到欧洲及全世界。部分研究未明确提及基于何种证据 (Mason, 1984)，也有研究基于亚洲拥有种类最多的家鸭品种来说明亚洲为鸭子的驯化中心 (Zeuner, 1963)。Serjeantson 等认为，野鸭可能是被中国地区的水稻田或收割后的田野放牧茬所吸引进而被驯化 (Serjeantson, 2009)。其中我国江苏余姚一带出土的距今七千到九千年前的河姆渡文明遗址就有鸭的头骨。勉县、汉中市出土的东汉时期的文物中有陶鸭，西昌礼州汉墓出土的文物“陶塘”上已经有鸭子的雕塑，说明两千多年以前我国已经开始从事养鸭的生产。家鸭与野鸭的差异也是多方面的，比如野鸭有很强的飞行迁徙能力但家鸭不具备这种能力。家鸭通常比野鸭体型较大，而且产蛋量也更多。家鸭又有很多特性非常不同的地方品种和商业品种。从遗传学角度来看，生物个体表现出来的差异，主要是由于 DNA 的差异造成的，因此，通过基因组 DNA 来评估各个品种，种群之间的差异及遗传多样性，遗传结构，挖掘具有价值的功能基因非常有意义。

动物的驯化过程被认为是由人类介导的，对于人类文明进程有重要意义的过程。驯化动物的表型以及行为相对于其野生祖先来说发生了巨大而快速的改变，因此对于研究表型变化背后的遗传基础是非常理想的材料，具有较高的理论价值。狗，猪，鸡等重要驯化动物的基因组草图的相继完成，极大地促进了这一领域的研究。2013 年鸭的基因组草图绘制完成 (Huang et al., 2013)，在此基础上，本人利用第二代基因组测序技术对多个野鸭与家鸭群体的多个个体进行测序，在全基因组水平上展开对鸭的起源历史以及进化选择的研究。

1.1 测序技术的发展及其应用

2003 年，历时 13 年，投入 38 亿美金的人类基因组计划完成，该项目主要使用的是 Sanger 法为主的第一代测序技术。人类基因组项目的实施极大推动了测序技术的发展，也带动了测序成本的下降。下降的速率甚至超过了摩尔定律 (图 1-1)。得益于测序技术的发展以及测序成本的降低，许多模式生物的基因组相继被测定，基于二代测序的研究方法逐渐成为了进化生物学的主流研究手段，传统的遗传学也藉此焕发出了新的活力。伴随着二代测序数据的迅速积累，产生许多新的方法和理论框架，如溯祖理论，新的统计方法，机器学习和和其他一些根据进化遗传学原理派生出来的新的方法和理论，丰富的数据和新的理论框架更加

详细的展现了基因组在进化上的各种特性,极大地丰富了人们对基因组以及生物进化的认识。




图 1-1 测序成本的逐年下降 (https://www.genome.gov/pages/der/seqcost2015_4.xlsx)

1.1.1 第一代测序技术的简介

第一代 DNA 测序技术指的是,由 Maxam 和 Gilbert 建立的化学降解法,或由 Sanger 等人建立的链终止法(Sanger et al., 1977)。而使用较多的是双脱氧末端链终止法。一方面因为化学降解法中的化学试剂毒性大,放射性同位素标记对人有伤害。另一方面是因为链终止法更易自动化。其中链终止法又称 Sanger 法或双脱氧终止法,其基本原理是将 DNA 单链模板在 DNA 聚合酶,引物和四种带有 P32 标记的单脱氧核苷三磷酸 (dNTP) 存在条件下复制时,在四管反应系统中分别引入少量四种双脱氧核苷三磷酸 (ddNTP),当双脱氧核苷三磷酸参与链的合成时,反应就会终止,该链就无法继续延伸。对这四个管分别在四个泳道上进行凝胶电泳,会发现每个泳道上都有与其他泳道位置不同的长短不一的片段的条带,据此可以读出碱基的排序 (如图 1-2)。Sanger 测序法从最初的使用同位素标记手工完成,经历了荧光标记,自动化测序到毛细管电泳的发展历程。美国 ABI 公司生产的 3730 测序仪就是采用 Sanger 法为原理。该测序仪拥有 96 道毛细管电泳装置,整合了一体化自动进样器,自动灌胶系统,氩离子激光源等装置,并带有 ABI 专门的软件分析系统,实现了自动碱基识别与质量评分判定。第一代测序技术的特点是读长较长 (可达 1000 bp),但是实验步骤复杂,测序通量低,成本高,测序周期长等不利因素。随着许多对于第一代测序技术的改进,诞生了第二代测序技术。但第一代测序技术也并未因此而退出历史舞台,而是与二代测序互补的应用于不同的测序市场需求。并且也常常用作二代测序数据的准确性验证工作。




图 1-2 Sanger 法测序原理 (<http://wenku.baidu.com/view/0b2cd23bbb4cf7ec4bfd01a>)

待测序的 DNA 单链模板在四个分别加入四种少量双脱氧核苷酸的试管中分别进行链合成，当双脱氧合谷氨酸参与合成时，该链将无法继续延伸。在四条凝胶泳道上各自会出现长短不一的条带，据此读出碱基排序。

1.1.2 第二代测序技术及其应用

第二代测序技术 (Next-generation sequencing technology) 又称高通量测序技术 (High-throughput sequencing)，以能一次并行对几十万到几百万条 DNA 分子进行序列测定为标志。同时，高通量测序使得对一个物种的转录组和基因组进行细致的全貌分析成为可能，所以又被称为深度测序 (Deep Sequencing)。目前市面上主流使用的二代测序平台是 Illumina/Solexa GenomeAnalyzer 测序平台，其核心思想是边合成边测序，本研究所使用的测序数据就是来源于 Illumina 的测序平台，所以这里简单介绍一下该平台测序的大致流程 (图

1-3):

(1) 文库的构建：即用物理的方法将提取的基因组随机打碎为小片段，然后在两端加上接头。

(2) 锚定桥接和预扩增：利用微注射系统将已经加过接头和待测片段随机添加到测序芯片 (flow cell) 上，芯片光学透明且固定有与接头片段互补的序列，每一个测序芯片又分成 8 条 lane，每条 lane 的内表面上以共价键的形式随机固定单链接头序列和带接头的单链待测 DNA 片段。加接头的 DNA 片段与测序芯片连接锚定之后，即可对这些 DNA 片段进行原位扩增，通过桥式 PCR 扩增得到上亿条成簇分布 (cluster) 的待测序列。




图 1-3 Illumina 测序平台的测序流程 (图片来自 Illumina 测序仪说明书)

其中, 图 1,2 为将基因组 DNA 片段连接在测序芯片的内表面; 图 3 为桥接扩增; 图 4 形成双链; 图 5 双链退火; 图 6 完成扩增; 图 7, 8 为碱基成像。

(3) 单碱基延伸测序: 这一步反应中就使用了 Illumina 平台“边合成边测序”的原理。在 flow cell 内加入未被标记的 dNTP 和酶, 进行固相桥式扩增, 所有单链桥型待测片段被扩增成双链桥片段, 通过变形, 释放出互补的单链, 锚定到附近的固相表面 (图 1-3 的 3-4)。通过不断循环, 将会在 flow cell 的固相表面获得上百万条成簇分布的双链待测片段 (图 1-3 的 5-6)。每个循环过程里面, 四种不同荧光标记的 dNTP 和 DNA 聚合酶被加入到单分子阵列中, 互补的核苷酸和 DNA 片段的第一个碱基配对, 通过聚合酶加入到引物上, 多余的核苷酸被移走。这样随着每一轮反应的进行, 不同的碱基加到引物后端时释放出不同的荧光, 荧光信号被 CCD (charge-coupled device) 采集, CCD 快速扫描整个阵列捕获荧光信号并转化为一个测序峰值, 依次判定序列的碱基排布 (图 1-3 的 7-8)。

除了目前市场上最主流的 Illumina 公司生产的二代测序仪以外, 还有许多其他各具特点的二代测序仪, 简单介绍如下:

454 测序仪是一款具有革命性意义的基于焦磷酸测序法的高通量基因测序系统, 被《自然》杂志以里程碑事件报道, 揭开了测序历史上新的一页, 拉开了二代测序技术的序幕。其测序过程主要包括: 1) 文库准备。2) 连接接头。3) PCR 扩增。4) 测序。与其他二代测序仪相比, 其突出优势是较长的读长, 目前 GS FLX 测序系统的序列读长已经超过 400 bp。

SOLiD (Sequencing by Oligonucleotide Ligation and Detection) 是 ABI 公司推出的二代测序仪, 与 454 和 Illumina 的合成测序有所不同, SOLiD 是使用连接法测序获得基于“双碱基编码原理”的 SOLiD 颜色编码序列, 然后与原始颜色序列进行比较。其特点是可以自动校正测序错误, 并且结合原始颜色序列的质量信息发现潜在 SNP 位点。测序准确性高, 通量大。

Ion Torrent 测序仪是一款相对经济实用的测序仪, 操作也相对简单, 主要适用于小型基因组。它是第一个不需要光学系统的商业测序仪, 所采用的技术为半导体测序, 利用 DNA 聚合酶把核苷酸聚合到延伸中的 DNA 链上时, 释放出氢离子导致 PH 值变化产生电信号来读取 DNA 序列。测序长度较长, 速度快。由于其并不需要昂贵的物理成像设备, 因此, 成本较低, 体积也比较小。由于该技术中也是用了 PCR 扩增技术所以我们倾向于将其归为第二代测序技术, 也有人将其归类为第三代测序技术。

第二代高通量测序技术的发展, 不仅为分子进化等基因组学相关的研究提供了良好的平台, 经过改进之后其应用还被扩展到转录组 (RNA-Seq), 基因组甲基化分析, 染色质免疫共沉淀 (chromatin immunoprecipitation sequencing, ChIP-Seq) 以及近些年研究比较火热的 3D 基因组的研究。

1.1.3 第三代测序技术简介

第二代测序都需要对样品进行 PCR 扩增, 增加了试剂成本, 通过光学成像分辨碱基的方式需要记录, 存储分析大量光学图像。除此之外, 扩增后得到的 DNA 片段的比例和扩增之前 DNA 分子片段的比例有偏差, 对于后续分析尤其是表达分析有一定影响。因此人们提

出了直接测序的概念，也就是第三代测序技术。其最大特点就是测序过程无需进行 PCR 扩增的单分子测序，通常比二代测序有着更长的读长以及更快的测序速率。三代测序按其技术原理目前主要分为两种，一种是利用荧光信号进行测序，另一种是利用不同碱基通过纳米孔时产生不同的电信号来进行测序。也有人将纳米孔测序技术称为第四代测序技术。

目前市场上主要使用的第三代测序技术是美国太平洋生物 (Pacific Biosciences) 公司的 SMRT 技术。其测序原理是：将 DNA 聚合酶、待测序列和四种不同荧光标记的 dNTP 放入 ZMW (zero-mode waveguides, 零模波导孔) 孔的底部，进行合成反应。与其他技术不同的是，这里荧光标记 dNTP 的位置是磷酸基团而不是碱基。DNA 聚合酶被固定在孔内，在 DNA 片段延长的过程中，当一个 dNTP 被添加到合成链上的同时，这种特定颜色的荧光会持续一小段时间，直到新的化学键形成，荧光基团被 DNA 聚合酶切除。通过测定小孔内的荧光的连续变化情况，就可以测定每个孔内的 DNA 模板的序列 (图 1-4)。




图 1-4 PacBio RS 测序仪工作原理 (Eid et al., 2009)

这种测序技术测序速度很快，可达每秒 10 个碱基 (Zhang et al., 2016)。并且读长很长，在一篇关于小蓬草基因组组装的报道中其测序平均读长可达 3.1 kb (Peng et al., 2014a)。此外，SMRT 测序技术经过改进，还可以直接对 RNA 序列和甲基化 DNA 序列进行测定。但是目前三代测序技术也面临价格昂贵，测序错误率太高等问题，但是其出错是随机的，并不会像二代测序技术一样存在测序错误的偏向，因此可以通过多次测序等方法来克服这一困难。

1.1.4 基于高通量测序技术的基因组组装

获得全基因组碱基排序目前已经成为几乎所有生物学研究分支的基石。对于全面了解一个物种的分子进化，基因组组成和基因调控等有着非常重要的意义。随着测序技术尤其是高通量测序技术的发展，使得各个研究单位独立的开展全基因组从头测序成为可能。2008 年首个利用高通量测序技术得到的人类全基因组序列的研究成果发表在《自然》杂志 (Wheeler et al., 2008)。2010 年首个完全由高通量测序技术完成的基因组序列拼接工作的成果发表 (Li et al., 2010)。

虽然二代测序技术具有高通量低成本 (相对于第一代测序技术) 的特点，但是其测序读长短，reads 量大，这给基因组的组装带来了很大的挑战。这些挑战使得人们在 de novo 组装算法改进方面做了巨大努力，其主要算法有贪婪算法，overlap-layout-consensus (OLC) 和 de Bruijn 图算法。一些软件，比如 phrap, Celera assembler, ARACHNE, Phusion, RePS, PCAP, Atlas 等，虽然成功的应用在基于 Sanger 技术的全基因组测序的组装。但是其原理都是基于

测序片段之间重叠的策略来组装基因组。因此不适用于基于短 reads 的基因组组装。针对二代测序数据,有基于贪婪算法的 SSAKE, SHARCGS, VCAKE 和 QSRA 等软件。这些软件使用一个相同的基本策略,即迭代延伸的方式延长 contig。其中 SSAKE, ACAKE 和 QSRA 被用于处理不完整匹配的 reads,而 SHARCGS 被广泛用于长度一致,高覆盖度和不成对的短 reads。还有基于 OLC 算法的 CABOG, Edena, Newbler 和 Shorty。OLC 算法主要包含三个步骤:首先是 overlap 探测阶段,比较 reads 之间的重叠构建重叠图。第二步为 layout 阶段,分析重叠图并且找到最佳的路径遍历整个重叠图。第三步是通过多序列比对构建一致序列。2001 年在一款名为 EULER (Pevzner et al. 2001) 的基因组组装软件中首次使用了 de Bruijn 图的数据结构。该数据结构特别适合于表示短 reads 之间的重叠关系。这种数据结构使用以 K-mer 为点,沿 read 的路径为边的图(图 1-5)。因此图的大小就决定于基因组的大小和重复序列的含量。之后有一系列组装软件采用此算法,诸如 Velvet, ALLPATHS, 和 EULER-SR 都使用这种算法,并且取得了很好的效果。但是这些软件都只能处理诸如细菌或真菌的基因组,受到内存的限制,无法应用到如人类基因组这样的大型基因组的组装。华大基因的 SOAPdenovo 软件很好的解决了这一问题 (Li et al., 2010)。该软件也是目前为止唯一一款结合 OLC 和 DBG 算法的软件。本研究就使用了这款软件进行基因组组装。Narzisi 等人认为,由于基因组和测序数据的复杂性,组装长度,准确性与覆盖度之间往往是一个平衡的关系 (Narzisi and Mishra, 2011)。为了取得良好的组装效果,通常会使用不同插入长度的文库,利用 pair-end read 连接不同的 contig 成为 scaffold,而大片段插入文库对于提高 scaffold N50 有很重要的作用。




图 1-5 De bruijn 图构建原理示意 (Compeau et al., 2011)

a 为一小段基因组 DNA 片段。b 表示 sanger 测序策略下,使用图表示序列的方法,称为哈密顿环:即寻找一个环路,访问且仅访问每个节点(reads)一次。短 read 测序法最早用图来表示一段序列的方法也是哈密顿环,但将 reads 切成 k-mer,其中灰色部分是重复的 k-mer。如图中 c 所示延红线箭头方向可以构建出基因组序列。更先进的用图表示序列的方法是图 d 所示的用边来表示不同的 K-mer。

基于二代测序数据进行的基因组组装仍然面临许多问题, 诸如对于富含 GC 或 AT 的序列以及同型核苷酸 DNA 片段测序存在困难, 这一类序列的测序输出往往会偏向性的减少。另外, 对于短 reads 的组装往往对于重复序列元件无能为力。因此, 人们开始逐渐的采用第二代与第三代测序技术结合的基因组组装策略, 三代测序不需要 PCR 扩增, 因此对于富含 GC, AT 与同核型的核酸片段并不存在测序偏差, 而其测序片段长的优势可以测穿整个重复序列。从而弥补二代测序在基因组组装上的问题。目前已有一些报道使用这种结合的方法进行基因组组装 (Faino and Thomma, 2014; Mostovoy et al., 2016; Peng et al., 2014b)。

1.1.5 高通量测序带来的生物学大数据处理困难

随着测序技术的发展, 尤其是二代测序带来的测序成本的下降, 越来越多的基因组测序项目得以开展, 使得人们以前所未有的雄心尝试整合遗传, 分子, 以及表型信息, 也使得基因组学等生命科学子学科逐渐成为了数据驱动的学科, 因此面临巨大的计算以及信息处理方面的挑战。用基因组数据去研究生物进化、理解表型以及分子表型背后的遗传基础、进而预测表型, 已经成为生物学最活跃的核心领域 (Zerbino et al., 2012)。

当前的基因组研究方法以基因组组装为起点, 通常对某一个种群的某一个个体的基因组构建不同大小的文库, 进而通过测序得到足够丰富的冗余的 DNA 小片段, 根据小片段的重叠部分逐渐的拼接成一个完整的基因组碱基排序信息, 以此作为该物种基因组的参考序列。即从头测序 (de novo)。之后再对该物种的其他个体进行小片段文库的测序, 将测得的 DNA 小片段比对到该参考序列上, 从而比较不同个体基因组之间的 DNA 的变异, 称为重测序 (ressequencing)。而这种全基因组范围内的比对也会因区域的不同而出现差异, 受到纯化选择的区域的序列保守性会很高。比如直系同源编码蛋白区域通常可以跨物种的进行良好的比对。中性漂变的区域则相比于保守区域分化的更加快, 一般只有近期分化的物种能够良好的比对上。对多个物种的基因组进行比对或一个物种的多个基因拷贝进行比对, 提供了一个系统发生树的构建方法, 可以明确地知道基因的进化顺序, 这类系统发生树构建模型主要考虑的是插入、缺失和碱基替换事件。而基于碱基替换和插入、缺失的系统发生分析因同源重组事件而变得更加复杂。而溯祖理论正是一种考虑了碱基替换以及同源重组来模拟进化历史的模型。除此以外, DNA 序列之间的进化关系还应该考虑倒位, 片段顺序改变, 片段重复, 片段插入, 片段缺失等事件。然而目前的进化研究都是单一的考虑某一两项因素, 构建一个统一的进化理论将这些因素都包含进来是这个领域的一大挑战。

充分理解进化过程, 离不开海量的多样的信息整合, 这需要强大的数据处理技术的支撑。而这正是当前生命科学领域面临的一个重要问题。单个研究人员很难利用现有的工具和方法去恰当的处理分析海量的数据, 并且数据分析的过程也很难能被其他的研究者理解, 评估与重复。

对此, 包括生命学科领域与计算机科学领域在内的科学家与工程师们做出了诸多的努力, 比如维也纳大学的 Niko Popitsch, 加州大学的 Scott Christley 等在解决数据压缩与存取方便性方面的工作 (Christley et al., 2009; Popitsch and von Haeseler, 2013)。哈佛大学和麻省理工的 Mark A DePristo 等在二代测序数据变异检测方面设计了分析框架 (DePristo et al., 2011)。宾夕法尼亚大学 Anton Nekrutenko 和埃莫里大学的 James Taylor (Nekrutenko and Taylor,

2012) 在大数据处理及存取方面提出了一些具有普遍意义的观点, 他们认为:

1. 在数据分析实践过程中应该更多采用已有的经过验证的方法。

拿探测变异来说, 由千人基因组技术的推动, 产生了一系列发现变异的方法实践, 一个典型的发现变异的分析包括去 PCR 重复, 质量校正和优化比对, 之后是基因分型, 优化变异探测结果, 以及对变异的注释。但是在千人基因组上的成功实践很难应用到其他非模式生物, 因为这需要一系列依赖辅助数据的分析步骤, 而这类辅助数据仅有少数有良好注释的基因组才有, 大多数研究都选择了更为直接的方法, 这样就潜在的牺牲了分析的质量。

2. 关于数据分析实验的可重复性上存在的问题和一些解决方案。

重复数据分析实验需要提供原始数据, 分析过程中软件的详细参数与版本, 基因组参考序列的版本等详细信息。缺少这样的信息使得有些相同的研究, 研究结果存在很大差异。比如两篇分析头与颈部鳞状细胞癌的研究分析得到的潜在致癌的错义突变没有任何交集 (Agrawal et al., 2011; Stransky et al., 2011)。而由于两篇研究都缺乏详细的分析信息所以制约了对这两篇研究的评估。

3. 集成分析与可视化将使的数据更加易于理解。

这里所指的集成既包含集成各种分析工具, 也包括集成多维数据和诸多已有基因组数据。首先, 对于普通研究人员来说对二代测序数据的操作分析是一件很困难的事情, 任何一项生物信息分析都可能需要一系列步骤, 相应的需要使用一系列软件并熟悉一系列参数, 并且二代测序数据的规模通常很大, 每个软件的运行都会非常耗时, 运行过程当中随时都可能会有意外和错误产生, 因此仅仅是每一项基本的生物信息分析步骤就会耗费研究者大量的时间和精力去关注每一个细节和调整每一个参数。其次, 重复数据分析实验需要每一步分析的详细记录, 而通常的研究报告并没有提供足够的信息去重复分析实验。针对这些问题, 一系列集成框架被开发出来, 比如 BioExtract、Galaxy、GenePattern、GeneProf、Mobyle (Agrawal et al., 2011; Goecks et al., 2010; Halbritter et al., 2012; Lushbough and Brendel, 2010; Neron et al., 2009; Reich et al., 2006) 等。这些软件可以帮助用户管理软件以及参数, 并且在非常精确详细的级别自动的记录分析过程。并且集成分析、集成其他已有的分析结果和数据可视化可以帮助用户更加直接实时的看到不同参数对分析结果的影响, 更将直观的观测数据的特性。也更加有助于对分析结果的可靠性进行评估。

针对数据分析实验的可重复性问题, Geir 等人提出了十条简单的原则: 1) 对每一个结果, 保存得到这个结果的 Track。2) 避免手工的数据处理。因为程序处理只要逻辑正确语法正确则结果就一定正确, 而手工处理的话出现各种各样的问题的可能性较大。3) 记录所有使用的软件的版本。4) 对所有自编脚本进行版本控制。可以采用标准的代码改进追踪解决方案, 比如 Git、Subversion 等。5) 尽可能保存中间结果, 至少在进行一项分析的时候保存这项分析的所有中间结果。6) 对包含随机数的分析保存该随机数。7) 总是保存画图所使用的数据。8) 生成层级分析结果, 使得每一增加细节的环节都可以被调查。9) 为每一个分析结果的产生注释一段文本的说明。使得研究者再回过头来看的时候, 可以快速明白这个分析的参数的设置过程中都考虑了哪些因素。10) 提供可公开访问的输入数据, 脚本, 版本和参数等。

在现有的关于生物大数据 (或者说是大体量的数据, 主要是指二代测序数据) 分析方面的探索实践、思考和总结的基础之上, 结合本人在做该进化项目的实践以及本人的信息技术的

背景。本人设计、实现了一套生物大数据分析系统,并且应用在了本研究当中,取得了非常好的效果。

1.2 基于基因组的群体历史推断与选择分析

群体遗传学属于微观进化的范畴,它的两个主要目标是构建群体历史和识别受到选择的基因组区段。群体进化过程中的各种事件都会对群体的基因组产生影响,比如群体分化,群体扩增,群体收缩,迁徙,群体混合都会在基因组上留下相应的印迹,然而自然选择同样能在基因组上留下非常相像的信号。根据基因组上的这些印迹推断群体的进化历史则是群体进化分析以及选择分析的基石。从理论上讲,经典的群体遗传学的基本理论框架在 20 世纪初便由英国数学家哈迪和德国医学家温伯格提出。这种经典的群体遗传学的理论思想是面向未来的,即从当前的群体参数出发,预测群体在未来会有什么样的发展趋势。而 20 世纪 80 年代初期,英国数学家 Kingman 用两篇极具开创性的论文建立了溯祖理论,与经典的群体遗传学不同的是,溯祖理论是面向过去的。溯祖理论同样有其严格的数学基础,实际上溯祖理论可以看成是利用分析数学和统计学理论来回溯序列之间的变异过程。从方法上讲,推断群体历史的方法可以分为两类:一类是模型限定的方法,这类方法要求研究者事先给定群体模型(比如群体保持恒定大小一段时间之后紧接着群体扩增,之后分化为两个群体)。模型的参数将通过拟合期望特征与实际数据的特征得到,主流的方法有:ms 利用溯祖理论模拟,∂a∂i 利用基于扩散方程的方法从过去某时间点到现在模拟等位基因频率谱(AFS)的变化,IBS tracts 通过溯祖理论模拟群体内或群体间共有 IBS 的长度推测群体历史。以及基于贝叶斯框架推断的 ABC (Approximate Bayesian Computation) 方法等。另一类是非模型限定的群体推断,比如 PSMC (Pairwise Sequentially Markovian Coalescent), MSMC (Multiple sequential Markovian Coalescent) 等。

随着研究的深入和基因组数据的极大丰富,越来越多的信息被用于群体历史的推断,出现了许多新的方法和思路。比如 Nick Patterson, David Reich (Durand et al., 2011; Patterson et al., 2012) 等在人类进化历史的研究中,提出了 D-statistic 方法与 F-statistic 方法(如 f3, f4, roll off 等)可以进行深入和混群事件的推断,roll off 方法甚至可以根据各个群体 LD 衰减的相关性,推断混群发生的时间。通过单倍型,LD,多态性等信息也可以进行群体历史的推断(Conrad et al., 2006),其基本假设是同一族群相对于其他族群有更多相同的单倍型,而共有单倍型的程度又在一定程度上反应出群体的历史,祖先群体通常具有最高的单倍型多样性,随着进化上离祖先群体距离的增加,单倍型的多样性也会降低。虽然连锁不平衡的程度在不同群体中变化很大,但仍然有大量共同的单倍型结构存在。据此可以从一定程度上对进化关系进行推测。主成分分析 (PCA, Principal Component Analysis),遗传结构分析 (genetic structure) 以及连锁不平衡衰减 (LD decay) 也广泛的应用在群体结构乃至群体历史的推测。另外,还有一些研究根据基因组上的纯和区域 (ROH) 大小,数量等对群体历史进行推断。

与群体历史变化紧密相连,同样对基因组有塑造作用的是选择,包括自然选择和人工选择。根据选择发生的时间,强度,区域以及类型的不同,其对基因组的塑造也有所不同。

自然选择学说是达尔文进化论的核心内容,其主要内容是:1) 生物界普遍存在着变异。2) 生物个体具有亲本的遗传性状,这是生物的一个普遍特征。3) 所有物种都要繁殖和生存,

为了更高概率的将自己的遗传信息成功传给下一代, 每个物种总是尽可能多的产生后代。4) 繁殖过度之后, 由于资源有限, 物种之所以不会数量大增, 是个体之间通过争夺有限资源进行相互斗争。5) 由于个体之间存在差异。于是在生存斗争之中适应环境的个体被保留下来, 称为适者生存。如今从分子水平上看, 生物进化的本质是基因频率的改变。作为进化理论的重要补充, 日本科学家木村资生在分子生物学研究中, 提出了分子进化中性学说。其有别于达尔文进化论, 提出在分子水平上, 大多数生物演化和物种内的大多数变异, 不是由自然选择引起的, 而是通过那些对选择呈现中性或近中性的突变等位基因的遗传漂变积累引起的。某种程度上, 中性学说可以看做是达尔文进化论的零假说, 在分析进化现象时有重要作用 (McDonald and Kreitman, 1991)。

在自然选择中, 主要存在三种不同类型的自然选择, 正选择, 纯化选择又称负选择或背景选择, 以及平衡选择。具体来说, 将二倍体种群中同一等位基因组上的两个不同的等位基因定义为 A, a , 假设 A 是野生型, a 是突变型。则该种群有三种基因型 Aa, AA, aa 。假设三种基因型的适应度 (携带该等位基因的存活的几率) 分别为 F_{Aa}, F_{AA}, F_{aa} 。将适应度转换为相对 AA 的适应度, 则三个基因型的适应度分别为 $1 + hs, 1, 1 + s$ 。从中可以看出, 选择系数 s 的正负及杂合效应 h 的大小决定选择的类型。当 $s = 0$ 时, 三种基因型的适应度相同, 进化是中性的。选择发生时, 当 $0 < h < 1$ 时, 会产生定向选择, 它使某种特定的基因频率增加或降低, 如果 $s < 0$, 表明突变基因 a 是有害的, 携带该基因的个体由于适应度低, 在自然选择中逐渐被淘汰, 这使得 a 在群体中的频率降低, 称之为纯化选择。反之, 如果是 $s > 0$, 表明 a 是有利突变, 在群体中频率会升高, 最终在群体中固定下来, 称之为正选择。当 $s > 0, h > 1$ 是, 杂合子有最高的适应度, 属于平衡选择。三类选择中, 我们通常关注正选择。

当等位基因 (遗传变异) 受到正选择时, 会在基因组上留下“信号”, 这种信号可以通过与中性区域比较而被识别出来。有很多统计检验方法可以探测正选择, Sabeti 等人将他们总结为本质上都基于五种信号 (Sabeti et al., 2006)。

1. 大比例的蛋白功能变异。

探测中性信号的检测方法有 Ka/Ks 检验。McDonald-Kreitman (MK) 检验。 Ka/Ks 检验基于编码序列的比对中非同义与同义突变的比值检测正向选择信号, 它涉及两类突变事件: 一种是同义突变, 即不改变氨基酸序列的突变, 一般认为这类的突变不会受到自然选择压力的作用, 或者受到选择压力比较小; 另一种是非同义突变, 即改变氨基酸的突变, 一般认为非同义突变是有害的, 因而一般会被纯化选择清除 (Makalowski and Boguski, 1998)。

MK 检验是由 McDonald 和 Kreitman 在 1991 年最先提出和运用的。MK 检验的原理: 在中性进化条件下, 基因在种内的同义、非同义突变应与种间同义、非同义突变成正比。反之, 则推翻零假设, 即该基因在不同物种中可能受到了选择的作用。McDonald 和 Kreitman 为了区分种内差异和种间差异, 将序列的位点分为两类: 一类是指在物种间有差异而在物种内无差异的位点, 称为差异固定位点; 另一类是指种内个体间有碱基差异的位点, 称为多态性位点 (Polymorphic sites)。然后分别计算两类位点中的同义替代和错义替代的数目。则在中性进化条件下, 非同义突变的固定位点数与同义突变的固定位点数的比值, 应该和非同义突变的多态位点数与同义突变的多态位点数的比值相

同。

2. 基于遗传多样性的降低。

由于优势等位基因频率的增加，染色体周围的变异的频率由于连锁也会增加，这种搭车效应导致了选择性清除 (selective sweep)，探测这种选择信号的统计量有 Tajima's D, Hudson-Kreitman-Aguade 检验 (HKA)，和 Fu and Li's D*检验等。

3. 基于高频的衍生等位基因。

衍生等位基因通过突变产生，相对于其祖先等位基因，他们通常有较低的频率。然而由于选择性清除造成的搭车效应会使之频率升高。最常用检测统计量之一是 Fay and Wu's H。

4. 基于群体之间的分化。

当地理隔离的群体在不同的环境，选择压力之下时，正选择会使得两个群体之间的频率改变并出现差异。典型的探测这一指标的统计量包括 F_{ST} 和 P_{excess} 。

5. 基于连锁不平衡的方法。

根据选择理论，正选择位点的频率会在群体中显著提高，而周围的位点由于搭车效应使得单倍型频率在群体中会高于群体均值，因此形成了拥有较长区域的连锁不平衡的单倍型结构。Sabeti 等人最早提出长范围单倍型检测 (EHH)，通过对核心单倍型 (Core haplotypes) 的频率及其衰减进行分析，在全基因组范围内对正向选择的信号进行扫描。核心单倍型指的是基因组中，重组率低的密集区域，同样也是 LD 高的区域。如果某个核心单倍型的连锁不平衡程度高于具有其相同频率的一般单倍型，且 LD 衰减慢，那么这个位点极可能受到了正选择作用。Voight 等人在 2006 年设计的 iHS 的方法，用来检测人类基因组近期正选择信号的一种方法。给定一个 SNP 位点，它是祖先等位基因的 iHH 相对于衍生基因 iHH 的比值。当衍生等位基因相对于祖先等位基因有着较高的频率和较长的单倍型 (衰减慢) 时，这可能是一个正选择信号。

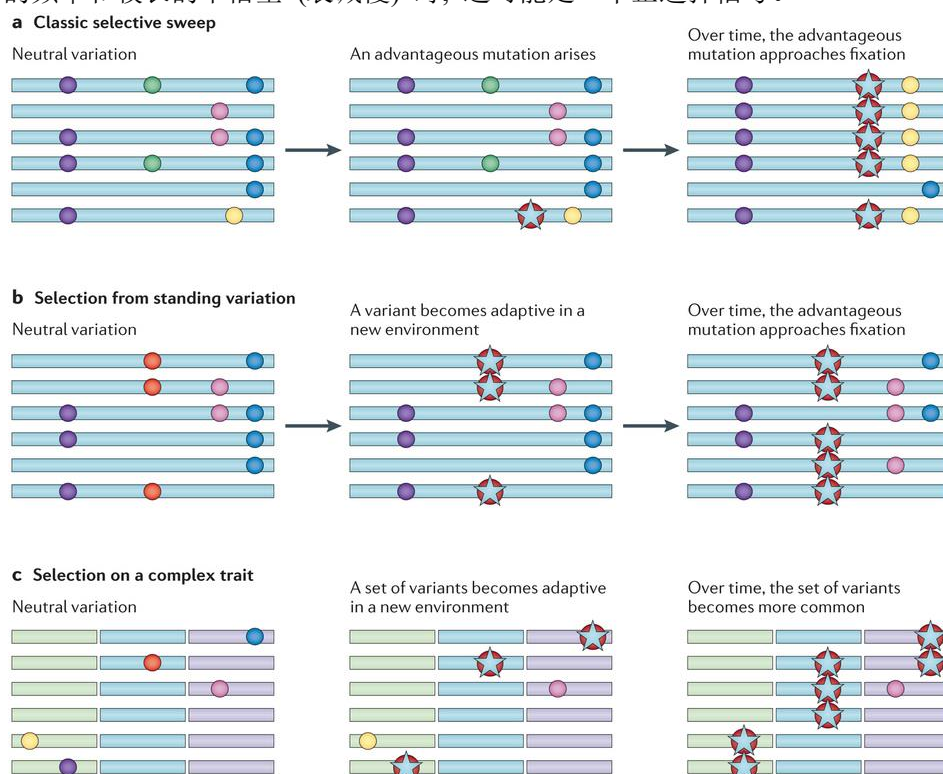


图 1-6 正选择信号的遗传特征 (Scheinfeldt and Tishkoff, 2013)

图中分别描述了三种遗传变异的频率随时间改变的情况。变异用圆圈表示, 长方形表示染色体片段。星形表示优势变异。a) 经典选择性清除。新的有利突变出现之后, 随后其在群体之中的频率不断增加直到接近固定。b) 已存在的变异受到选择。变异在群体中已经存在, 之后在一个新的环境中变成有利变异并且随着时间推移, 其在群体中的频率增加直到接近固定。因为这种变异存在于不同单倍型背景条件下, 所以很难用 EHH 检验检测到。然而, 当这种情况发生在一个限定区域, 会造成该群体的等位基因相对于另一个没有受到选择的群体频率显著扩增的结果。c) 选择发生在复杂性状相关的不同染色体的多个位点。造成多个位点等位基因频率发生细微的改变。

从微观上看, Scheinfeldt 等人将正选择信号的遗传特征总结为三类 (Scheinfeldt and Tishkoff, 2013)。如图 1-6 所示首先是经典的选择性清除, 即从无到有出现了新的有利突变, 其频率扩速增加 (包括附件的位点通过搭车效应)。第二种是已经存在的变异在新的环境条件下受到选择, 即变异从无用到有用。这种情况通常是涉及多个位点, 也即复杂性状的多因微效。

1.3 利用基因组学方法研究驯化的进展

驯化作为一个特殊的进化过程, 通常涉及剧烈的表型和行为的改变, 也因此成为了研究表型背后的遗传基础的极佳材料。驯化的研究主要集中在两个方面, 一方面是在基因组层面研究起源及群体历史问题, 另一方面是对优良性状基因组位点的发掘。其本质是群体遗传学中的群体历史推断和选择分析。近年来随着基因组数据的大量积累, 群体遗传学理论的发展和基因组研究新技术新思路的涌现。诸多物种中的驯化研究都取得了丰硕的成果。

其中 Elinor K Karlsson 等根据连锁不平衡和 F_{ST} 等方法找到了狗的一些孟德尔性状的致病基因, 并且提出了计算 F_{ST} 的估算方法 (Karlsson et al., 2007)。Car-Johan Rubin 等提出了一种计算杂合度的方法依次来探测选择性清除, 通过探测混池测序的 4 个商业肉鸡品种、4 个商业蛋鸡品种和一个红色原鸡品种的杂合度降低的区域, 找到了可能和鸡的驯化以及生长和繁殖相关的基因 (Rubin et al., 2010)。两篇研究都是 (或者部分) 由瑞典乌普萨拉大学的 leif Andersson 指导完成。2012 年 leif Andersson 团队继续使用其杂合度的探测方法找到了可能和家猪脊椎骨骨节数增加相关的三个位点。同时他们通过结构变异的分析找到了最明显的一个功能相关的结构变异, 在 KIT 基因上的一个拷贝数变异可能和猪呈现白色或黑白色相关。值得一提的是他们巧妙的探测到相比于野猪在驯化的猪当中衍生非同义突变显著的增加, 这点暗示出在驯化过程中的正选择作用。其逻辑是衍生等位基因可能是近期出现的并且由于正选择其频率会增加。如果两个群体的等位基因频率差异是由于遗传漂变造成的, 那么同义衍生突变和非同义衍生突变在家猪当中变为高频的概率应该是相同的。但是他们发现衍生型非同义突变在家猪群体当中变为高频的数目显著多于衍生型非同义突变在家猪中变为高频的数目。这反映出驯化过程中正选择的作用 (Rubin et al., 2012)。2013 年还是乌普萨拉的 Erik Axelsson 等结合之前 Karlsson 和 Rubin 的研究方法, 同时利用 F_{ST} 与杂合度的分析在狗与狼的全基因组混池测序的分析中找到了 36 个在狗从狼驯化过来的过程中受到选择的基因组区

域。两种信号的高度一致说明了狗中的选择性清除的区域和狗与狼高度分化的区域几乎是相一致的, 这显示这些区域就是驯化区域, 两种信号探测的是相同的事件。其中 19 个区域中包含和脑功能相关的基因, 其中 8 个和神经系统发育通路相关并且潜在的和狗驯化过程中的行为改变相关。10 个受选择的基因在淀粉消化过程中扮演重要角色 (Axelsson et al., 2013)。2014 年 leif Andersson 团队以兔子的驯化过程为研究对象, 研究了驯化过程初始阶段的遗传变化。用 Sweepfinder, F_{ST} -Hp 的方法找到了家兔当中的选择性清除区间 (即要求选择性清除被 Sweepfinder 或 F_{ST} , Hp 两种方法同时找到), 并且用溯祖理论模拟了选择信号的形成过程。非常值得一提的是他们通过巧妙的设计发现了高 ΔAF (野兔和家兔 SNP 频率的差异高的 SNP) 的 SNP 并不是在基因组上随机分布的, 而是主要富集在保守非编码区域, UTR 区域, 其次富集在 CDS 区。由此可以看出调控位点的改变可能在家兔的驯化过程中起重要的作用 (Carneiro et al., 2014)。

当前在驯化的研究方面, 除了瑞典的 leif Andersson 团队以外, 另一个不得不提的对该领域的研究做出很大贡献的是荷兰的 Martien A. M. Groenen 研究团队。他们的主要研究领域为猪的驯化, 参与了第一个猪的参考基因组的组装 (Groenen et al., 2012), 发现大量包含非同义变异的基因都和嗅觉相关, 并且是在哺乳动物中高速进化的基因。系统发育树的分析揭示出欧洲猪与亚洲猪之间的分化程度高于家猪与野猪的分化程度。并且探测了分化早期受选择的基因。混群的分析则显示巴克夏猪, 大白等欧洲家猪品种有大量中国家猪的血统。同年发表了利用“区域纯和”(ROH) 研究猪的群体历史以及全基因组的重组的分布。发现了 ROH 的平均尺寸的分布以及数量的分布与群体历史之间的关系。并且巧妙的利用个体 ROH 尺寸和 ROH 数量以及核苷酸多样性完成了类似于 PCA 的功能, 将个体进行分类, 成功的将个体按照群体进行分类。还发现 ROH 的分布与重组率, GC 含量以及核苷酸多样性负相关。解释了 ROH 的形成机制主要受到于群体历史和重组事件的影响 (Bosse et al., 2012)。在发现欧洲家猪中存有大量亚洲家猪的研究基础之上, 2014 年 Martien 研究团体继续对大白猪中进行亚洲猪血统基因渗入的研究。利用亚洲猪与欧洲猪单倍型的差异在全基因组范围按窗口计算基因渗入的程度。发现相对于狗, 猪中存在大量的基因渗入的位点, 并且亚洲猪的单倍型深入之后收到了选择, 但是几乎没有固定, 这可能说明了亚洲猪的单倍型为复杂性状的多因微效的位点, 或者基因渗入之后存在不同方向的选择。渗入单倍型大多包含和肉质量, 发育和生殖相关的基因。他们还在 AHR 基因中识别出了和产仔数相关非同义的亚洲衍生非同义突变。在最大的两个深入片段上, 进一步结合 D 统计量分析发现, 最大的基因渗入片段的渗入也发生在欧洲野猪当中, 而第二大的片段的基因渗入仅发生在长白中。该研究详细阐述了基因渗入如何在不同群体发生。并且提供了一个独特的视角研究家猪育种实践 (Bosse et al., 2014)。

2015 年 Martien 研究团队在国际著名刊物《自然·遗传》杂志发表研究成果, 通过对 103 头来自欧洲的野猪, 欧洲的家猪, 亚洲的野猪, 亚洲的家猪的基因组进行分析, 认为猪的驯化过程和传统认为的驯化模型不一致。传统的驯化模型认为的驯化模型中认为驯化过程存在生殖隔离, 强烈的驯化瓶颈效应。他们认为并不存在这样的瓶颈效应, 并且野猪和家猪之间存在持续的基因交流, 家猪在影响行为和形态的区域中存在强烈的选择信号。并且通过使用 ABC 方法发现家猪中存在和未知野猪群体的基因交流 (Frantz et al., 2015)。

在猪的驯化研究领域, 我国四川农业大学的李明洲和江西农业大学的艾华水等研究团

体也作出了重要贡献。2013 年李明洲研究团体在《自然·遗传》杂志上撰文阐明了藏猪在适应高原环境过程中的遗传改变。发现和供氧, 嗅觉, 能量代谢和药物反应相关的基因受到自然选择的作用 (Li et al., 2013)。2014 年艾华水研究团队同样在《自然·遗传》上撰文阐明了造成中国南北方家猪在适应高低纬度环境差异上的遗传基础。并且发现在 X 染色体上存在一段长达 14 Mb 的低重组区域在南北方家猪中为两种不同的单倍型, 其可能影响南北方家猪在冷热适应性上的差异。有趣的是和高纬度适应性相关的 DNA 片段可能来自一种已经灭绝的野猪 (Ai et al., 2015)。

与猪相类似, 狗也是在驯化领域被广泛而深入研究的驯化动物, 2010 年 Bridgett M. vonHoldt 等基于芯片数据主要利用单倍型和 SNP 等信息推断狗起源于中东的狼, 并且进一步的分析发现不同狗的品种之间在遗传上和表型功能上的差异存在很明显的对应, 但也存在例外 (Vonholdt et al., 2010)。2013 年我国著名科学家张亚平通过对多种中国地方狗品种以及其他多种狗品种和多个灰狼群体进行全基因组测序, 首先对遗传多样性和群体结构进行分析, 随后使用群体模拟软件 $\partial a \partial i$ 分析发现狗与狼大约在 3 万多年前分化。并且狗在驯化过程中与人存在平行选择。2015 张亚平研究团队继续撰文发表狗驯化历史的研究成果, 通过对世界范围内的多个狗品种以及灰狼群体的群基因组重测序分析, 全面展现了狗与狼的遗传多样性以及群体结构的, 在此基础之上利用 PSMC 结合 $\partial a \partial i$ 的分析推测狗在 33000 年前于东亚被驯化而成, 大约在 15000 年前开始先后传入中东, 非洲和欧洲并且传入欧洲的时间大约是 10000 年前, 并且其中的一支又传回了亚洲。

1.4 利用基因组学方法研究物种形成的过程

物种形成是进化过程的一个重要基础。也是理解物种多样性的关键。自然界的物种形成主要有 4 种模型。异域性物种形成 (Allopatric Speciation), 同域性物种形成 (Sympatric Speciation), 边域性物种形成过程 (Peripatric Speciation), 临域性物种形成 (Parapatric Speciation)。而基因组学的研究方法对这个领域的研究的重要性日益显现。一方面其有助于阐述进化过程和基因组分化模式之间的关系, 另一方面其有助于统一生态和非生态原因的物种形成过程。

60 年前认为地理隔离是物种形成的必要条件, 生殖隔离是物种形成的本质。完善了我理解内在和外在生殖隔离的进化和基因组基础。但是其中有一个不可忽视的问题, 就是很长一段时间导致生殖隔离的最初的遗传改变并没有从分化之后的群体之间找到。实际上, 很久之后人们才意识到, 基因组上的不相容性可能远比隔离造成的遗传改变要多。于是很容易想到遗传不相容性对杂交不育的贡献是造成物种形成的原因而非结果。在此基础之上美国印第安纳大学的 Matthew Hahn 利用基因芯片在两种蚊子之间寻找这样的基因差异。结果发现除了三个位点之外, 基因组的其他地方这两种蚊子几乎不存在差异。Matthew 将这三处节点称为物种形成的“基因组岛”(Via and West, 2008)。

“基因组岛”的概念提出之后, 乌普萨拉大学的 Hans Ellegren 研究团队对斑驳姬鹀和花领姬鹀的种化过程进行深入研究, 先后发表了三篇重要的报道。这三篇论文对于种化过程的理解具有重要意义。根据之前基于线粒体 DNA 的研究, 这两种姬鹀分化时间应该在两百万年左右。2012 该研究团队拼接完成了姬鹀的基因组序列, 通过对这两个品种的各 10 只姬鹀

进行全基因组重测序分析发现了将近 50 个“基因组岛”。其分化程度比全基因组背景值高出 50 倍以上。并且这些“基因组岛”非随机的主要分布在着丝粒或端粒区域。并且“基因组岛”呈现出核苷酸多样性降低, 等位基因频率偏移, 连锁不平衡增加以及群体之间共有 SNP 减少等特征, 暗示出这些区域受到选择。随后, 为了进一步分析“基因组岛”的成因, 该研究团队对姬鹀的群体历史进行了推断, 通过使用 ABC 方法对两种姬鹀的 15 种可能的分化模型进行评估, 找出了最有可能的两种分化模型, 结合 PSMC 分析推断其分化时间为 34 万年左右, 大大短于之前基于线粒体 DNA 的 1~2 百万年分化时间的推断。造成这种差异的可能原因是 mtDNA 的溯祖可信度不高。或者线粒体基因分化时间早于物种分化。并且发现在末次盛冰期 (Last Glacial Maximum, 简称 LGM) 之后, 群体之间的基因交流明显增加。在此基础之上, 该研究团体进一步展开研究, 发现连锁选择和重组率的不同是不同姬鹀种群之间的基因组差异的驱动因素。

1.5 鸭基因组序列构建和家鸭起源与驯化的研究

家鸭在我国的养禽业中是仅次于家鸡的第二大驯养群体, 具有丰富的品种资源。我国也是世界上养鸭数量最多、消费量最大的国家, 与人工驯化相关的基因的鉴定和改良将有力推动鸭品种的改良, 进而提高养鸭业经济效益。鸭还是禽流感, 肝炎等多种病毒的天然宿主, 因此对鸭的研究具有很高的学术价值。鸭的基因组序列是由我国科研人员于 2013 年率先组装完成, 并且结合深度的转录组数据分析了鸭的免疫相关的基因, 发现鸭的免疫基因相对于鸡和斑胸草雀发生了种系特异的收缩, 并且在应对禽流感病毒时的免疫机理有了优化 (Huang et al., 2013)。在此基础之上使得我们可以对家鸭的驯化起源从基因组层面展开研究。

野鸭的种类有很多, 大部分都有迁徙的习性, 也有少部分群体不迁徙。许多野鸭都有回归出生地的特性, 这对野生种群的群体结构有重要影响, 可以导致群体隔离, 遗传分化增加。鸭的另一个重要特性是有种间杂交的倾向。其中最为主要的两种野鸭是绿头野鸭和斑嘴野鸭, 有研究通过对其线粒体的分析, 推断两种群是近期分化的, 并且通过实验证明两者可以杂交且后代可育 (Zhuravlev and Kulikova, 2014)。家鸭被认为是起源于绿头野鸭或者绿头野鸭与斑嘴野鸭的杂交后代。这种推测主要是基于其外形, 生活习性等, 其与家鸭交配可育也是重要依据之一。鸭驯化过程的研究也主要是根据一些文字记载。有些研究认为鸭是在至少公元前 500 年的中国被驯化 (Kiple and Ornelas, 2000)。原因可能是被当地的稻谷或收割茬吸引而被驯化。也有分析综合大量文献认为家鸭是在欧洲罗马时期之后被驯化 (Albarella)。

从基因组层面的分析将为家鸭的驯化起源提供更多的证据。对于揭示水禽的驯化动力以及驯化过程中的遗传选择效应有十分重要的意义。这对动物优良品种选育具有指导意义。另外, 由于不同种群的基因组具有一定的差异, 因此仅仅利用单一的基因组参考序列无法完全展现不同种群之间的基因组变异。随着基因组组装技术的普及, 很多物种的研究都会结合近缘物种的基因组信息, 用以揭示更加丰富的生物学信息。最典型的例子是灵长类动物的研究, 人类, 黑猩猩, 矮黑猩猩, 大猩猩, 红猩猩, 长臂猿, 猕猴等灵长类动物的基因组均已得到, 很多生物学的特性是在这些基因组的比较当中被发现。比如 Frank 等人通过对这些基因组的分析揭示出两个灵长类特异的 *KZNF* 基因在进化过程中抑制两个反转座子基因家族, 并且这两个反转座子基因家族通过变异逃逸出该基因对其的抑制 (Jacobs et al., 2014)。如此往复使

得他们均加速进化。Adam 等人通过构建异源四倍体非洲爪蛙的基因组和其近缘二倍体非洲爪蛙比较, 刻画了异源四倍体的起源 (Session et al., 2016)。近年来发展起来的泛基因组学的研究中通过构建多个亚种的基因组进行比较分析都取得了很好的成果。因此, 我们除了进行了重测序的分析, 进一步构建了两个野鸭的基因组序列。这些工作不仅在本研究中的分析取得了一些初步的成果, 弥补了重测序研究在结构变异以及重复序列等分析方面的不足。对于以后的深入分析, 解决和发现更多生物学问题也是十分必要的。

第二章 实验材料及分析方法

2.1 实验仪器设备

Nanodrop 分光光度计: Thermo Fisher;
PCR 仪: 北京东盛;
电泳仪 (DYY-III2): 北京六一仪器厂;
超纯水仪: Millipore;
漩涡振荡器: 海门其林贝尔仪器制造公司;
匀浆仪: Thermo Fisher;
微波炉: 格兰仕;
天平: Sartorius;
凝胶成像系统: 美国 Bio-Rad 公司;
超净工作台: 北京昌平长城空气净化公司;
微量加样器: 德国 Eppendorf 公司;
低温离心机: 德国 Eppendorf 公司;
自动灭菌锅: 日本 SANYO 公司;
超低温冰箱: Model 925, 美国 Thermo 公司;
恒温培养箱: DNP-9082 型, 上海精宏实验设备有限公司;
电热恒温水浴锅: 北京长风仪器仪表厂;
制冰机: Model D101, 日本 SANYO 公司;
CO₂ 细胞培养箱: 美国 Thermo 公司;
恒流泵: 美国 Millipore 公司;
通风橱: 德高实验室设备制造有限公司;
生物操作安全柜: 美国 Thermo 公司;
细胞培养皿: 美国 Corning 公司;

2.2 实验试剂与溶液配制

琼脂糖 (Agarose) 购自赛百盛生物技术的发展中心; Tris-base、EDTA、DMSO 购自美国 Sigma 公司; DNA Marker、dNTP、Easy Taq 酶购自宝生物工程 (大连) 有限公司; 质粒提取试剂盒、胶回收试剂盒购自北京康为世纪生物科技有限公司; Endo-free 去内毒素质粒中提试剂盒购自 Omega 公司; T4 连接酶、各种内切酶及 Q5 高保真聚合酶购自 NEB 公司; 双报告基因检测试剂盒购自 Promega 公司; Lipofectamine 3000 转染试剂、Opti-MEM 培养基购自 Life Technologies 公司; DMEM 培养基、DPBS、0.25% 胰蛋白酶、胎牛血清购自 Gibco 公司; 其他常规化学试剂均由中国农业大学物资供应科提供; 引物均在上海生工生物工程公司合成。

2.2.1 常用缓冲液

1 mol/L Tris-HCl: 称取 121.14 g Tris-base, 加 800 mL 去离子水溶解, 利用 HCl 调 pH 值至 8.0, 定容至 1000 mL, 高温高压灭菌。灭菌条件为 120°C, 1.034×10^5 Pa, 20 min (下同)。

50×TAE 缓冲液: 称取 Tris-base 242 g, 量取冰乙酸 57.1 mL, 并添加 0.5 mol/L EDTA (pH=8.0) 100 mL, 去离子水定容至 1000 mL。

5×TBE 缓冲液: 称取 Tris-base 54 g, 硼酸 27.5 g, 并添加 0.5 mol/L EDTA (pH=8.0) 20 mL, 去离子水定容至 1000 mL。

10×TE 缓冲液: 量取 100 mL 的 1 mol/L Tris-HCl 和 20 mL 的 0.5 mol/L EDTA (pH=8.0), 加入 800 mL 去离子水, 均匀混合后定容到 1000 mL, 高温高压灭菌。

PBS溶液: 按PBS粉末说明书进行配制, 2 L装PBS粉末溶于2 L去离子水中。配制完成后检测pH值 (pH=7.2~7.4), 高压灭菌, 4°C待用或-20°C保存。

2.2.2 质粒提取相关试剂

LB 液体培养基: 称取胰蛋白胨 10 g, 酵母粉 5 g, NaCl 10 g, 共同溶于 800 mL 水中, 定容至 1000 mL, 高温高压灭菌。

LB 半固体培养基: 在 LB 液体培养基中, 添加琼脂粉 18 g, 而后定容至 1000 mL, 湿热灭菌后取出轻轻摇晃, 待温度冷却至 56°C 左右时加入氨苄青霉素或卡那霉素 (100 µg/mL), 倒板, 4°C 保存。

2.2.3 细胞培养试剂

DMEM高糖培养基: 一袋DMEM高糖培养基干粉加3.7 g NaHCO_3 用去离子水溶解, 定容至1000 mL后分装, -20°C冻存。使用前37°C水浴助融, 调pH值至7.2后, 用0.22 µm滤膜过滤除菌, 4°C保存。

0.25%胰酶消化液: 用PBS将0.25 g胰蛋白酶和0.04 g EDTA溶解, 定容为100 mL后, 4°C过夜。次日用0.22 µm滤膜过滤除菌, -20°C保存。

全培养基: 180 mL DMEM 高糖培养基 (过滤后) 加入 20 mL FBS, 4°C 保存待用。

G418: 用 PBS 配制成 100 mg/mL 的浓缩液, 0.22 µm 滤膜过滤灭菌, 分装后 4°C 保存。

PBS 溶液: 同上。

2.3 用于基因组组装的样品提取与建库测序

用于组装绿头野鸭, 斑嘴野鸭基因组的 DNA 样品采集自浙江奉化野鸭厂的两只成年母鸭的血样, 其中绿头鸭 1.5 岁, 斑嘴鸭 5 岁。按照我的建库要求, 所需的样品 DNA 量至少需要是 500 µg-1 mg。按如下盐析法流程从血液中提取 DNA:

1. 首先处理血液样品。

a) 将新鲜血液或解冻血液上下颠倒混匀后, 取 2 mL 无血凝块血液到标记样品名称的 15 mL 离心管中。

b) 向装有样品的 15 mL 离心管内加入 8 mL 红细胞裂解液, 将血液样品与红细胞

裂解液震荡混匀。

- c) 设置离心机转速为 4700 rpm 离心时间为 10 min, 将装有样品与红细胞裂解液的 15mL 离心管置于离心机内, 并启动离心机。
 - d) 待离心完成后, 小心取出离心管, 将离心管内液体倒入废液缸, 视沉淀情况重复 1-2 次直至看不到明显红色。
2. 裂解血样。
- a) 向含有样品的 15 mL 离心管内加入 20 uL 蛋白酶 K (50 mg/mL), 再加入 200 uL 的 SDS (20%)。
 - b) 将含有样品的 15 mL 离心管用食指与拇指捏住离心管的上下两端, 管盖在食指端, 上下震荡混匀 20 次。
 - c) 含有样品的 15 mL 离心管置于浮漂上, 再次上下颠倒混匀 10 次, 放入预先开启的 56℃ 的水浴锅中。使用计时器计时, 处理 45 min。期间每隔 5 min 连带浮漂将含有样品的 15 mL 离心管上下颠倒混匀 10 次。
3. 抽提步骤。
- a) 取出保存于 4℃ 冰箱的抽提液置于通风橱, 在通风橱内混匀。
 - b) 在通风橱内按顺序每次打开一支含有样品的 15 mL 离心管, 向其中加入 1.5 mL 抽提液, 并立即盖好管盖, 待全部样品完成后, 用食指与拇指捏住离心管的上下两端, 管盖在食指端, 缓慢上下颠倒混匀 10 min。
 - c) 将含有样品及抽提液的 15 mL 离心管置于离心机中, 设置离心转速为 4700 rpm, 离心时间为 10 min, 并启动离心机。
 - d) 离心结束后, 将含有样品的 15 mL 离心管按顺序放置于离心管架上, 置于通风橱内。在通风橱内, 观察含有样品的 15 mL 离心管内液面分层情况, 从其中缓慢吸取上层液体约 3.2 mL, 将液体转移排放至标记好样品名称的新的 15mL 离心管中。将用过的含有酚/氯仿/异戊醇抽提液的 15 mL 离心管盖好后丢弃。
 - e) 再次将抽提液混匀后, 吸取 3.2 mL 酚/氯仿/异戊醇抽提液加入到含有样品的 15mL 离心管中, 并立即盖好管盖。待全部样品完成后, 用食指与拇指捏住离心管的上下两端, 管盖在食指端, 缓慢上下颠倒混匀 10 min。
 - f) 将含有样品的 15 mL 离心管置于离心机中, 设置离心转速为 4700 rpm, 离心时间为 10 min, 并启动离心机。
 - g) 离心结束后, 将含有样品的 15 mL 离心管按顺序放置于离心管架上, 置于通风橱内。在通风处内, 按顺序每次打开一支含有样品的离心管以及一支新的做好样品名称标记的 15 mL 离心管。
 - h) 观察含有样品的 15 mL 离心管内液面分层情况, 从其中缓慢吸取上层液体约 3 mL, 将液体转移至新的做好样品名称标记的 15 mL 离心管中, 置于离心管架上。将用过的含有酚/氯仿/异戊醇抽提液的 15 mL 离心管盖好后丢弃。
 - i) 待全部收集管完成操作后, 将含有样品的 15 mL 离心管连同离心管架一起置于实验台操作区内。
4. 沉淀和洗涤。

- a) 取出保存于-20℃冰箱内异丙醇置于实验台操作区内。
 - b) 在实验台操作区内,按顺序每次打开一支含有样品的 15 mL 管,向其中加入 3 mL 的-20℃预冷的异丙醇,缓慢上下颠倒混匀 10min。
 - c) 观察到明显的 DNA 沉淀后,如果得到的 DNA 聚成一团,直接用装好吸头的移液器挑到做好样品名称标记的 1.5 mL 含有 750 μ L 的 70%的乙醇的离心管中,如果沉淀不絮聚成团则 4℃条件下将含有样品的 15mL 离心管放置于离心机内,设置离心转速为 4700 rpm,离心时间为 10 min 后,开启离心机。
 - d) 离心结束后,每次取出一支取出样品管,可观察到离心管底部沉淀,缓慢将管内液体倒入废液缸内,并在吸水纸上吸干管口残留液体,加入 750 μ L 70%乙醇洗涤并用移液器将沉淀转移到做好样品名称标记的新的灭菌 1.5 mL 离心管中。
 - e) 待全部完成操作后,将含有样品的 1.5mL 离心管置于离心机中,设置离心转速为 12000 rpm,离心时间为 5 min,并启动离心机。
 - f) 离心结束后,每次取出一支样品管,缓慢将管内液体倒入废液缸内,并在吸水纸上吸干管口残留液体。
 - g) 向收集管中加入 500 μ L -20℃预冷的 70%乙醇,盖好管盖,上下颠倒混匀 10 次,待全部收集管完成操作后,将含有样品的 1.5 mL 离心管置于离心机中,设置离心转速为 12000 rpm,离心时间为 5 min,并启动离心机。
 - h) 离心结束后,每次取出一支取出含有样品的 1.5 mL 离心管,缓慢将管内液体倒入废液缸内,并在吸水纸上吸干管口残留液体,盖好管盖。待全部完成操作后,将含有样品的 1.5 mL 离心管置于台式迷你离心机内,离心 20 sec。打开管盖,用最大量程为 10 μ L 的移液器吸取管内残留液体并排至废液缸内。
 - i) 待全部完成操作后,将含有样品的 1.5 mL 离心管敞口置于 Thermomixer 内,设置温度为 37℃,盖好 Thermomixer 盖子,烘干 10 min。
5. 向其中加入 2 μ L RNase A (10mg/mL)。盖好管盖,轻轻上下颠倒混匀。将含有样品的 1.5 mL 离心管置于 Thermomixer 内,设置温度为 37℃,盖好 Thermomixer 盖子,酶解作用 15 min。
6. Nanodrop8000 检测 DNA 样品,将上样孔用 Milli-Q 水清洗,用 TE 缓冲液设置空白对照后,上样,读取提取得到的 DNA 纯度与浓度数据。Qubit 检测 DNA 样品,按照 Qubit 及相应的试剂盒的使用说明,将样品 DNA 根据 Nanodrop 检测浓度结果稀释到 Qubit 试剂盒可测范围内,并检测提取得到的样品浓度。
7. 琼脂糖凝胶电泳检测 DNA 样品,步骤如下。
- a) 按照琼脂糖凝胶电泳操作程序,配置 0.6%的琼脂糖凝胶,并按照琼脂糖凝胶体积:EB 体积为 100:1 加入 EB (10 mg/mL)
 - b) 将样品、6 $\times$ loading buffer 按比例混匀,按照规定的顺序上样,最后点上 2 μ L λ -Hind III Marker 及 6 μ L DL2000 Marker 到相应的胶孔内。
 - c) 上样之后,将电泳电压设置为 120V,电泳电流设置为 400mA,进行 40 min 的电泳,并启动电泳仪。

d) 电泳完成之后将胶块放入电子成像系统中成像。

我采取了不同插入片段长度的建库策略进行全基因组测序。构建了 8 种插入片段长短不同的文库。对于短片段文库, 用 5 μ g 的 DNA 随机打断成 250-800 bp, 末端修复之后加上 Illumina 双端接头。在琼脂胶电泳中选出 250, 350 和 800 bp 的片段并通过桥式 PCR 扩增产生相应长度的短片段文库。用 20-40 μ g DNA 来构建 2 kb, 5 kb, 10 kb 和 20 kb 的文库。对其进行环化处理之后的片段剪切进去测序阶段。

2.4 用于重测序分析的样品的选取与基因组提取

我从浙江奉化和浙江杭州的野鸭厂还收集了 16 个野鸭群体 35 个个体的血样, 连同 114 只家鸭, 一共对 149 个个体的血样进行分个体或混池重测序, 如图 2-2, 2-3 所示。群体重测序, 单个个体所需要的样本 DNA 量至少 3 μ g。本研究提取基因组的工作由荣恩光协助完成。

我采用酚仿法提取 DNA。盐析法 DNA 提取需经过初始样品的样品处理、核裂解液裂解、酚/氯仿/异戊醇的抽提、氯仿/异戊醇的抽提、异丙醇的沉淀、70%乙醇的洗涤, DNA 的溶解以及 DNA 样品的检测等步骤。提取得到的 DNA 需要经过 Qubit 和琼脂糖凝胶电泳检测提取到的 DNA 质量。提取的 DNA 经过琼脂糖凝胶电泳检测需要达到 23kbp 大小, 且没有降解和蛋白质及 RNA 污染。提取步骤如下:

1. 用如下体系配置裂解液: 尿素 120.2 g, Tris 12.11 g, EDTA 37.2 g, SDS 10 g (最后加)。用 600 ml 水溶液定容到 1000 ml。
2. 高压灭菌之后用如下体系进行消化处理: 400 μ l 裂解液, 2 μ l RNAase (200 μ g/ μ l), 6~8 μ l pk (20 μ g/ μ l), 300 μ l TE。55 $^{\circ}$ C 消化过夜之后按照如下步骤进行酚仿抽提 DNA。
3. 在超净台上进行酚仿抽提 DNA。
 - a) 加 500 μ l 酚, 颠倒 10 min。
 - b) 12000 rpm 离心十分钟吸水相到事先加过 100 μ l 水的 P 管。
 - c) 加 400 μ l 以 1:1 比例配的酚和仿, 摇十分钟之后再 13000 rpm 的离心机中离心, 吸上层水相加入新管。
 - d) 用无水乙醇加到两倍体积。
 - e) 挑沉淀至新管, 8000 rpm 离心 10 min。弃上清。
 - f) 加 1 ml 70%乙醇 (-20 $^{\circ}$ C 预冷) 8000 rpm 离心 5 分钟。
 - g) 弃上清之后重复 f。
 - h) 倒置在滤纸之上 10 min, 在超净台下吹干。
4. 测定样品的 OD260 和 OD280

测序之后的到的原始数据经过包括去除接头, 质量值过低的 reads 等一系列处理之后得到 clean data 的 fastq 格式文件用于后续的数据分析。



图 2-2 本研究所收集家鸭品种的地理分布及该品种典型外形照片
图片下方标注为采集的样本量，成年公/母鸭体重和年均产蛋量。



图 2-3 本研究所使用野鸭品种和外群的外形照片

每个野鸭品种分别给出了中文名，英文名和学名。

2.5 基因组组装与功能注释的方法

我与BGI的合作者使用 SOAPdenovo 软件进行基因组组装，其进行基因组构建的主要步骤如下：1) 用短片段文库构建 de Bruijn 图, K 的大小设为 29。2) 通过移除 tips, merging bubbles, 低覆盖的连接并且解决小的重复来简化 de Bruijn 图, 进行 contigs 构建。3) 利用短




图 2-4 SOAPdenovo 组装流程示意图 (Li et al., 2010)

a) 基因组 DNA 被随机打断并且从两端进行测序。短片段克隆长度一般为 150 bp 到 500 bp，长片段克隆长度一般为 2-10 kb 甚至更长。b) 以 de Bruijn 图的数据结构存储所有 reads 到计算机内存。c) 对图结构进行简化处理。d) 简化后的图仍然会有很多分叉位点无法确定真正的连接关系，因此在每个分叉位点将序列截断得到最初的 contigs。e) 通过双端 reads 信息将 contig 连接成 scaffold。f) 通过一端比对在 contig 上，另一端没有比对上的 reads 进行补洞。

插入片段 pair-end 和大片段 pair-end 文库构建 scaffolds。4) 填补 scaffold 之内的 gaps。(如图 2-4) 5) 最后，我通过 SSPACE 延伸 scaffolds。

我们使用如下流程注释重复序列 (TE) 元件：

- 1) 我们首先用 RepeatScout 和 LTR_FINDER 软件的默认参数注释重复元件。将注释所得的两个野鸭的 TE 序列当做各自的 de novo TE 数据库。
- 2) 接着我们用 RepeatMasker 软件和其重复元件库 Repbase 数据库鉴定重复元件。
- 3) 用 RepeatMasker 软件及其 RepeatProteinMask 库，对组装的序列进一步在蛋白重复数据库中搜索。
- 4) 使用 Tandem repeat finder 软件的默认参数“Match=2, Mismatch=7, Delta=7, PM=80, PI=10, Minscore=50 和 MaxPeriod=12”鉴定串联重复序列。

2.6 遗传变异的鉴定方法

本研究使用 bowtie 默认参数将 fastq 格式 pair-end reads 比对到 Ensembl 1.0 版本的北京鸭的基因组。使用 GATK 的标准流程,对生成的比对 bam 文件进行排序,去 PCR 重复,realignment。通过 bam 的比对记录中是否存在 "XS:i" 得到唯一比对的记录。最后用 GATK 的 UnifiedGenotyper 功能对唯一比对的结果进行 SNP 以及 indel 的鉴定。我分群体各自进行 SNP 鉴定,当需要对两个或两个以上的群体联合进行分析时,对每个位点采用类似于 sql 外连接的方式进行 SNP 记录的合并,对于在某个群体中没有 SNP 记录,但是在其他群体中存在的记录,我通过 bam 文件查到这个群体的覆盖度,如果其覆盖度达到我设定的阈值,则认为该群体固定 ref 类型的碱基,否则认为该群体在该位点没有覆盖。多个群体混合使用时,SNP 的频率取各个 SNP 的平均值。

后续的许多分析需要知道 SNP 的祖先状态,比如 d_{ai} 的分析,早期选择的分析。我通过将番鸭和太湖鹅比对到 Ensembl 1.0 版本的北京鸭的基因组来确定 SNP 的祖先状态。即对于某 SNP 位点,当其中一个外群的覆盖度达到 $20\times$ 且固定为某一种碱基类型时,并且两个外群不存在差异固定,则认为该碱基为祖先状态。否则认为无法判断祖先状态。

2.7 群体结构分析方法及原理

本人利用 PoPoolation 软件来计算各个群体的核苷酸多样性 (π) 和群体突变率 (Watterson's estimator Θ)。用 plink 的如下参数计算连锁不平衡: `-ld-window-kb 500 --ld-window 99999 --ld-window-r2 0 --r2`。其输出文件为每个 SNP 与其 500kb 范围内的所有 SNP 的 r^2 的值。我将 500kb 分成 5000 个 bins, 计算每个 bins 的 r^2 的值 (即将物理距离在该 bin 范围内的所有 SNP 之间的 r^2 取平均值) 得到连锁不平衡的衰减。“连锁不平衡” (LD) 这个术语并没有准确揭示他的确切含义, LD 仅仅指的是两个或更多位点的等位基因之间的非随机相关性, 并不要求他们之间是否连锁。LD 的测量也有许多不同的定义, 来刻画非随机相关的不同特性。我使用来衡量连锁不平衡程度。LD 与群体遗传学上的很多因素相关, 所以从一定程度上能够反映群体的很多信息以及历史。比如正选择通常会增加 LD, 而平衡选择则会无限期的保存 LD, 更进一步, 当两个或以上通过这种方式相互作用, 也暗示出这样的单一的一个位点并不是受到选择的恰当单元。这种理论将来可能会重新流行起来随着上位效应证据的增加。遗传漂变也可以增加 LD, 比如小的群体相比于大的群体漂变的概率也更大, 因此其 LD 通常情况也会更高。相比于选择仅仅影响一部分位点的 LD, 群体的历史变化则有更大的影响, 比如群体之间的交流引起基因深入的同时也会增加群体的 LD, 群体大小收缩 (特别的如瓶颈效应) 会增加 LD。

主成分分析 (PCA), 遗传结构分析 (genetic structure) 和 f3-statistics 的分析当中, 我使用稀释后的 SNP。通过 LD 衰减曲线 (图 3-6) 可以看出当 SNP 距离为 100 kb 时, SNP 之间基本没有连锁。于是将 SNP 稀释到每 100 kb 取一个 SNP 以排除连锁造成的干扰。

其中主成分分析我使用 GCTA64 软件包。主成分分析和因子分析相类似但是更直接, 依然属于无监督机器学习的范畴, 其本质是使高维数据降维使之易于观察和理解, 目前至少有 9~10 种 PCA 的解释和推导方法。在群体遗传学当中, PCA 分析可以找到一个方向 (或

多个) 尽可能多的解释样本 (个体或群体) 之间的方差, 从而能将样本区分开来, 区别出样本之间进化历史的差异。

遗传结构分析 (genetic structure) 我使用 ADMIXTURE 软件包。遗传结构分析是指通过基因组上 SNP 的频谱变化, 个体间的 SNP 频谱变化, 推断出不同个体是否来源于同一个共同祖先的方法, 利用基因组不同位置 SNP 的共祖性, 估计个体不同祖源成分的比例。

当对北京鸭, 绍兴鸭, 绿头鸭和斑嘴鸭同时进行 PCA 或 genetic structure 分析时, 我将北京鸭和绍兴鸭各随机抽取 14 只, 以使各个群体的样本数相同, 从而减少群体样本量不等带来的误差。

F3-统计量 (f3-statistics) 用于分析 C 群体是否有由 A, B 群体混合而成的证据。如图 3-8 所示, $F3(C;A,B) = 1/N \sum_{i=1}^N (c'_i - a'_i)(c'_i - b'_i)$, 其中 a' , b' , c' 分别代表 A, B, C 群体的期望频率。可以证明 (Patterson et al., 2012), 仅有当 C 群体的祖源成分同时来自与 A 和 B 时, f3 才有可能小于 0 (如图 2-5 B)。如果 C 不是由 A, B 混合而成, 则 f3 一定大于 0 (如图 2-5 A)。值得注意的是, 即使 C 是有 A, B 混合而成的群体, f3 也不一定总是小于 0。如果 C 群体经历了非常强的遗传漂变, 则 f3 依然有可能大于 0。我将 SNP 稀释到每 100 kb 取一个 SNP。使用 ADMIXTOOLS 软件计算 f3 统计量。为了减少群体结构对于结果的影响。我选取不同的亚群组合进行了多次 f3 统计量的计算 (如表 3-10)。




图 2-5 F3 统计量示意图

A, B 分别代表两个混合起源的 source 群体, C 代表混合起源的 target 群体。

2.8 群体历史推断方法及原理

2.8.1 使用 $\partial a \partial i$ 重构家鸭与野鸭分化的群体历史

$\partial a \partial i$ 是目前群体历史推断当中非常主流的一款软件。它基于一个或多个群体的等位基因频谱, 根据中性进化理论以扩散方程的方法得到期望的 AFS, 与实际的 AFS 比较再调整参数, 反复模拟直到参数收敛。我的主要目的是推测绿头野鸭和斑嘴野鸭, 以及两种野鸭和家鸭之间的分化时间。于是我使用最简单的群体分化模型 (如图 2-6), 分别模拟绿头野鸭和斑嘴野




图 2-6 $\partial a \partial i$ 模拟所使用的 IM 群体分化模型

该模型有 NuA , $Nu1$, $Nu2$, TA , 分化时间 TS , 迁徙率 $m12$, $m21$ 等 7 个参数

鸭的群体分化, 绿头野鸭和家鸭之间的群体分化, 斑嘴野鸭与家鸭之间的群体分化。每种模拟重复 100 次, 统计估计出来的参数的分布。下面是这个模型的 python 代码描述:

```
def split_mig_1_IM(params, ns, pts):
    nuA, nuM, nuP, TA, TS, m12, m21 = params
    xx =  $\partial a \partial i$ .Numerics.default_grid(pts)
    phi =  $\partial a \partial i$ .PhiManip.phi_1D(xx)
    phi =  $\partial a \partial i$ .Integration.one_pop(phi, xx, TA, nu=nuA) # 在 TA 的时间段内祖先群体大小维持 nuA
    phi =  $\partial a \partial i$ .PhiManip.phi_1D_to_2D(xx, phi) # 分化为两个群体
    phi =  $\partial a \partial i$ .Integration.two_pops(phi, xx, TS, nu1=nuM, nu2=nuP, m12=m12, m21=m21) # 在 TS 的
    时间段内分化之后的两群体的有效群体大小分别维持在 nuM 和 nuP, 群体 1 向群体 2 的迁徙率为
    m21, 群体 2 向群体 1 的迁徙率为 m12。
    fs =  $\partial a \partial i$ .Spectrum.from_phi(phi, ns, (xx, xx))
    return fs
```

我使用自己编写的程序生成 $\partial a \partial i$ 的 SNP 信息输入文件, 其中主要的信息是 SNP 的祖先碱基类型, SNP 的两侧的碱基和各个群体的等位基因的抽样个数。我将 8 个家鸭品种量化为一个有 14 个样本的家鸭群体抽样。估计到的参数是一个相对值, 因此需要将其转化为绝对值。其转换公式如下:

有效群体大小: $N_{ref} * nux$ (nux 为估计得到的相对参数)

时间 (代): $N_{ref} * T * 2$

迁徙率: $m/2 * N_{ref}$

N_{ref} 的换算公式为: $\theta / (4 * \mu * L)$ μ 为突变率, L 表示用于计算的 SNP 来自于多长的基因组区域。如果 SNP 有稀释, 则 L 要乘以稀释倍数, 得到稀释后的长度。

2.8.2 使用 psmc 重构家鸭与野鸭的群体历史

PSMC 是一款非常好的用于推断群体大小历史变化的软件, 它是基于马尔科夫链-溯祖模型进行计算的。仅需要一个个体, 就可以根据其基因组上杂合子密度的变化推测出各个基因组片段的最近共祖时间 (TMRCA), 而该个体两个等位基因之间的 TMRCA 的分布又提供了群体大小的历史变化的信息。PSMC 巧妙的利用了其中的关系推测出了群体大小的历史变

化。但是 PSMC 也有其缺陷, 由于重组率的关系, 对于非常近期的群体历史和非常远的群体历史无能为力。对人类这个物种来说, 其有效的推测时间范围大概是 20 Kyr (kilo years ago) 年到 3 Myr (million years ago)。并且需要很高的测序深度以保证 SNP 的检出率以达到饱和的程度为宜。

本研究使用如下方法和参数进行 PSMC 的计算。

```
samtools mpileup -C50 -uf duckref.fa duckindvd.bam|bcftools view -c -|vcfutils.pl
vcf2fq -d 10 -D 100|gzip > duckindvd.fq.gz
对于绍兴鸭, 由于测序深度较低, 于是将-d 参数改为 5 -D 参数改为 80
fq2psmcfa -q20 duckindvd.fq.gz > duckindvd.psmcfa
psmc -N30 -t5 -r5 -p "4+30*2+4+6+10" -o duckindvd.psmc duckindvd.psmcfa
psmc_plot.pl -g 1 -u 9.97e-10 -M duckindvd1,duckindvd2 outfilename duckindvd1.psmc
duckindvd2.psmc
```

其中突变率采用 9.97e-10 (Nadachowska-Brzyska et al., 2015)。

由于我们的样品有测序深度的差异。而不同的测序深度直接影响发现 SNP 的效率, 而 SNP 的密度又直接影响 PSMC 对群体历史的重构, 所以我推测曲线的差异是由于测序深度的差异造成的, 于是我将北京鸭的测序数据稀释到 0.2 倍, 0.3 倍, 0.4 倍, 0.6 倍, 0.7 倍, 0.8 倍, 0.9 倍, 大致相当与 3×, 4.5×, 6×, 9×, 10×, 12×, 13×的测序深度。观察曲线的变化。

稀释的方法为:

```
samtools view -bhs 0.1 duckindvd.bam > duckindvdafterduilt0.1.bam
```

2.9 探测基因组受选择区域的方法

2.9.1 分化早期选择信号的探测方法

我使用一种在人类学研究中探测人与尼安德特人分化早期, 人类中受到选择的方法 (Green et al., 2010)。该方法的基本思想是, 某些遗传变异由于具有了适应性优势, 于是在群体中的频率开始升高。现代人群体中依然存在大量比例在现代人和尼安德特人分化早期就已经存在的变异。然而, 在现代人类祖先当中的基因组中由于受到选择性清除的区域 SNP 会固定, 因此会丢失很多两个群体的共有 SNP。该方法就是利用这些古老 SNP 搜寻分化早期在人类中的选择性清除区域。即就是寻找人类群体当中尼安德特衍生位点显著减少的区域。在给出人类群体中衍生等位基因的频率条件下可以得到尼安德特衍生等位基因的期望数量。该研究作者通过模拟中性进化的序列和正选择的序列阐释了该方法的效力, 并且该方法预测尼安德特衍生等位基因频率的能力受到重组率的影响很小 (如图 2-7 A, B)。在低重组率的区域频谱会向衍生等位基因频谱会向低频段偏移 (图 2-7 C)。这可能是因为在低重组区域与受纯化选择的片段连锁更加紧密。作者首先按照如下标准筛选 SNP 位点: 可以判定祖先基因型的非 CG 位点, 在人类中为双等位基因, 至少有一种等位基因在尼安德特人中被观测到。对于这些位点, 尼安德特等位基因中衍生等位基因的比例是人类衍生等位基因频率的函数 (如图 2-7 D)。

而在受到强烈纯化选择或近期正选择的区域, 其频谱会向低频段移动。在这样的区域现

代人基因树会很浅，并且不太可能有很多分化时期就已经存在的足够古老的与尼安德特人共有的 SNP。




图 2-7 人类衍生等位基因频谱与重组率和尼安德特衍生等位基因比例的关系 (Green et al., 2010)

A), B)显示尼安德特衍生等位基因和文特尔衍生等位基因的比例是局部重组率和人类衍生等位基因频率的函数。C) 显示随着重组率的增加，更多衍生等位基因会在高频段被观测到。图中仅显示了三个衍生等位基因频率的 bins。D) 特定的人类衍生等位基因配置对于尼安德特衍生等位基因的比例有一定的信息。详细解释见 (Green et al., 2010)。

对每个多态位点，根据人类中 SNP 频率计算尼安德特中固定为衍生等位 allele 的期望比例，其与实际尼安德特人中衍生等位基因的比例的差值作为选择性清除的信号。该方法之所以计算人类频率和尼安德特中固定的比例之间的关系，是因为尼安德特样本太少。该方法的发明人在 Martin 主持的猪的进化研究将该思想延伸改进为更适合大规模群体数据 (Groenen et al., 2012)。也即用频率之间的相关性。一般而言，没有受到选择的区域，两个群体将共享数量相当的变异位点，对于分化之后受到选择的区域，会丢失很多这样的共享 SNP。为了确定观测位点最有可能的祖先基因型，研究人员使用了三个外群：Phacoecochorus africanus, Sus verrucosus, Sus celebensis。对于在欧洲群体中衍生等位基因频率大于 0 的位点，这个相关性被用来估算亚洲群体中相同位点的衍生等位基因的频率的期望。探测基因组上衍生等位基因的频率显著低于期望的区域。认为这样的区域是早期受到选择的区域。

结合起来，我使用如下位点探测野鸭当中分化早期受到选择的区域。

- 1) 在家鸭中 DAF 大于 0;
- 2) 在野鸭当中 DAF 大于 0;

- 3) 该位点可以判定祖先等位基因型的状态;
- 4) 排除 CpG 位点;

对于这些位点, 首先计算相关性, 将每个位点所有家鸭群体中的频率取平均值作为该位点家鸭群体当中的频率, 将频率为 0 到 1 划分为 24 个 bins, 对每个 bin 中野鸭当中的所有位点的频率取平均值。得到家鸭与野鸭频率相关性。根据相关性求得野鸭的期望频率。

对于上述位点, 按照 20 kb 的窗口, 每次滑动 10kb 按如下公式计算早期选择信号 S 的值:

$$S = \log_e \left(\sum_s^e f_o / \sum_s^e f_e \right)$$

要求每个窗口至少10个SNP位点。每个SNP的MQ值大于28。该公式可以解释为根据野鸭中的SNP频率计算的家鸭当中SNP的期望频率, 当实际在家鸭当中观测到的SNP频率小于期望时, 即是说受到了早期选择。

解释如下, 当野鸭中早期出现sweep时, 其与家鸭共有的衍生等位SNP频率会增高, 于是期望增高, S值下降, 而野鸭当中近期的sweep, 或纯化选择会消除或使共有衍生等位SNP频率变低, 于是期望下降, S值上升。而家鸭当中早期的sweep会使共有衍生等位SNP频率上升, 于是观测值上升, S值上升, 家鸭近期受到的sweep会使共有衍生等位SNP被清除, 这样也会造成S值下降, 于是我排除家鸭当中受到选择性清除的位点 (SNP被清除的位点, 也即要求家鸭中DAF大于0, 这样家鸭近期受到sweep的区域就被排除了)。

2.9.2 驯化过程中受选择区域的探测方法

我尝试使用之前乌普萨拉大学研究团队提出的两种选择信号探测家鸭在驯化过程中的选择性清除区域— F_{ST} 与 H_p 。根据连锁不平衡程度和 SNP 的密度, 我选取窗口的大小 40 kb 滑窗 20KB 来探测选择信号。其中 F_{ST} 使用如下公式:

$$F = \frac{\sum_{k=1}^K N_k}{\sum_{k=1}^K D_k}$$

其中 N_k 可以用如下的公式估计: $N_k = (a_1/n_1 - a_2/n_2)^2 \cdot h_1/n_1 \cdot h_2/n_2$

D_k 可以用如下公式估计: $D_k = N_k + h_1 + h_2$

$$h_i = \frac{a_i(n_i - a_i)}{(n_i - 1)n_i} \quad (i=1, 2)$$

其中分别为群体 i 的等位基因数和样本数。当 n_1 和 n_2 相等时, 该 F_{ST} 的估计退化为与 Weir 和 Hill (Weir and Hill, 2002) 提出的 F_{ST} 的估计相同。 F_{ST} 用来衡量两个群体的分化程度, 其本质是组间方差与组内方差的比。

我用上述公式计算野鸭和家鸭之间的 F_{ST} 即分别计算绿头野鸭和斑嘴野鸭与 8 个家鸭品种之间的 F_{ST} 对每个窗口取平均值。对于在两个比较群体之间都固定的 SNP 位点, 不进行 F_{ST} 的计算。每个窗口内至少 10 个 SNP 位点。考虑两个比较的种群都固定的位点。

杂合度 (H_p) 的公式如下:

$$H_p=2\sum n_{MAJ} \sum n_{MIN}/(\sum n_{MAJ}+\sum n_{MIN})^2$$

其中， n_{MAJ} 和 n_{MIN} 是频率高的等位基因碱基型的 reads 支持数，和频率低的等位基因碱基型的 reads 支持数。

2.9.2 详细展示受选择区域的情况

为了详细观察受选择区域的情况，我们对受选择区域（及邻近区域）以 5 kb 为窗口大小，每次滑动 5 kb 重新计算选择信号的值。同时计算各群体之间的一致性（Identity Score）。IS-score 的计算方法为对每个 SNP，首先先基三其在该群体中的和 reference allele 一致的碱基型的频率 F_{POP} 。两个群体之间的 $IS=1 - (|F_{POP1}-F_{POP2}|)$ 。对于某个群体中 reads 支持数小于 10 个的位点舍弃。之后将 IS 的转换为不同的颜色。

*以上分析方法在实际的数据分析过程当中需要控制大量的数据，软件，参数和处理流程。本人为此开发了自动化分析系统。本项目的分析广泛的使用本人设计并开发的自动化分析系统。

2.10 验证受选择变异位点活性的方法

2.10.1 验证位点的选取

我使用荧光素酶报告基因的方法，对如下表（表 2-3）所示的 6 个位点进行变异活性的验证。

表 2-3 用于荧光素酶报告基因实验验证变异活性的位点

基 因 symbol	变异位点物理位置	变异位点位 置功能分类	Δ AF	野生群体的 AF	驯化群体的 AF
<i>EFNA5</i>	KB744645.1: 114292,114293,114301	基 因 下 游 10 kb	0.949,0.916,0.740	0.000,0.916, 0.000	0.949,0.000,0.74 1
<i>EFNA5</i>	KB744645.1:58363	基因上游 4 kb	0.809	0.835	0.026
<i>ISL1</i>	KB743873.1	3' 端的侧翼 序列	0.875	0.875	0.000
<i>MRPS2</i> 7	KB742554.1:2151394,215 1434,2151445	3' UTR	0.960,0.419,0.417	0.000,0.419, 0.419	0.960,0.419,0.41 9
<i>GRIK1</i>	KB742951.1:543269	5' UTR	0.730	0.151	0.881
<i>LYST</i>	KB743543.1:403502	5' UTR	0.611	0.685	0.074

变异位点物理位置为：“scaffold 号：物理位置”。ΔAF 为野生群体和驯化群体的 AF 的差值的绝对值。*EFNA5*, *ISL1*, *MRPS27* 在野鸭祖先群体当中受到选择。其中 *EFNA5* 与视网膜神经节导向相关。*ISL1* 结合胰岛素基因增强子的蛋白。*MRPS27* 与线粒体蛋白的合成相关。*GRIK1* 和 *LYST*在驯化过长当中受到选择。*GRIK1* 与神经系统功能相关。*LYST*可能和色素沉着有关。

2.10.2 PCR 扩增

不同 DNA 聚合酶的反应体系和热循环条件根据各自使用说明书而定, 以下是 NEB 公司 Q5 高保真聚合酶的使用方法:

试剂组分	体积
5×Q5 Reaction buffer	10 μ L
dNTP Mixture (2.5 mmol/L each)	4 μ L
上游引物 (10 μ mol/L)	0.8 μ L
下游引物 (10 μ mol/L)	0.8 μ L
模板 DNA	小于 1 μ g
Q5 高保真聚合酶	0.5 μ L
5×Q5 高 GC Buffer (可选)	10 μ L
Total volume	50 μ L

反应条件为: 98℃预变性 30 s; 98℃变性 10 s, 50~72℃退火 20 s, 72℃延伸 (30 s/kb), 25~35 个循环; 72℃终延伸 2 min; 4℃保存。

2.10.3 PCR 扩增产物和酶切片段的回收

使用 EasyPure PCR 纯化盒子 (全式金) 直接纯化:

- (1) 将 50~100 μ L PCR 产物, 加入 5 倍体积的 BB, 混匀后加入离心柱中, 静置 1 min, 10 000 g 室温离心 1 min, 弃去流出液;
- (2) 加入 650 μ L 溶液 WB, 10 000 g 室温离心 1 min, 弃去流出液;
- (3) 10 000 g 室温离心 1~2 min, 去除残留的 WB 溶液;
- (4) 将离心柱置于一个干净的离心管中, 加入 30~50 μ L EB (65℃预热), 室温静置 1 min, 10 000 g 离心 1 min, 洗脱出的 DNA 于-20℃保存。

使用琼脂糖凝胶 DNA 回收试剂盒 (康为世纪) 切胶纯化:

- (1) 将 PCR 产物或酶切产物进行琼脂糖电泳, 待条带明显分开后, 将单一目的 DNA 条带从琼脂糖凝胶中切下, 放入干净的离心管中, 称量计算凝胶重量;
- (2) 向胶块中加入 1 倍体积 Buffer PG (如凝胶重为 100 mg, 其体积可视为 100 μ L), 55℃水浴中, 彻底溶解胶块;
- (3) 柱平衡: 向已装入收集管中的吸附柱 (Spin Columns DM) 中加入 200 μ L Buffer PS, 13 000 rpm 离心 1 min, 弃废液, 将吸附柱重新放回收集管中;
- (4) 将步骤 2 所得溶液加入到吸附柱中, 室温放置 2 min, 13 000 rpm 离心 1 min, 弃废液, 将吸附柱放回收集管中;
- (5) 向吸附柱中加入 450 μ L Buffer PW, 13 000 rpm 离心 1 min, 弃废液, 将吸附柱放回收集管中, 再重复一次;
- (6) 13 000 rpm 离心 1 min, 弃滤液;
- (7) 将吸附柱置于一个干净的离心管中, 加入 30~50 μ L Buffer EB (65℃预热), 室温静置 2 min, 13 000 rpm 离心 1 min, 洗脱出的 DNA 于-20℃保存。

2.10.4 连接反应

pEASY-T1 或 pEASY-Blunting 载体 (全式金) 的连接:

连接体系如下:

试剂组分	体积
pEASY-T1 vector 或 pEASY-Blunting vector	1 μ L
PCR 纯化产物	4 μ L
Total volume	5 μ L

轻轻混合上述反应液, 25℃反应 10~15 min。反应结束后, 将离心管置于冰上。

T4 DNA 连接酶 (NEB) 步骤:

载体或 PCR 产物的酶切, 体系如下:

试剂组分	体积
内切酶 I	2.5 μ L
内切酶 II	2.5 μ L
10×Buffer (两种酶通用)	10 μ L
质粒或 PCR 产物	小于 5 μ g
Total volume	100 μ L

将上述反应液在 37℃反应 3 h (或过夜), 产物胶回收后用于下一步的连接。

目标片段与载体的连接, 连接体系如下:

试剂组分	体积
T4 DNA Ligase	1 μ L
10×T4 DNA Ligase Buffer	2 μ L
DNA 片段	0.076 pmol
Vector	0.025 pmol
Total volume	20 μ L

将上述反应液在 16℃条件下过夜, 产物用于下一步的转化或-20℃保存。

2.10.5 转化

- (1) 从-80℃冰箱中取出感受态细胞 (50 μ L), 冰上融化, 将 5 μ L 连接产物加入其中, 冰浴 30 min;
- (2) 42℃水浴热激 30s, 立即置入冰上 1~2 min, 加入 700 μ L LB 液体培养基, 37℃振荡复苏 60 min;
- (3) 4 000 rpm 离心 5 min, 弃去 650 μ L 上清, 吹匀后铺于 LB 平板上, 平板含 0.1% (V/V) 的氨苄青霉素或卡那霉素, 37℃恒温培养 10~15 h。

2.10.6 菌落 PCR 鉴定

- (1) 用灭菌的白枪头挑取转化后的单克隆菌落在新鲜的含抗生素平板上划线后, 将白枪头在配好的 PCR 反应液中涮洗后拿出;
- (2) PCR 反应液置于 PCR 仪上进行 PCR 反应扩增;
- (3) 产物用 1~2% 琼脂糖进行电泳检测, 鉴定出阳性单克隆菌落, 扩大培养后进行测序鉴定, 测序无误的菌液用于下一步的质粒提取。

2.10.7 去内毒素质粒 DNA 提取

- (1) 取 30~50 mL 过夜培养的菌液加入离心管中, 3 500~5 000 g 离心 10 min 收集菌体沉淀;
 - (2) 倒弃培养基, 加入 2.5 mL Solution I/RNase A 混合液, 涡旋振荡使细胞完全悬浮;
 - (3) 加入 2.5 mL Solution II, 轻轻地颠倒混匀 10~15 次, 室温静置 5 min;
 - (4) 加入 1.25 mL Solution N3, 温和地颠倒数次至形成白色絮状沉淀;
 - (5) 将步骤 4 液体全部加入到已放入收集管的 Lysate Clearance Filter 过滤器中, 加压至液体全部流出;
 - (6) 向滤出液中加入 0.1 体积的 ETR 溶液, 上下颠倒混匀, 冰浴 15 min;
 - (7) 冰浴结束后, 42℃ 水浴 5 min, 3 500~5 000 g 离心 10 min;
 - (8) 小心的吸取步骤 7 上清液, 加入到一个新的离心管中, 同时加入 0.5 体积的无水乙醇, 上下颠倒混匀;
 - (9) 向 HiBind® DNA Midi 柱中加入 3 mL GPS Buffer, 静止 5 min, 3 500~5 000 g 离心 10 min, 弃滤液;
 - (10) 将步骤 8 混合液加入到经步骤 9 预处理的 HiBind® DNA Midi 柱中, 3 500~5 000 g 离心 10 min, 弃滤液;
 - (11) 向 HiBind® DNA Midi 柱中加入 3 mL Buffer HB, 3 500~5 000 g 离心 10 min, 弃滤液;
 - (12) 向 HiBind® DNA Midi 柱中加入 3.5 mL DNA Wash Buffer, 3 500~5 000 g 离心 10 min, 弃滤液, 再重复一次;
 - (13) 3 500~5 000 g 离心 10 min, 弃滤液, 将 HiBind® DNA Midi 柱置于新的离心管中, 65℃ 烘箱中静置 10 min;
- 向 HiBind® DNA Midi 柱中加入 0.5~1.0 mL 去内毒素的 Elution Buffer (65℃ 预热), 3 500~5 000 g 离心 10 min, 弃滤液, 洗脱出的质粒于 -20℃ 保存。

2.10.8 细胞复苏、传代培养及冻存

- (1) 细胞复苏: 从液氮罐中取出细胞, 在 37℃ 的水浴锅中迅速融化; 将冻存管中的细胞加入到装有 5 mL 完全培养液的离心管中, 轻轻吹打混匀, 1 000 rpm 离心 5 min, 得到细胞沉淀; 弃去上清液, 加入 1 mL 细胞培养液重悬细胞; 将细胞加入装有培养基的培养皿中, 37℃, 5% CO₂ 条件下培养;
- (2) 传代培养: 将长成层的原代培养细胞从二氧化碳培养箱中取出, 在超净工作台中倒

掉瓶内的培养液,加入少量消化液。静置 5~10 分钟。在倒置镜下观察被消化的细胞,如果细胞变圆,互相之间不在连接成片,这时应立即在超净台中将消化液倒掉,加入 3~5 mL 新鲜培养液,吹打,制成细胞悬液。将细胞悬液吸出 2 mL 左右,加到另一个培养瓶中并向每个瓶中分别加 3mL 左右培养液,盖好瓶塞,送回 37℃, 5% CO₂ 条件下继续培养。

- (3) 细胞冻存:待细胞长至 60%~70%汇合时进行冻存,按照细胞传代步骤进行消化、离心、收集细胞后,加入相应体积的冻存液(每 1 mL 冻存液中 DMEM、胎牛血清好 DMSO 比例为 6:3:1)重悬,分装到冻存管中,4℃ 20 min, -20℃ 2 h, -80℃ 过夜后转移到液氮罐中。

2.10.9 细胞转染

各转染试剂转染方法严格按照说明书进行,以下为利用 Lipofectamine 3000 (Life Technologies) 转染 12 孔板的转染方法:

- (1) 细胞铺板:以 $1\sim4\times10^5$ 个/mL 的密度对细胞进行传代铺板,37℃, 5% CO₂ 培养 12 h;
- (2) 转染时细胞密度为 70~90%,转染前 2 h 换液,将 Lipofectamine 3000、重组质粒和 Opti-MEM 培养基调整到 15~25℃;
- (3) 用 75 μ L 无血清无双抗的 Opti-MEM 培养基稀释 1.2 μ g 质粒和 2.4 μ L P3000,轻轻混匀;
- (4) 再用 75 μ L 无血清无双抗的 Opti-MEM 培养基稀释 2.8 μ L Lipofectamine 3000 转染试剂,轻轻混匀;
- (5) 将步骤 3 和步骤 4 混到一起,轻轻混匀,即为转染复合物,室温孵育 15 min;

从培养箱中取出细胞,将转染复合物直接加到培养基液面下,摇晃培养板混匀(转染后也不用换液),继续培养细胞,转染后 18~72 h 观察结果。

2.10.10 荧光素酶活性检测

参照 Dual-Luciferase Reporter Assay System (Promega) 说明书操作:

- (1) 测定前将 Dual-Glo® Luciferase Buffer 和 Dual-Glo® Stop & Glo® Buffer 平衡至室温,配制 Dual-Glo® Luciferase Reagent 和 Dual-Glo® Stop & Glo® Reagent;
- (2) 常规操作消化细胞,向 96 孔白板每孔中加入 75 μ L 细胞悬液,同时加入 75 μ L Dual-Glo® Luciferase Reagent,轻轻混匀,室温避光孵育 30 min,酶联免疫监测仪上进行萤火虫荧光素酶活性测定;
- (3) 向每孔中加入 75 μ L Dual-Glo® Stop & Glo® Reagent,轻轻混匀,室温避光孵育 30 min,酶联免疫监测仪上进行海肾荧光素酶活性测定;
- (4) 相对报告基因活性结果计算,以 Fluc/Rluc 值表示。

第三章 分析结果

3.1 绿头野鸭和斑嘴野鸭基因组测序、组装与注释

3.1.1 数据过滤和基因组大小估计

为了减少测序错误提高组装质量, 我采取了如下的一系列标准对测序读段进行过滤: 1) 移除‘N’的长度超过读段长度的 10% 的读段; 2) 移除超过 40 bp 低质量碱基 (质量数小于 7) 的 reads。3) 读段包含超过 10 bp 的接头序列 (允许 3 个以内的错配); 4) 小片段文库的读段之间有 overlapped (超过 10bp); 5) 移除 PCR 造成的重复序列, 即两个完全相同的 reads。经过上述标准过滤之后, 得到 275 Gb 序列用于斑嘴鸭基因组组装, 262 Gb 数据用于绿头鸭基因组组装。通过 2.3 节所述的步骤得到基因组之后进行建库测序。测序结果如表 3-1, 3-2。其中, 物理覆盖度包含文库片段被测两端片段中间所夹的一段未被测序的序列, 而测序覆盖度仅指的是测序的碱基数。

表 3-1 绿头鸭基因组组装的测序读段统计

Pair-end 文库	插入长度	文库数量	Reads 长度 (bp)	总数据量 (Gb)	测序深度 (X)	物理深度 (X)
Solexa Reads	250bp	3	150_150	89.76	70.81	59.01
	500bp	2	100_100	46.18	36.94	92.35
	800bp	2	100_100	57.40	45.92	183.68
	2K	3	49_49	27.37	21.90	446.94
	5K	2	49_49	16.32	13.06	666.33
	10K	3	49_49	11.67	9.34	953.06
	20K	2	49_49	13.75	11.00	2,244.90
Total	----	17	----	262.45	208.97	4,646.27

*计算测序深度时假设基因组大小为 1.25Gb.

表 3-2 斑嘴鸭基因组组装的测序读段统计

Pair-end 文库	插入长度	文库数量	Reads 长度 (bp)	数据总量 (Gb)	测序深度 (X)	物理深度 (X)
Solexa Reads	250bp	3	150_150	95.64	76.51	63.76
	500bp	2	100_100	63.39	50.71	126.78
	800bp	2	100_100	45.31	36.25	145.00
	2K	3	49_49	26.20	20.96	427.76
	5K	2	49_49	17.11	13.69	698.47
	10K	3	49_49	15.37	12.30	1,255.10
	20K	2	49_49	12.17	9.74	1,987.76
Total	----	17	----	275.19	220.16	4,704.63

*计算测序深度时假设基因组大小为 1.25Gb.

组装之前我首先通过 K-mer 估计基因组大小。一个长度为 L bp 的读段包含 (L-K+1)个

K-mer。于是可以计算全基因组的读段的 K-mer。除去由于测序错误造成的高比例的低频率段，K-mer 频率随着序列覆盖度梯度呈现泊松分布。基因组的大小 G 则可以估计为 $G=K_num/K_depth$, K_num 是 K-mer 的总数, K_depth 是 K-mer 的期望深度, 也就是泊松分布的峰值。如图 3-1 所示, 17-mer 分析显示绿头鸭和斑嘴鸭的基因组大小分别是 1.15 Gb 和 1.14 Gb。




图 3-1 绿头野鸭 (D2L) 和斑嘴野鸭 (D2B) 短片段插入文库的 17-mer 分布

在绿头和斑嘴野鸭中一共分别鉴定出 22,312,838,068 个 K-mer 和 28,137,616,208 个 K-mer。

3.1.2 绿头野鸭和斑嘴野鸭基因组的组装及 supperscaffold 构建

经过严格的质量控制，我们使用 SOAPdenovo 软件对两个野鸭的基因组构建 contigs 和 scaffolds 并且用 SSPACE 软件构建 supperscaffold。组装结果如表 3-3, 3-4 所示。看以看出两只野鸭的 scaffold N50 分别达到了 2 Mb 以上。

表 3-3 绿头野鸭组装结果统计

	Scaffold		Contig	
	Size (bp)	Number	Size (bp)	Number
N90	145,390	870	5,381	38,114
N80	572,414	447	12,265	24,024
N70	1,056,811	284	19,655	16,471
N60	1,638,385	189	28,193	11,463
N50	2,489,142	125	38,271	7,876
Longest	17,658,973	-----	484,574	-----

	Scaffold		Contig	
	Size (bp)	Number	Size (bp)	Number
Total Size	1,270,808,751	-----	1,176,969,925	-----
Total	-----	61,591	-----	172,189
Number(>=100bp)	-----		-----	
Total Number(>=2kb)	-----	7,076	-----	56,501

N50：对于一个序列集合，将所有序列按长度从长到短排列并依次相加，当相加长度超过总长度的一半时，该序列的长度就是 N50。类似的当相加长度超过总长度的 90%时的序列的长度为 N90。类似的可以定义 N60，N70，N80 等。

表 3-4 斑嘴野鸭组装结果统计

	Scaffold		Contig	
	Size (bp)	Number	Size (bp)	Number
N90	102,224	1,035	4,386	45,269
N80	530,335	525	10,422	28,261
N70	966,486	342	16,811	19,292
N60	1,443,141	230	24,130	13,407
N50	2,054,876	154	33,061	9,194
Longest	25,320,044	-----	673,122	-----
Total Size	1,317,385,384	-----	1,187,333,591	-----
Total	-----	67,685	-----	194,934
Number(>=10bp)	-----		-----	
Total Number(>=2kb)	-----	8,133	-----	62,605

3.1.3 利用 EST 和 BAC 对基因组组装进行评估

我们评估基因组组装的准确性主要有两步：

- 1) 用 BLAT 以默认参数将组装的基因组与北京鸭基因组序列，北京鸭的七个 BAC, 240 个微卫星标记和 319,996 个 EST 相比较。结果显示两个野鸭比对到北京鸭基因组的覆盖度均为 92%左右。7 个 BAC 中 92%的长度比对到 1, 3 和 4 号染色体共覆盖 640 Kb。如图 3-2, 3-3。EST 序列也显示出基因组被很好的覆盖，如表 3-5, 3-6, 3-7。
- 2) 为了决定是否存在冗余序列，对其基因组做自身比对。发现两个野鸭基因组覆盖超过 50%的 scaffolds 的总长度是 11.3 Mb 和 10.3 Mb。该结果显示组装的两个野鸭的基因组几乎不存在冗余。在后续的工作中移除了覆盖超过 50%的 scaffold 片段。




图 3-2 利用北京鸭 1,3,4 号染色体的 7 个 BAC 文库评估绿头野鸭的组装

每个 BAC 的图示有三个部分：测序深度，BAC 序列图示（红色），组装的绿头野鸭基因组序列（蓝色）。




图 3-3 利用北京鸭 1,3,4 号染色体的 7 个 BAC 文库评估斑嘴野鸭的组装

每个 BAC 的图示有三个部分：测序深度，BAC 序列图示（红色），组装的斑嘴野鸭基因组序列（蓝色）。

表 3-5 BAC 文库对绿头野鸭和斑嘴野鸭基因组组装的评估

Fosmid_id	长度	绿头野鸭基因组覆盖率	斑嘴野鸭基因组覆盖率
ndae_TLR1	67,954	85.91%	70.03%
ndbaa_TLR15	79,704	98.50%	98.25%
ndbab_TLR5	72,128	98.41%	98.32%
ndbac_1_TLR3	76,489	97.53%	96.49%
ndbad_2_TLR7	97,799	95.64%	87.51%
ndbae_TLR2	75,080	98.82%	93.59%
ndbag_TLR4	77,042	97.79%	97.98%

表 3-6 用 EST 序列评估绿头野鸭基因组的组装覆盖度

数据集	数量	总长度 (bp)	组装覆盖 率 (%)	序列的 90%以上在一个		序列的 50%以上在一个	
				scaffold		scaffold	
				数量	百分比(%)	数量	百分比(%)
>0bp	319,996	98,257,350	99.02	294,845	92.14	315,689	98.65
>200bp	144,337	73,939,509	99.53	135,799	94.08	143,128	99.16
>500bp	43,896	43,155,260	99.84	41,595	94.76	43,687	99.52
>1000bp	13,652	22,939,026	99.99	12,831	93.99	13,613	99.71

表 3-7 用 EST 序列评估斑嘴野鸭基因组的组装覆盖度

数据集	数量	总长度 (bp)	组装覆盖 率 (%)	序列的 90%以上在一个		序列的 50%以上在一个	
				scaffold		scaffold	
				数量	百分比(%)	数量	百分比(%)
>0bp	319,996	98,257,350	99.01	294,324	91.98	315,566	98.62
>200bp	144,337	73,939,509	99.53	135,565	93.92	143,053	99.11
>500bp	43,896	43,155,260	99.85	41,531	94.61	43,670	99.49
>1000bp	13,652	22,939,026	99.99	12,802	93.77	13,606	99.66

3.1.4 重复序列，基因结构和基因功能注释与比较基因组学分析

在组装完成之后，用最后处理完成的基因组进行基因组注释。首先进行 TE 的注释，在使用多种软件利用预测以及同源比对的方法得到多个 TE 结果集合的情况下，根据 TE 的位置，综合考虑了所有重复注释的结果。注释结果如表 3-8。

随后进行蛋白编码基因结构注释，首先使用同源基因预测方法，根据 *Anas platyrhynchos* (北京鸭), *Gallus gallus* (鸡), *Struthio camelus* (鸵鸟), *Meleagris gallopavo* (火鸡), and *Ficedula albico* (姬鹇) 五个物种的基因组的蛋白数据库预测两只野鸭的蛋白编码基因。将预测的蛋白序列用 BLASTN 以 -e 1e-5 -F F -m 8 参数比对到基因组。之后用 GeneWise 将同源基因组序列比对蛋白，以精确其的剪切位置。

表 3-8 绿头野鸭，斑嘴野鸭和北京鸭中不同类型重复序列所占的比例

类型	绿头野鸭		斑嘴野鸭		北京鸭		鸡	
	长度	基因组	长度	基因组	长度	基因组	长度	基因组
	(Bp)	占比	(Bp)	占比	(Bp)	占比	(Bp)	占比
DNA	9,479,699	0.75	9,438,606	0.71	5,590,903	0.51	13872990	1.33
LINE	98,060,422	7.71	101,177,399	7.68	63,146,176	5.71	116778031	11.15
SINE	1,389,649	0.10	1,274,941	0.09	892,886	0.08	573610	0.05
LTR	52,195,974	4.10	48,381,075	3.67	21,255,312	1.92	47374647	4.53
其他	21,136	0.00	12,303	0.00	3,201	0.00	3338	0.00
未知	1,100,812	0.08	3,402,377	0.25	4,600,535	0.41	3351756	0.32
总计	136,134,153	10.71	139,051,537	10.55	80,740,993	7.31	149208388	14.25

其次，用北京鸭的转录组数据进行基因注释。使用 TopHat 将转录组 reads 比对到两个野鸭的基因组，并且用 Cufflinks 构建转录本集合。

最后，用 GLEAN 结合所有基因模型（五个同源基因模型集合和转录本基因模型集合）产生出一个统一的基因集。

基因功能注释过程中，我将最终的蛋白序列比对到功能已知的蛋白数据库包括 InterPro (iprscan_4.7) (profilescan, blastprodom, hmmsmart, hmmpanther, hmmpfam, fprintscan, patternScan), Gene Ontology, Swiss-Prot, TrEMBL and KEGG (release76)，以此来识别他们的 motifs, domains, 生物学功能和他们的分子通路。最终, 87%的基因模型都做了功能注释。如表 3-9。

表 3-9 利用多种不同已知数据库对蛋白编码基因进行功能注释

数据集	绿头野鸭		斑嘴野鸭	
	数量	百分比 (%)	数量	百分比 (%)
基因总数	21,056	100	21,123	100
InterPro	15,335	72.83	15,308	72.47
GO	12,817	60.87	12,815	60.67
KEGG	15,878	75.41	15,803	74.81
Swissprot	17,551	83.35	17,531	82.99
TrEMBL	18,371	87.25	18,327	86.76
注释数量	18,467	87.70	18,426	87.23
未注释	2,589	12.29	2,697	12.77

进一步根据这 9 个物种的基因集进行基因家族聚类。对存在可变剪切异构体的基因，仅保留含有最长翻译产物的转录本。我用 BLASTP 以 E-value 小于 1E-7 为标准，将所有蛋白之间进行比对，包括物种内部以及物种之间的蛋白。之后用一个简化版本的 Treefam 方法将不同物种的基因聚类为包含从一个相同最近祖先基因而来的基因家族，这样比出来的基因家族包括了直系同源和旁系同源基因。结果如表 3-10。

表 3-10 使用 TreeFam 进行基因家族聚类

物种	总基因数	未分类基因	基因家族	Unique 基 因家族	家族平均基因 数量
绿头野鸭	21,056	2,478	14,541	30	1.28
斑嘴野鸭	21,123	2,604	14,530	42	1.27
北京鸭	20,629	5,381	13,498	18	1.13
鸡	15,508	493	13,351	6	1.12
鸵鸟	16,178	326	11,579	105	1.37
火鸡	14,123	455	12,414	7	1.10
姬鹇	15,303	716	13,284	33	1.10
人类	20,238	1,825	15,036	117	1.22
鼠	22,627	1,549	15,407	139	1.37

在基因家族聚类之后，用所有单拷贝基因构建 9 个物种的进化树。使用 MUSCLE 软件对每个基因家族进行多序列比对，并且提取密码子第一位或第三的四重简并位点，将之连成一个超长的比对。据此构建进化树并且利用分子钟估算分歧时间（如图 3-4）。




图 3-4 基于单拷贝基因家族构建系统发生树

其中分歧时间是通过分子钟方法估计的，对于绿头野鸭，斑嘴野鸭，北京鸭之间的估计并不能适用。

3.2 鸭种群的群体多样性和群体结构分析

我对 87 只来自 7 个家鸭品种和 35 只来自 8 个野鸭品种的鸭子进行全基因组测序。其中，13 只斑嘴鸭，14 只绿头鸭和 27 只北京鸭按个体测序一共得到约 802 Gb 2×125-bp 的 paired-end reads。6 个家鸭品种，每个品种采集 10 只个体进行混池测序，一共产生 327.8 Gb

表 3-11 各品种的测序统计

分类	种群/品种	个体数	平均每只覆盖度	reads 长度	总量 (Gb)	测序策略
野鸭	绿头鸭 (<i>Anas poecilorhyncha</i>)	14	14.1 ×	125 bp	207	按个体测
	斑嘴鸭 (<i>Anas platyrhynchos</i>)	13	14.5 ×	125 bp	193	按个体测
	赤颈鸭 (<i>Anas penelope</i>)	3	22.8×	125 bp	75	按个体测
	赤膀鸭 (<i>Anas strepera</i>)	1	20×	125 bp	22	按个体测
	针尾鸭 (<i>Anas acuta</i>)	1	23×	125 bp	25.3	按个体测
	罗文鸭 (<i>Anas falcata</i>)	1	20×	125 bp	22	按个体测
	绿翅鸭 (<i>Anas penelope</i>)	1	21×	125 bp	23	按个体测
	花脸鸭 (<i>Anas crecca</i>)	1	20×	125 bp	22	按个体测
中国	北京鸭	27	13.4 ×	125 bp	397.98	按个体测
地方品种	绍兴鸭	27	2~3.5 ×	100 bp	89	按个体测
	高邮鸭	10	4.7×	100 bp	47	混池测序
	山麻鸭	10	4.0×	100 bp	40	混池测序
	连城白鸭	10	4.7×	100 bp	47	混池测序
	金定鸭	10	4.4×	100 bp	44	混池测序
商业品种	樱桃谷鸭	10	7.5×	100 bp	75	混池测序
	康贝尔鸭	10	4.5×	100 bp	45	混池测序
外群	番鸭	10	5.2×	100 bp	52	混池测序
	太湖鹅	10	3.5×	100 bp	35	混池测序




图 3-5 基于 SNP 的群体之间多样性比较

Ma, Sp, Bj, Sx, Gy, Jd, Cp, Lc, Sm, Cv 分别代表：绿头野鸭，斑嘴野鸭，北京鸭，绍兴鸭，高邮鸭，金定鸭，康贝尔鸭，连城白鸭，山麻鸭，樱桃谷鸭。A) SNP 数量统计，其中绿色部分为所有鸭品种中共有的 SNP 数量，粉红色为各鸭品种特异的 SNP 数量，蓝色为其余部分。B) 绿头野鸭特异 SNP 和斑嘴野鸭特异 SNP 在 8 个家鸭群体当中的数量。C) 基于 SNP 的个群体的多样性, π 为群体多样性, Watterson θ 为群体突变率)。D) 各群体的杂合子密度分布。其中野鸭的杂合度最高，北京鸭和绍兴鸭样本量为 27 个个体，所以其杂合度分布介于野鸭（样本量分别为 13，14 个个体）和其他家鸭品种（样本量为 10 个个体）之间。

2×100-bp 的 paired-end reads。另外我使用了一篇未发表的研究中测得的 27 只绍兴鸭数据。结合两个外群的混池测序结果进行后续的进化分析 (表 3-11)。

在 8 个家鸭品种中我一共鉴定出了 20,676,377 个 SNP, 在绿头野鸭和斑嘴野鸭中一共鉴定出 40,519,599 个 SNP, 在这 10 个群体当中一共鉴定出 44,852,612 个 SNP。其中两者共有 18,093,115 个 SNP。绿头野鸭和斑嘴野鸭与家鸭共有的 SNP 分别是 15,904,435 和 16,062,465。虽然两野鸭种群和家鸭之间有大量共有的 SNP，但是本研究所使用的十个用于分析的家鸭




图 3-6 绿头野鸭, 斑嘴野鸭和北京鸭, 绍兴鸭的连锁不平衡衰减 (LD decay) 情况

使用 plink 进行 LD 分析。纵坐标为 LD 大小, 横坐标为 SNP 之间的物理距离。A) 为 500 kb 以内的连锁不平衡衰减程度。B) 为 100 kb 以内的连锁不平衡衰减程度。

群体和野鸭种群中均共有的 SNP 是非常少的 (图 3-5 A)。进一步分析发现绿头野鸭特异 SNP (在绿头野鸭中为杂合状态在斑嘴野鸭中为纯和状态) 和斑嘴野鸭特异 SNP 在各个家鸭品种中的数量几乎是等量的 (图 3-5 B)。基于我鉴定的 SNP, 我首先进行群体多样性的分析, 结果如图 3-5 C, 可以看出两种野鸭的群体多样性和有效群体大小要明显高于家鸭各个群体 ($Watterson\ theta=4\mu N_e$)。而 SNP 的密度曲线 (图 3-5 D) 也显示出野鸭拥有较高的核苷酸多样性。其中北京鸭和绍兴鸭的多样性介于其他家鸭和绿头野鸭的曲线之间, 是因为这个两种群的样本量都是 27 只, 比其他的种群样本量都高。

对绿头野鸭, 斑嘴野鸭, 北京鸭和绍兴鸭的全基因连锁不平衡分析 (图 3-6), 发现其值 (r^2) 的跨度并不是很大, 整体上 LD 水平比人类群体高。野鸭品种在 1 kb 以上几乎不衰减, 但北京鸭和绍兴鸭在 1 kb 到 100 kb 范围之内仍然在持续衰减, 这可能是较高强度的人工选择造成的, 因为选择的特点就是改变局部的 LD 的强度, 而绍兴鸭和北京鸭在大于 200 kb 的 LD 水平低于野鸭品种, 这可能是因为野鸭群体中存在较强的结构化, 而家鸭群体在遗传结构上较为均一。我们通过连锁不平衡衰减图还可以知道需要将 SNP 稀释到每 100 kb 一个 SNP 的程度就可以近乎排除连锁效应的影响。

3.3 家鸭起源分析

我首先对 27 只绍兴鸭和 27 只北京鸭代表的家鸭品种和 35 只野鸭品种进行主成分分析。我发现家鸭和绿头野鸭, 斑嘴野鸭聚在一起, 而与其他野鸭品种有着明显的区分 (图 3-7 A, B)。为了展示 8 个家鸭品种与绿头野鸭和斑嘴野鸭之间的关系, 我对 8 个家鸭群体与绿头野鸭, 斑嘴野鸭群体进行主成分分析, 同时用番鸭作为外群。其显示家鸭群体聚为一类, 与绿头和斑嘴鸭在第二主成分上有着明显的区分。由于相对于野鸭, 8 个家鸭品种之间高度相似, 因此后面一些分析当中我们使用北京鸭和绍兴鸭代表家鸭。类似的, 我进行了基于 IBS 的进化树分析 (如图 3-7 C)。结果与主成分分析的结果相一致。这种结果也符合传统观点, 即家鸭起源于绿头野鸭或者绿头野鸭和斑嘴野鸭的杂交后代。进一步我为了弄清家鸭是否起源于单一的绿头野鸭还是其与斑嘴野鸭的杂交后代。我使用了 F3 统计量进行分析。发现不论如何处理数据 (消除群体结构等带来的误差), F3 的值都是大于 0 的 (如表 3-12)。也就是说 F3 并没有检测出混合起源的证据。由之前两种野鸭特异 SNP 在各个家鸭品种中的分布是等量的结果可以排除单一起源造成 F3 大于 0 的可能性。




图 3-7 进化关系与遗传特性分析

A) 使用 GCTA 进行三维主成分分析 (PCA); 左图为 8 个野鸭品种和两个家鸭品种的三维 PCA 分析。发现绿头野鸭与斑嘴野鸭和家鸭 (以北京鸭和绍兴鸭为代表) 的遗传关系最接近。右图为绿头野鸭, 斑嘴野鸭和北京鸭, 绍兴鸭的三维 PCA 分析。fh 样品来自表示浙江分化, hz 表示样品来自浙江杭州。

B) 表示 8 个家鸭群体和绿头野鸭, 斑嘴野鸭的二维 PCA 分析。用番鸭做外群。C) 使用 plink 计算 IBS 距离进而构建进化树。

表 3-12 基于 F3 统计量的混群分析

Source 1	Source 2	Target	f3	std.err	Z	SNP
Mallard	Spot-billed	beijing	0.007886	0.000748	10.546	9997
Mallard	Spot-billed	shaoxing	0.008662	0.000814	10.643	9943
Mallard	Spot-billed	mix beijing, shaoxing	0.007279	0.000305	23.834	---
Mallard_hz	Spot-billed_hz	beijing	0.008656	0.001076	8.045	9975
Mallard_hz	Spot-billed_hz	shaoxing	0.010200	0.000683	14.930	9907
Mallard_fh	Spot-billed_fh	beijing	0.007320	0.000603	12.147	9986
Mallard_fh	Spot-billed_fh	shaoxing	0.007380	0.000988	7.470	9921

*为了减少群体效应我们选取不同聚类的个体，进行多次 F3 统计量的检验。hz 表示样品来自浙江杭州，fh 表示样品来自浙江奉化。Mix beijing, shaoxing 表示将北京鸭和绍兴鸭的群体混合作为一个目标群体。

我进一步进行遗传结构分析 (genetic structure) (图 3-8 A), 将假设祖源成分从 K=2 增加到 K=7。令人感到奇怪的是, 当 K=2 时, 家鸭和野鸭首先可以被区分开, 当 K=3 时, 北京鸭和绍兴鸭群体可以被区分开, K=4 时, 绿头野鸭和斑嘴野鸭才开始被区分开, 直到 K=7 时, 才被完全区分开。这种情况暗示出野鸭是与家鸭的祖先分化之后再分化为绿头野鸭和斑嘴野鸭的进化结构 (如图 3-8 B 所示), 与传统的观念相左。造成这种现象的原因也不太可能是因为两种野鸭之间的基因交流, 因为如果绿头野鸭和斑嘴野鸭之间存在较强的基因交流的话, 那么每个野鸭群体的每个个体的祖源成分将有很大一部分是来自于另一个群体。另外, 当 K=2 时, Cross-Validation error 最小。这反映出相比于野生群体之间或驯化品种之间, 野生群体和驯化群体之间的差异最大。而图 3-8 B 的这种进化结构也解释了为什么两种野鸭的特异 SNP 会在家鸭各个群体之中等量的分布以及 F3 统计量大于 0 的原因。另外, 遗传结构的分析还显示出野鸭群体较高的遗传异质性, 并且家鸭群体的遗传背景非常均一。这与 PCA 的分析也是相一致。进一步我基于全基因组水平两两群体之间的群体分化程度 (F_{ST}) 构建以番鸭和赤颈鸭为外群的进化树 (图 3-8 C)。结果同样支持了我推断的进化结构。




图 3-8 家鸭与野鸭（绿头野鸭，斑嘴野鸭）群体历史的推断

A) 通过不同祖源成分分析野鸭群体和家鸭群体的遗传结构。每条垂直矩形代表一个个体，按群体划分。每种颜色代表一种祖源成分，祖源成分数量 K 从 2 递增到 7。B) 为群体历史模型。我们的观测与传统的家鸭驯化历史模型不相符（左），因此我们提出新的家鸭群体驯化历史的模型（右）。C) 基于全基因组 F_{ST} 构建的进化树

随后我使用 $\partial a \partial i$ 以如图 2-6 所示模型分别模拟绿头野鸭，斑嘴野鸭，家鸭之间两两之间分化的情况。如果他们的进化关系符合传统观点的话（图 3-8 B），那么家鸭和斑嘴野鸭，绿头野鸭和斑嘴野鸭的分化时间会是相比拟且最久远的，绿头野鸭和家鸭之间的分化时间会是最近的。而实际是家鸭和两种野鸭的分化时间是相比拟且比较久远（100 Kyr 左右），两种野鸭的分化时间是比较近的（20 Kyr 左右）（图 3-9）。这一结果进一步印证了之前推测的进化结构，并且给出了可供参考的分化时间。至此，SNP 的分布情况，PCA，IBS-tree，基于 F_{ST} 的进化树， f_3 统计量，genetic structure， $\partial a \partial i$ 等的分析均显示出家鸭祖先与野鸭祖先先分化之后，野鸭进一步分化为绿头野鸭和斑嘴野鸭的群体结构。也即是说家鸭可能起源于与绿头和斑嘴野鸭不同的另外一个鸭群体。




图 3-9 $\partial a \partial i$ 模拟结果对 IM 模型分化时间的推断

A) 通过 $\partial a \partial i$ 模拟对 IM 模型分化时间的推断结果的分布。从上到下一次为利用 $\partial a \partial i$ 软件模拟 100 次绿头野鸭和斑嘴野鸭，绿头野鸭和家鸭，斑嘴野鸭和家鸭的分化。使用图 2-5 所示的群体分化模型。纵坐标为模拟结果的似然率，横坐标为模拟得到的分化时间。B) 和图 A 100 次模拟中某一次模拟对应的频谱及残差的分布。左上为实际数据的频谱，右上为模拟得到的频谱，左下和右下分别为残差分布的不同展现形式。

与 $\partial a \partial i$ 根据经典遗传学从前向后模拟互补地，我使用基于溯祖理论从后向前模拟的软件 PSMC 对群体历史进行模拟。

我发现绍兴鸭的 PSMC 曲线与北京鸭的 PSMC 曲线形状相似，但是被压缩并且向前平移了 (如图 3-10)。由于两个品种鸭个体的测序深度差距较大，这种曲线上的差异可能是测序深度差异引起的差异。于是我对北京鸭按梯度稀释到与绍兴鸭相同的深度，得到了与绍兴鸭类似的曲线 (如图 3-11)。因此，我认为可以用北京鸭的 PSMC 曲线代表绍兴鸭的 PSMC 曲线，进而代表家鸭的 PSMC 曲线。与绿头野鸭和斑嘴野鸭的 PSMC 曲线相比较 (如图 3-12)，我发现野鸭的曲线和家鸭的曲线从 100 Kyr~200 Kyr 之间开始出现差异，家鸭的有效群体大小开始明显地持续减少。这一时间段和我之前通过 $\partial a \partial i$ 推测出的家鸭和野鸭分化的时间相近，而 11~12 万年前也正是末次冰河时期 (LGP) 开始的时候。这时野鸭的有效群体大

小并没有明显的减少直到大约 20 Kyr, 也就是末次冰期气温最低点的时期 (末次盛冰期 LGM) 出现了明显的种群规模的减少。

值得注意的是, 绿头和斑嘴野鸭的曲线, 个体之间有所差异, 并且无法区分是绿头还是斑嘴野鸭, 这个可能与野鸭群体遗传背景的异质性较高有关。因为雁形目有种间杂交的倾向 (Panov, 1989), 会导致种群的遗传结构出现较高的异质性, 造成 genetic structure 中绿头和斑嘴野鸭的成分很杂的现象, 也是 PSMC 曲线一致性较差的原因。




图 3-10 绍兴鸭与北京鸭的 PSMC 曲线的比较

纵坐标为有效群体大小, 横坐标为距今的时间。“sx-”表示绍兴鸭, “pk”表示北京鸭。A) 几个代表性的绍兴鸭。B) 绍兴鸭与北京鸭比较。




图 3-11 稀释到不同深度得到的 PSMC 曲线

A) 编号为 44448_30 的北京鸭稀释到不同深度时得到的 PSMC 曲线，图例中的数字表示 reads 的平均覆盖度。B), C) 依次为 43844_32 和 41300_50 两个体的不同测序深度的 PSMC 曲线。D) 将北京鸭 44448_30, 43844_32, 41300_50 分别稀释到平均覆盖度为 2.79, 2.86, 3.47 时，与绍兴鸭的代表个体的 PSMC 进行比较。




图 3-12 用 PSMC 计算野鸭与家鸭有效群体大小的历史变化

两条灰色条带分别表示末次冰期（LGP）开始的时候，和末次盛冰期（LGM）。

3.4 野鸭祖先群体当中受到的自然选择

为了探究是否在野鸭祖先和家鸭祖先分化的早期, 在野鸭的祖先当中的适应性选择导致了野鸭祖先群体适应了环境变化, 从而避免了种群规模因环境变化的减少。于是我对野鸭祖先与家鸭祖先分化时受到的正选择区域进行探测, 首先, 根据家鸭与野鸭频率的相关性(如图 3-13), 计算各个位点家鸭的期望频率。探测了在野鸭祖先和家鸭祖先分化早期, 野鸭祖先群体当中的受正选择的区域。本人一共探测到了 434 个潜在受选择的区域, 其平均长度为 25kb。这些区域包含 589 个 miRNA。其中 167 个受选择区域包含 189 个蛋白编码基因和 262 个 miRNA, 其余区域没有与已知的蛋白编码基因有交叠。根据最近的研究, 基因间区的变异可能通过远程调控影响临近的蛋白编码基因从而对表型变异产生影响。于是我将这些不包含蛋白编码基因的区域向上下游延伸 180 kb。在其中的 157 个受选择区域的延伸区域中一共找到了 164 个距离其最近的蛋白编码基因。我进一步将上述 189 个基因与 167 个受选择区域比较, 发现其中 100 个基因的 5'端或 3'端与受选择区域有重叠, 96 个基因包含或包含与受选择区域。




图 3-13 家鸭与野鸭 SNP 衍生等位基因频率的相关性

图示为全基因范围内, 以 20 kb 窗口每次滑动 10 kb 计算窗口内野鸭 DAF > 0 位点的 DAF 的均值, 将频率划分为 28 个 bins, 同时计算家鸭群体内对应位点的 DAF 均值。得到相关性曲线。

对鉴定出来的这 318 个基因做 GO 富集分析, 以 p 值小于 0.05 为标准, 发现 343 个条目发生明显富集, 其中 236 个生物学过程条目 (biological processes) (部分结果展示在表 3-13 中展示)。最主要的条目涉及一系列器官和系统, 诸如肢/翼, 肺, 心脏, 后肾的发育与形态发育, 呼吸系统的发育和心肌与骨骼肌的收缩与发育。一系列的器官与形态的改变可能暗示出野鸭远距离飞行能力的增强。另外“腹背形态的形成”, “左右平衡决定”也暗示其身体形态可能朝着更适宜飞行的形态改变。除此之外, “伤口愈合”, “蛋孵化活性”, “急性炎症反应”, “病毒探测”等条目的富集可能显示出野鸭野外生存能力的增强。在受选择的基因当中有一些非常有趣, 比如三个基因和线粒体相关可能对于长时间飞行的能量提供有重要作用。*DNAJ1* 促进 ATP 水解。*MRPS27* 有助于线粒体蛋白的合成。较高等级的线粒体代谢可能会有使线粒体受损的副作用, 而 *PARK2* (S=-3) 促进受损线粒体的水解。关于鸟类迁徙过程中的磁感应定位, 之前有研究报道称鸟类可能是通过视网膜感受磁场, 将信号传递到前脑的一个特殊

区域 (Liedvogel et al., 2007)。我也发现了 *EFNA5* 和 *ISL1* 两个受到选择的基因是和视网膜神经节细胞轴突导向相关, *CHRD* 和 *WNT7B* 和前脑的分区域发育相关。

表 3-13 野鸭祖先受选择基因的 GO 富集分析 (biology_process)

GO_Accession:GO_Term_Name	P-value	Nr	Size	gene_symbol
0042517:positive regulation of tyrosine phosphorylation of Stat3 protein	6.45E-05	4	12	<i>IL6ST</i> , <i>ISL1</i> <i>CRLF1</i> , <i>IL31RA</i>
0032925:regulation of activin receptor signaling pathway	0.00038688	2	2	<i>SMAD7</i> , <i>FGF10</i>
0051482:positive regulation of cytosolic calcium ion concentration involved in phospholipase C-activating G-protein coupled signaling pathway	0.000394021	3	8	<i>RXFP3</i> , <i>EDN1</i> , <i>LPAR1</i>
0009597:detection of virus	0.001145494	2	3	<i>SERINC5</i> , <i>DDX58</i>
0070779:D-aspartate import	0.001145494	2	3	<i>SLC1A1</i> , <i>SLC1A3</i>
0003338:metanephros morphogenesis	0.002261139	2	4	<i>FGF10</i> , <i>WNT7B</i>
0051938:L-glutamate import	0.002261139	2	4	<i>SLC1A1</i> , <i>SLC1A3</i>
2001240:negative regulation of extrinsic apoptotic signaling pathway in absence of ligand	0.003505232	3	16	<i>FGF10</i> , <i>GDNF</i> , <i>CX3CR1</i>
0032725:positive regulation of granulocyte macrophage colony-stimulating factor production	0.003719543	2	5	<i>ISL1</i> , <i>DDX58</i>
0060541:respiratory system development	0.003719543	2	5	<i>SPRY2</i> , <i>FGF10</i>
0007368:determination of left/right symmetry	0.003804996	5	53	<i>IFT74</i> , <i>FGF10</i> , <i>AP1B1</i> , <i>DPCD</i> , <i>PCSK5</i>
0021522:spinal cord motor neuron differentiation	0.004194841	3	17	<i>PTCH1</i> , <i>LMO4</i> , <i>ISL1</i>
0060425:lung morphogenesis	0.004194841	3	17	<i>SPRY2</i> , <i>FGF10</i> , <i>WNT7B</i>
0035235:ionotropic glutamate receptor signaling pathway	0.004961135	3	18	<i>GRIN2A</i> , <i>GRIA4</i> , <i>GRIN3A</i>
0055010:ventricular cardiac muscle tissue morphogenesis	0.004961135	3	18	<i>SMAD7</i> , <i>ISL1</i> , <i>PTCD2</i>
0009953:dorsal/ventral pattern formation	0.005296041	4	36	<i>PTCH1</i> , <i>CHRD</i> , <i>EDN1</i>
0010801:negative regulation of peptidyl-threonine phosphorylation	0.005506855	2	6	<i>SPRY2</i> , <i>SMAD7</i>
0042428:serotonin metabolic process	0.005506855	2	6	<i>GRIN2A</i> , <i>RNF180</i>
0060428:lung epithelium development	0.005506855	2	6	<i>FGF10</i> , <i>WNT7B</i>
0019221:cytokine-mediated signaling pathway	0.006435908	4	38	<i>GHR</i> , <i>CX3CR1</i> ,

				<i>IL6ST, FER</i>
0006289:nucleotide-excision repair	0.006732609	3	20	<i>POLL, RAD23B , FANCC</i>
0030593:neutrophil chemotaxis	0.006732609	3	20	<i>ITGA9, ITGA1, PDE4D</i>
0050680:negative regulation of epithelial cell proliferation	0.007062304	4	39	<i>IFT74, PTCH1, MCC</i>
0010460:positive regulation of heart rate	0.007609635	2	7	<i>SLC1A1, EDN1</i>
0048016:inositol phosphate-mediated signaling	0.007609635	2	7	<i>ITPR2, EDN1</i>
0060449:bud elongation involved in lung branching	0.007609635	2	7	<i>SPRY2, FGF10</i>
0035108:limb morphogenesis	0.010014442	3	23	<i>PTCH1, FGF10 , PCSK5</i>
0001676:long-chain fatty acid metabolic process	0.010014839	2	8	<i>SLC27A3, SLC27A6</i>
0006835:dicarboxylic acid transport	0.010014839	2	8	<i>SLC1A1, SLC1A3</i>
0070102:interleukin-6-mediated signaling pathway	0.010014839	2	8	<i>IL6ST, FER</i>
0070493:thrombin receptor signaling pathway	0.010014839	2	8	<i>F2R, IQGAP2</i>
0009611:response to wounding	0.012635377	3	25	<i>F2R, GRIN2A , SLC1A3</i>
0001516:prostaglandin biosynthetic process	0.012709815	2	9	<i>PTGS2, EDN1</i>
0031290:retinal ganglion cell axon guidance	0.012709815	2	9	<i>EFNA5, ISL1</i>
0035025:positive regulation of Rho protein signal transduction	0.012709815	2	9	<i>F2R, LPAR1</i>
0061029:eyelid development in camera-type eye	0.012709815	2	9	<i>INHBA, MAP3K1</i>
0089711:L-glutamate transmembrane transport	0.012709815	2	9	<i>SLC1A1, SLC1A3</i>
0006816:calcium ion transport	0.0137268	5	72	<i>GRIN2A, ITPR2, SLC24A2, PLCZ1, GRIN3A</i>
0008544:epidermis development	0.015612216	3	27	<i>IFT74, PTCH1, FGF10</i>
0015813:L-glutamate transport	0.015682288	2	10	<i>SLC1A1, SLC1A3</i>

*按 P 值从小到大排列 GO term。Nr 为富集在该条目的受选择基因数目，Size 为该条目的基因数。gene_Symbol 为富集在该条目的基因符号，有些转录本没有 symbol 因此其数量和 Nr 并不一定相等。

此外本人还进行了 KEGG 通路富集分析（表 3-14），结合 KEGG 通路富集分析，本人与合作者进一步对这些基因进行通路分析，主要对其抗病毒相关通路进行分析如图 3-14 所示。其中有 16 个受选择基因在 dsRNA 免疫通路上发挥作用。其中 *USP25* 在感染 RNA 或 DNA 病毒

表 3-14 野鸭祖先受到选择基因的 KEGG 通路富集分析

KEGGI	Pvalue	OddsRat	ExpCou	Cou	Siz	Term	Symbols
D		io	nt	nt	e		
4610	0.0033	7.22260	0.62310	4	69	Complement and coagulation cascades	C6;C7;C9;F2R
	22	6	4				
5020	0.0037	10.845	0.31606	3	35	Prion diseases	C6;C7;C9
	12		7				
4070	0.0051	6.33425	0.70437	4	78	Phosphatidylinositol signaling system	ITPR2;PIK3C2G;PIK3C3;PLCZ1
	63	3	9				
562	0.0144	6.40222	0.51473	3	57	Inositol phosphate metabolism	PIK3C2G;PIK3C3;PLCZ1
	37	2	8				
20	0.0296	8.10644	0.27091	2	30	Citrate cycle (TCA cycle)	DLAT;SDHD
	23	3	5				
5322	0.0336	3.51515	1.22814	4	13	Systemic lupus erythematosus	C6;C7;C9;GRIN2A
	77	2	8		6		
4140	0.0373	7.08823	0.30703	2	34	Regulation of autophagy	PIK3C3;PRKAA1
	41	5	7				





图 3-14 野鸭祖先群体受到选择的基因在 dsRNA 免疫通路上的分布

红色显示的基因为通路上受选择的基因，箭头表示促进，“T”型线一般表示抑制。

之后, 可通过结合 *TRAF3* 将其去泛素化 (Ren et al., 2016)。*ADAP* 可与 *TRAF6* 和 *TAK1* 形成蛋白复合体, 从而激活 *SMAD3*, 进而使 TGF- β 上调 (Li et al., 2015)。*INHBA* 不仅参与免疫信号通路, 其和眼睑闭合功能也相关。*FGF10* 与心脏发育也相关。*DNAJA1* 还参与促进线粒体中 ATP 水解的过程。

为了详细观察受选择区域的选择信号的情况和各个种群之间变异频率之间的差异, 我首先对受选择区域以及其上下游重新计算选择信号的值, 以 5 kb 作为窗口的大小, 每次滑动一个窗口, 这样对所有的 434 个受选择区域我可以得到如图 3-15 所示的详细展示图, 我用自动化系统一共生成了 434 张这样的选择信号详细展示, 这里我只展示几张典型的以及被选取进行实验验证的位点。另外, 我对这 434 个受选择区域绘制了 identity score (IS, 窗口大小 20 kb 每次滑动一个窗口) heatmap 图用以展示个两两群体之间的一致性, 同样我仅展示几张典型的示例 (如图 3-15)。可以观察到在受选择的位点并未出现明显的变化。这可能是由于我探测的是家鸭与野鸭分化早期的选择性清除, 随着时间的推移, 重组以及突变重塑了该区域的多样性而该方法计算选择信号主要利用古老 SNPs, 而 IS 的计算则是利用现存的所有 SNPs。另外值得一提的是, 在很多明显观察到选择信号但不包含编码蛋白基因的区域, 我都发现有 miRNA 的存在, 这也许暗示出 miRNA 通过调控作用影响生物表型的作用。从这几张图中我们可以看出, 相比于 miRNA 受选择区域, 蛋白编码基因区的受选择信号并不是很明显。如 *MRPS27*, *GHR*, *ISL1*, *DNAJA1* 等基因上或周围出现的选择信号散布分布与基因组上。主这可能反映出几点信息, 首先, 早期选择性清除的痕迹随着时间的推移, 逐渐的被湮灭, 信号残留微弱且存在较多的噪声。并且蛋白编码基因受到选择的位点可能是多个。而 miRNA 或非编码调控区域受到选择的位点是紧密连锁的或是单一的。其次, 非编码区可能对野鸭的表型改变有较为重要的贡献。从 IS 热图可以看出两野鸭群体之间的一致性在受选择区域没有明显的增强, 这也反应出选择信号已经比较久远, 需要采用类似本文中采用的专门探测早期选择信号的方法探测。






图 3-15 受选择区域的选择信号和 identity score

列举了 6 个受选择区域的情况，每个区域通过上下两张图展示。上图纵坐标表示其受选择信号强度的 S 值，横坐标为物理位置（即窗口号）。下图为相应受选择区域的不同鸭群体之间的 IS-score 值转化为不同颜色的热图展示。热图左边的色块表示对应行展示哪两个鸭群体的 IS 值的比较。Ma, Sp, Gy, Sx, Sm, Lc, Cv, Bj, Jd, Cp 分别代表绿头野鸭，斑嘴野鸭，高邮鸭，绍兴鸭，山麻鸭，连城白鸭，樱桃谷鸭，北京鸭，金定鸭，康贝尔鸭。A) 包含我们感兴趣的 *CHRD* 基因，和前脑发育相关，*CLCN2* 和视网膜发育相关。可能影响野鸭迁徙过程中利用磁场定位的能力。B) 包含 *MRPS27* 和线粒体合成相关。可能和野鸭长距离飞行过程中需要线粒体提供大量能量相关。C) 为 *GHR* 基因。D) 为 *EFNA5* 上游 10 kb，和视网膜发育相关。可能是与迁徙过程中感知磁场的的能力相关。该受选择区域中的一个突变在后续做了活性实验，证明其存在调控活性。E) *ISL1* 基因和能量代谢相关。F) 中不包含任何已知的编码蛋白基因，但是包含 miRNA，而且选择信号明显。此类情况在基因组上普遍存在，可能暗示出非编码基因的调控功能在进化过程中发挥重要作用。G) 包含 *DNAJ1* 促进 ATP 水解。可能和野鸭长距离飞行过程中需要大量能量相关。

图下标为 “scaffold 号：用于计算的第一个 SNP 的物理位置~最后一个 SNP 的物理位置

受选择区域的起始位置~受选择区域的末端：与受选择区域交叠的基因名”

3.5 绿头野鸭和斑嘴野鸭的种化分析

根据前面第三章第三节的推测，绿头野鸭和斑嘴野鸭的分化年代大约是 20 Kyr，这与之前根据线粒体推测绿头野鸭和斑嘴野鸭处在分化的早期阶段的报道相一致 (Zhuravlev and Kulikova, 2014)，并且其分化时间比另一个用于物种形成过程的研究的物种姬鹀（分化时间估计为 340Kyr~ 2 Myr）的分化时间要少。我比较了绿头野鸭和斑嘴野鸭的 F_{ST} ，以及他们和家鸭之间的 F_{ST} 。我发现野鸭之间的 F_{ST} 的范围是 -0.01566867 到 0.7970608 均值为 0.06369，其分布呈现出一个狭窄的单峰，而它们与家鸭的 F_{ST} 的范围是 0.088 到 0.8911792，均值是 0.2099762，其分布呈现出一个很宽的峰。该观测也与绿头野鸭和斑嘴野鸭处在分化早期的推测相一致。全基因组范围上看，两种群的分化程度非常低，但存在分化程度很高的少部分区域（如图 3-16）(Martin et al., 2013)。为了进一步在基因组层面探究物种形成的过程，我首先滑窗计算有多少位点满足所有 14 只绿头野鸭都固定为一种碱基，而所有 13 只斑嘴野鸭都固定为另一种碱基（称为 df 位点）。窗口大小 40 kb 每次滑动 20 kb。我一共只找到 4,386 个这样的位点，分布在很小的基因组区域之内（分布在 713 窗口中，而一共有 52214 个窗口）。4,386 个 df 位点中，位于 CDS 区，intron 区和基因间区的位点数分别为 26, 1286, 6 和 2946 个。沿用之前的研究中使用的标准，我定义 df 密度高于 50 倍的基因组均值的区域称为基因组岛。我发现绝大多数 (3, 522) df 位点都位于 348 个基因组岛之内，其中总长度仅覆盖鸭基因组的 0.6%。而姬鹀的研究中，有比本研究多 54 倍的 df 位点 (239,745)，其中仅有 25% 分布在约 50 个基因组岛，覆盖姬鹀基因组面积的 2.7%。这种差异可能是由于野鸭的分化时间要少于姬鹀的分化时间。

随后我沿用类似姬鹀研究中描绘基因组特性的几个指标 (F_{ST} , π 和 Tajima's D) 来刻画绿头野鸭与斑嘴野鸭的基因组分化特性。与姬鹀中的观测相同的是虽然基因组岛呈现出较高的群体分化程度 (F_{ST} , 变化范围从 0.239062 到 0.6280952，均值为 0.4146389 $\pm$ 0.072)，但绿头

野鸭和斑嘴野鸭在基因组岛的核苷酸多样性都有所降低 (如表 3-13)。这样在基因组岛呈现出两种群间的高度分化以及种群内部的较低的核苷酸多样性暗示出选择独立的发生在两个种群内部, 也因此使得该区域出现群体分化。进而我期待两个野鸭品种的 Tajima's D 也出现降低, 正如姬鹇中所观测的那样, 但是我发现 Tajima's D 并没有显著的变化 (图 3-17, 3-18)。我进一步比较基因组岛内外的 SNP 数量, 我发现基因组岛内的 SNP 数量显著降低 (如表 3-13)。也就是说基因组岛内的 SNP 位点数与核苷酸多样性都发生了降低。由于 $Tajima's D = \frac{\pi - \theta_w}{Var}$, 而 $\theta_w = K / (\sum_{i=1}^n \frac{1}{i})$ (K 是 SNP 数目, n 是个体数) 这样就解释了 Tajima's D 在绿头鸭和斑嘴鸭中都没有出现明显变化的原因。综上, 我认为强烈的选择性使得鸭与姬鹇的基因组岛的 π 与 Watterson theta (θ_w) 都发生了降低, 然而由于绿头与斑嘴野鸭处在物种分化的早期且其分化时间比斑驳姬鹇和花领姬鹇的分化时间要短, 因此前者没有积累起足够的突变以增加群体突变率使得其 Tajiam's D 像后者那样出现降低 (因为新出现的突变会在低频段开始积累, 主要会增大 θ_w , 而 π 主要由高频段等位基因决定)。

表 3-15 群体基因组参数均值

参数	全基因组背景值	基因组岛内均值
df	4.06E-06	2.03E-04
F _{ST}	0.06133946	0.414639
SNP _{mallard}	1086	308
SNP _{pot-billed}	1108	194
$\pi_{mallard}$	0.00723877	0.002136
$\pi_{spot-billed}$	0.00729366	0.001341
D _{mallard}	-0.50958810	-0.23
D _{spot-billed}	-0.6087172	-0.39483




图 3-16 全基因组 F_{ST} 分布的比较

红色曲线表示绿头野鸭和斑嘴野鸭之间的全基因组 F_{ST} 分布，褐色和绿色的曲线分别为斑嘴野鸭，绿头野鸭和家鸭之间的全基因组 F_{ST} 分布。蓝色曲线表示家鸭与绿头野鸭和斑嘴野鸭混合之后的 F_{ST} 分布。




图 3-17 绿头野鸭和斑嘴野鸭全基因组 Tajima's D 的分布图

绿色线为绿头鸭群体的全基因组上所有 40 kb 的窗口 (滑动 20 kb) 的 Tajima's D 的值的分布图。蓝色线为斑嘴鸭群体的全基因组上所有窗口的 Tajima's D 的值的分布图。虚线为基因组岛内的 Tajima's D 的分布图。




图 3-18 群体基因组参数在 scaffolds 上的分布

将所有 40 kb 以上的 scaffolds 按照数值由小到大排序，这里展示的是从 KB742597.1 号 scaffold 到 KB742716.1 号 scaffold，颜色变化表示 scaffold 变化，对所有 scaffolds 循环使用七种颜色。图中展示的群体基因组参数分别为绿头野鸭和斑嘴野鸭的 Tajima's D，差异固定密度 df, zF_{ST} (仅显示标准化之

后大于 0 的值)，绿头野鸭和斑嘴野鸭的 SNP 数量，核苷酸多样性 (π) 和杂合度 (zHp, 仅显示小于 0 的值)。

将 df 与 F_{ST} 在基因组上的分布与早期选择信号 S 值的分布比较我发现三者有相似的趋势 (如图 3-19)。这可能暗示出绿头野鸭和斑嘴野鸭的祖先群体在冰河时期受到的正选择可能与其群体分化有关系。进一步比较发现基因组岛内的 S 值要明显低于全基因组上 S 值的分布 (如图 3-20)。




图 3-19 基因组岛与野鸭祖先群体当中受选择的区域高度重合

图中显示的 scaffold KB742382.1 到 scaffold KB742819.1 的基因组参数和选择信号的分布。第一行为差异固定的密度 df ，第二行为群体分化指数 F_{ST} 。第三行为野鸭祖先群体中的选择信号 (S)。可以看到 S 的分布与 df 或 F_{ST} 的分布呈现出“倒影”状。




图 3-20 野鸭祖先群体中的选择信号 (S) 在基因组岛内的分布高于基因组岛之外的分布
窗口大小为 40 kb，每次滑动 20 kb。

3.6 家鸭驯化过程中遗传改变的鉴定

我采用两种选择信号探测驯化过程中受到选择的区域 (图 3-21): 家鸭与野鸭的分化程度 F_{st} , 和家鸭自身杂合度的降低 H_p 。对两个信号进行 Z-transform 标准化之后, 以 4 倍的标准差作为阈值, 发现 F_{st} 与 H_p 的离群值部分只有很少比例的重叠, 暗示这两种信号探测的并不是




图 3-21 家鸭全基因组的选择性清除分析

A) 上半部分为 8 个家鸭群体与野鸭群体 (绿头野鸭和斑嘴野鸭) 之间的大于 0 的 zF_{st} 在全基因组上的分布, 下半部分为 8 个家鸭群体的杂合度 (zH_p) 小于 0 的窗口在全基因组上的分布。两个信号的窗口大小都是 40 kb 每次滑动 20 kb。横坐标为基因组物理位置, 不同颜色代表不同 scaffold 号。对于横线之外的离群值的窗口, 显示出窗口之内包含的基因 symbol。B) 下半部分为所有窗口内 zF_{st} 与 H_p 的分布。虚线表示四倍标准差的阈值, 用来选出离群值的窗口。可以看到 zF_{st} 与 zH_p 的重叠部分非常少 (红色部分)。

完全相同的事件。对 *Fst* 以及 *Hp* 共同探测到选择信号的这部分区域 (如果不包含基因就向上下游延伸 180 kb 寻找最近的基因), 一共找到 *MLLT3*, *CD180*, *PIK3R1*, *FBXO4*, *FAM84B*, *DGKQ*, *TMEM170B*, 7 个已知基因。*PIK3R1* 与神经营养因子 *TRKA* 受体的结合有关, *DGKQ* 和 NAD^+ 激酶活性相关, 与细胞信号转导过程中的 PI (phosphatidylinositol 磷脂酰肌醇) 循环相关, 而 PK3-K 和记忆形成相关 (Mizuno et al., 2003)。*CD180* 和 B 细胞扩增相关, *FBXO4* 和蛋白的泛素化正调控有关。由于家鸭与野鸭分化时间较为久远, 因此各自都经历了很长的并不相同的群体历史, 可能会有很多事件导致 *Fst* 的升高, 比如野鸭受到自然选择, 家鸭早期受到的自然选择以及近期受到的驯化选择。由于 *Hp* 更适于衡量近期的选择性清除效应, 因此我下面仅就 *Hp* 探测到的受选择区域进行分析。当以 *zHp* 小于 -4 作为阈值时, 本人一共探测到 73 个连续的潜在受选择区域。对其中包含的基因 (如果不包含基因就向上下游延伸 180 kb 寻找最近的基因, 一共 91 个) GO 富集上看, 主要集中在神经, 免疫, 细胞分裂, 细胞间信号通路, 脂肪, 蛋白质及糖类的代谢合成。其中受选择最大的区域是位于 KB742969.1 号 scaffold 的一段长达 400k 的区域, 包含 *TMEM132C*, *SLC15A4*, *GLT1D1*, *TMEM132D* 四个基因。其中 *TMEM132C* 与 *TMEM132D* 为跨膜蛋白, 可能和细胞间的信号通路相关。另外值得注意的是 *LYST*, *HEXB*, *MRAP2*, *MC4R*, *NLGN1* 与 *PER2* 基因, *LYST* 在北极熊的研究中也被发现受到选择, 被认为是和北极熊毛的白化相关, *PER2* 以及 *NLGN1* 都和生理节律相关。*MC4R* 与 *MRAP2* 和动物被饲喂行为相关, *HEXB* 与雄性求偶行为相关。

表 3-16 家鸭群体受选择基因 (*zHp*<-4) 的 GO 富集分析

GO_Accession:GO_Term	Name	P-value	Nr	Size	geneSymbol
0008209:androgen metabolic process	0.001626152	2	10		<i>CYP19A1</i> , <i>HSD17B4</i>
0061025:membrane fusion	0.002366012	2	12		<i>STX7</i>
0007157:heterophilic cell-cell adhesion via plasma membrane cell adhesion molecules	0.003236251	2	14		<i>NLGN1</i> , <i>CDH4</i>
0007416:synapse assembly	0.004779003	2	17		<i>NLGN1</i>
0007162:negative regulation of cell adhesion	0.005354974	2	18		<i>CDH13</i> , <i>PIK3R1</i>
0010841:positive regulation of circadian sleep/wake cycle, wakefulness	0.006140463	1	1		<i>NLGN1</i>
0015761:mannose transport	0.006140463	1	1		<i>M6PR</i>
0036111:very long-chain fatty-acyl-CoA metabolic process	0.006140463	1	1		<i>HSD17B4</i>
0036112:medium-chain fatty-acyl-CoA metabolic process	0.006140463	1	1		<i>HSD17B4</i>
0048789:cytoskeletal matrix organization at active zone	0.006140463	1	1		<i>NLGN1</i>
0051531:NFAT protein import into nucleus	0.006140463	1	1		<i>PIK3R1</i>
0051640:organelle localization	0.006140463	1	1		<i>STX7</i>

0070925:organelle assembly	0.006140463	1	1	<i>STX7</i>
0071881:adenylate cyclase-inhibiting adrenergic receptor signaling pathway	0.006140463	1	1	<i>ADRA2A</i>
0071882:phospholipase C-activating adrenergic receptor signaling pathway	0.006140463	1	1	<i>ADRA2A</i>
0072553:terminal button organization	0.006140463	1	1	<i>NLGNI</i>
0097091:synaptic vesicle clustering	0.006140463	1	1	<i>NLGNI</i>
0097113:AMPA glutamate receptor clustering	0.006140463	1	1	<i>NLGNI</i>
0097115:neurexin clustering involved in presynaptic membrane assembly	0.006140463	1	1	<i>NLGNI</i>
1902685:positive regulation of receptor localization to synapse	0.006140463	1	1	<i>STX7</i>
2000302:positive regulation of synaptic vesicle exocytosis	0.006140463	1	1	<i>NLGNI</i>
0006597:spermine biosynthetic process	0.012243611	1	2	<i>SMS</i>
0014054:positive regulation of gamma-aminobutyric acid secretion	0.012243611	1	2	<i>GRIK1</i>
0015672:monovalent inorganic cation transport	0.012243611	1	2	<i>TMEM38B</i>
0031581:hemidesmosome assembly	0.012243611	1	2	<i>LAMC1</i>
0032510:endosome to lysosome transport via multivesicular body sorting pathway	0.012243611	1	2	<i>LYST</i>
0032648:regulation of interferon-beta production	0.012243611	1	2	<i>TRAF3</i>
0033299:secretion of lysosomal enzymes	0.012243611	1	2	<i>LYST</i>
0033364:mast cell secretory granule organization	0.012243611	1	2	<i>LYST</i>
0048017:inositol lipid-mediated signaling	0.012243611	1	2	<i>TNFAIP8L3</i>
0048753:pigment granule organization	0.012243611	1	2	<i>LYST</i>
0051668:localization within membrane	0.012243611	1	2	<i>CDH13</i>
0055096:low-density lipoprotein particle mediated signaling	0.012243611	1	2	<i>CDH13</i>
0060627:regulation of vesicle-mediated transport	0.012243611	1	2	

0071883:activation of MAPK activity by adrenergic receptor signaling pathway	0.012243611	1	2	<i>ADRA2A</i>
0072578:neurotransmitter-gated ion channel clustering	0.012243611	1	2	<i>GLRB</i>
0097112:gamma-aminobutyric acid receptor clustering	0.012243611	1	2	<i>GLRB</i>
1900244:positive regulation of synaptic vesicle endocytosis	0.012243611	1	2	<i>NLGNI</i>
0000320:re-entry into mitotic cell cycle	0.018309669	1	3	<i>CCND1</i>
0002677:negative regulation of chronic inflammatory response	0.018309669	1	3	<i>CYP19A1</i>
0008063:Toll signaling pathway	0.018309669	1	3	<i>TRAF3</i>
0016080:synaptic vesicle targeting	0.018309669	1	3	<i>NLGNI</i>
0032204:regulation of telomere maintenance	0.018309669	1	3	<i>YLPM1</i>
0035625:epidermal growth factor-activated receptor transactivation by G-protein coupled receptor signaling pathway	0.018309669	1	3	<i>ADRA2A</i>
0050688:regulation of defense response to virus	0.018309669	1	3	<i>TRAF3</i>
0060012:synaptic transmission, glycinergic	0.018309669	1	3	<i>GLRB</i>
0070858:negative regulation of bile acid biosynthetic process	0.018309669	1	3	<i>FGF19</i>
0097105:presynaptic membrane assembly	0.018309669	1	3	<i>NLGNI</i>
0097120:receptor localization to synapse	0.018309669	1	3	<i>NLGNI</i>
0008543:fibroblast growth factor receptor signaling pathway	0.021616104	2	37	<i>FGF19,FGF6</i>
0032869:cellular response to insulin stimulus	0.022727013	2	38	<i>PIK3R1</i>
0002322:B cell proliferation involved in immune response	0.024338859	1	4	<i>CD180</i>
0006002:fructose 6-phosphate metabolic process	0.024338859	1	4	<i>PFKP</i>
0006707:cholesterol catabolic process	0.024338859	1	4	<i>CYP46A1</i>
0006857:oligopeptide transport	0.024338859	1	4	<i>SLC15A4</i>
0007044:cell-substrate junction assembly	0.024338859	1	4	<i>TNSI</i>

0009396:folic acid-containing compound biosynthetic process	0.024338859	1	4	<i>MTHFD1L</i>
0010760:negative regulation of macrophage chemotaxis	0.024338859	1	4	<i>CYP19A1</i>
0019222:regulation of metabolic process	0.024338859	1	4	<i>MC4R</i>
0030595:leukocyte chemotaxis	0.024338859	1	4	<i>LYST</i>
0030835:negative regulation of actin filament depolymerization	0.024338859	1	4	<i>PLEKHH2</i>
0045741:positive regulation of epidermal growth factor-activated receptor activity	0.024338859	1	4	<i>ADRA2A</i>
0050995:negative regulation of lipid catabolic process	0.024338859	1	4	<i>ADRA2A</i>
0051967:negative regulation of synaptic transmission, glutamatergic	0.024338859	1	4	<i>GRIK1</i>
0061002:negative regulation of dendritic spine morphogenesis	0.024338859	1	4	<i>NLGN1</i>
0061179:negative regulation of insulin secretion involved in cellular response to glucose stimulus	0.024338859	1	4	<i>ADRA2A</i>
0070141:response to UV-A	0.024338859	1	4	<i>CCND1</i>
0090003:regulation of establishment of protein localization to plasma membrane	0.024338859	1	4	<i>PIK3R1</i>
0097104:postsynaptic membrane assembly	0.024338859	1	4	<i>NLGN1</i>
0097119:postsynaptic density protein 95 clustering	0.024338859	1	4	<i>NLGN1</i>
1900103:positive regulation of endoplasmic reticulum unfolded protein response	0.024338859	1	4	<i>PIK3R1</i>
2000809:positive regulation of synaptic vesicle clustering	0.024338859	1	4	<i>NLGN1</i>
0030335:positive regulation of cell migration	0.026163762	3	104	<i>,ADRA2A,CDH13,PIK3R1</i>
0002446:neutrophil mediated immunity	0.030331404	1	5	<i>LYST</i>
0002456:T cell mediated immunity	0.030331404	1	5	<i>LYST</i>
0007158:neuron cell-cell adhesion	0.030331404	1	5	<i>NLGN1</i>
0007171:activation of transmembrane receptor protein tyrosine kinase activity	0.030331404	1	5	<i>PDGFC</i>
0007379:segment specification	0.030331404	1	5	<i>MLLT3</i>

0016339:calcium-dependent cell-cell adhesion via plasma membrane cell adhesion molecules	0.030331404	1	5	<i>CDH13</i>
0030162:regulation of proteolysis	0.030331404	1	5	<i>TRAF3</i>
0031571:mitotic G1 DNA damage checkpoint	0.030331404	1	5	<i>CCND1</i>
0032816:positive regulation of natural killer cell activation	0.030331404	1	5	<i>LYST</i>
0035418:protein localization to synapse	0.030331404	1	5	<i>NLGN1</i>
0042058:regulation of epidermal growth factor receptor signaling pathway	0.030331404	1	5	<i>CDH13</i>
0043551:regulation of phosphatidylinositol 3-kinase activity	0.030331404	1	5	<i>PIK3R1</i>
0050927:positive regulation of positive chemotaxis	0.030331404	1	5	<i>CDH13</i>
1903076:regulation of protein localization to plasma membrane	0.030331404	1	5	<i>STX7</i>
0009058:biosynthetic process	0.031133818	2	45	<i>NMNAT2, GLT1D1</i>
0007155:cell adhesion	0.032093675	4	195	<i>,LAMC1, CDH13, NLGN1, CDH4</i>
0000460:maturation of 5.8S rRNA	0.036287523	1	6	<i>MPHOSPH6</i>
0001678:cellular glucose homeostasis	0.036287523	1	6	<i>PIK3R1</i>
0001817:regulation of cytokine production	0.036287523	1	6	<i>TRAF3</i>
0002087:regulation of respiratory gaseous exchange by neurological system process	0.036287523	1	6	<i>NLGN1</i>
0007196:adenylate cyclase-inhibiting G-protein coupled glutamate receptor signaling pathway	0.036287523	1	6	<i>GRM8</i>
0016079:synaptic vesicle exocytosis	0.036287523	1	6	
0016574:histone ubiquitination	0.036287523	1	6	<i>PHC1</i>
0030818:negative regulation of cAMP biosynthetic process	0.036287523	1	6	<i>GRM8</i>
0032438:melanosome organization	0.036287523	1	6	<i>LYST</i>
0033572:transferrin transport	0.036287523	1	6	<i>REP15</i>

*按 P 值从小到大排列 GO term。Nr 为富集在该条目的受选择基因数目，Size 为该条目的基因数。gene_Symbol 为富集在该条目的基因符号，有些转录本没有 symbol 因此其数量和 Nr 并不一定相等。

表 3-17 家鸭群体受选择基因的 KEGG 通路富集分析

KEG GID	Pvalu e	Odds Ratio	ExpC ount	Cou nt	Size	Term	Symbols
5218	8.27E-05	13.23462	0.459704	5	71	Melanoma	<i>CCND1;FGF6;PIK3R1;FGF19;PDGFC</i>
5222	0.000195	10.89205	0.550349	5	85	Small cell lung cancer	<i>CCND1;LAMC1;LAMC2;PIK3R1;TRAF3</i>
5200	0.004340	3.901709	2.110751	7	326	Pathways in cancer	<i>CCND1;FGF6;LAMC1;LAMC2;PIK3R1;TRAF3;FGF19</i>
120	0.004627	23.08333	0.103595	2	16	Primary bile acid biosynthesis	<i>HSD17B4;CYP46A1</i>
4080	0.007405	3.922697	1.761118	6	272	Neuroactive ligand-receptor interaction	<i>ADRA2A;GLRB;GRID2;GRIK1;GRM8;MC4R</i>
4510	0.008787	4.379176	1.29494	5	200	Focal adhesion	<i>CCND1;LAMC1;LAMC2;PIK3R1;PDGFC</i>
5215	0.019400	5.725914	0.576248	3	89	Prostate cancer	<i>CCND1;PIK3R1;PDGFC</i>
4130	0.022394	9.472222	0.233089	2	36	SNARE interactions in vesicular transport	<i>VAMP2;STX7</i>
5146	0.030578	4.766713	0.686318	3	106	Amoebiasis	<i>LAMC1;LAMC2;PIK3R1</i>
4962	0.032558	7.657407	0.284887	2	44	Vasopressin-regulated water reabsorption	<i>VAMP2;DYNC2L1I</i>
480	0.041154	6.693287	0.323735	2	50	Glutathione metabolism	<i>GCLM;SMS</i>
5213	0.044191	6.423333	0.336684	2	52	Endometrial cancer	<i>CCND1;PIK3R1</i>
5223	0.047309	6.174145	0.349634	2	54	Non-small cell lung cancer	<i>CCND1;PIK3R1</i>
4810	0.047520	3.16465	1.379111	4	213	Regulation of actin cytoskeleton	<i>FGF6;PIK3R1;FGF19;PDGFC</i>

据此我推测，家鸭的驯化过程与鸡的驯化可能不同，家鸭很有可能早期用作观赏性以及宠物被人做饲养，而充裕的食物强化了其对脂类，糖类，以及蛋白质的代谢合成，并且雄性荷尔蒙的代谢得到加强。神经系统，求偶行为以及求偶饲喂等行为方面受到选择，使其行为更具观赏价值。有意思的是对这 91 个受选择基因做 KEGG 通路富集分析，主要富集在了黑色素瘤，小细胞肺癌，前列腺癌以及子宫内膜癌等癌症信号通路上，这也暗示出受选择的基因很多是和信号通路相关。




图 3-22 受选择区域的选择信号和 identity score


列举了 4 个受选择区域的情况, 每个区域通过上下两张图展示。上图纵坐标表示其受选择信号强度的 S 值, 横坐标为物理位置 (即窗口号)。下图为相应受选择区域的不同鸭群体之间的 IS-score 值转化为不同颜色的热图展示。每一行代表两种鸭群体之间的比较。Ma, Sp, Gy, Sx, Sm, Lc, Cv, Bj, Jd, Cp 分别代表绿头野鸭, 斑嘴野鸭, 高邮鸭, 绍兴鸭, 山麻鸭, 连城白鸭, 樱桃谷鸭, 北京鸭, 金定鸭, 康贝尔鸭。A) 该区域包含 miRNA 但不包含任何已知的蛋白编码基因。B) 该区域包含 *NLGNI* 基因和神经发育相关。可能和驯化过程中家鸭变得更温顺相关。C) 该区域包含 *LYST* 基因, 有报道称其和羽色相关。后面我们对该区域的某个突变进行调控活性验证, 证实了调控活性的存在。D) *PER2* 基因和节律相关。

图下标为 “scaffold 号: 用于计算的第一个 SNP 的物理位置~最后一个 SNP 的物理位置

受选择区域的起始位置~受选择区域的末端: 与受选择区域交叠的基因名”

为了详细观察受选择区域以及各个品种之间的差异,我同样对这 73 个受选择区域的选择信号放大进行观察,并且利用 IS 热图展示品种之间的差异(图 3-22)。可以看到相对于早期选择信号的狭窄,近期选择信号的范围要更加宽而且明显。并且受选择的相应区域在各个家鸭品种之间都趋于固定为同一种单倍型,而与野鸭相比则有较明显的差异。

北京鸭是现代商业选育的著名优良肉用鸭品种，本人特别设计了探测北京鸭生长性状相关基因的实验。同一个北京鸭群体，经过 5~6 代的选育，形成了 5 系和 6 系北京鸭，平均体重差距达到了 1 公斤，我使用 F_{ST} 探测两者的差异区域。以 5 倍的标准差作为阈值共找到 23 个潜在和生长相关的差异位点，包含 21 个基因，其中最大的区域包含一个基因 *PDGFC* 是血小板衍生长因子家族成员 (图 3-23)。*PDGFC* 和 *DGKQ* 这两个基因在驯化选择的分析中也被探测到。

图 3-23 北京鸭高长肉系与低长肉系全基因组 F_{ST}

横坐标为基因组物理位置, 不同颜色代表不同 scaffold 号。以 5 倍的标准差作阈值为筛选离群值窗口, 离群窗口中包含的基因在图中标出。

3.7 受选择致因变异的功能验证

在野鸭祖先 434 个受选择的区域中, 有三个我感兴趣的位点位于三个基因的下游, 或 3'-UTR 区域, 这三个基因分别和视网膜和能量带向相关 (Davies et al., 2012; Noh et al., 2016; Wu et al., 2015)。我构建重组 psiCHECKTM-2 荧光素酶报告基因质粒表达包含野鸭或家鸭等位基因的 *MRPS27* 或 *ISL1* 的 3'-UTR 序列。并且构建重组 pGL3 荧光素酶报告基因质粒表达 *EFNA5* 的上游 11 kb 处的一段序列。然后我在 DF1 细胞中转染包含野鸭和家鸭突变型的质粒或者仅有荧光素酶的质粒, 计算荧光素酶活性。我发现野鸭 *MRPS27* 3'-UTR 的变异和 *EFNA5* 上游的变异的基因活性显著高于家鸭的表达活性 (如图 3-24)。而在 *ISL1* 的 3'-UTR 的一段序列的插入变异并未显著的影响基因的表达活性。

类似的, 在 73 个在家鸭当中受到选择的区域中有两个我感兴趣的变异位点, 分别位于主要兴奋性神经递质受体基因 (*GRIK1*) 的内含子和涉及色素沉积的溶酶体转运调节基因 (*LYST*)。我分别构建 pGL3 荧光素酶报告基因质粒表达包含野鸭和家鸭碱基型的 *GRIK1* 和 *LYST* 的 UTR 区的序列。我将上述重组质粒或单纯质粒转染到 DF1 细胞中计算荧光素酶的活性。这一分析显示 DF1 细胞表达的包含家鸭突变型的 *LYST* 的表达活性显著高于其野鸭突变型。然而 *GRIK1* 并没有这样的差异如图 3-24。

我选取变异的策略是首先倾向于挑选可能有调控功能的变异, 于是首先选取和基因的上下游侧翼序列, UTR 或内含子有重叠的受选择区域。然后筛选交叠区域中包含野鸭和家鸭频率差异较大的 SNP 或 INDEL。




图 3-24 候选致因突变活性验证

对从野鸭祖先群体受选择的位点和家鸭驯化过程中受选择的位点。我们选取 6 个进行荧光素酶报告基因的活性验证。A) B) C) E) 使用 pGL3 载体对突变位点进行活性验证。其中 A) B) E) 显示家鸭和野鸭当中的碱基型表达量差异显著, 说明位点具有调控活性。D) F) 使用 psiCHECK2 载体对突变位点进行活性验证。其中 F) 显示出位点具有调控活性。

第四章 自动化分析流程的设计与实践

由于二代测序数据的推动,生物信息在某种程度上已经成为数据驱动型的学科,而且需要综合的信息非常多,在这样的情况下除了科学本身以外,还需要工程设施的支持,进行集成化的分析。本研究中基于自身需求,目前已发表二代测序数据处理的解决方案以及现有的开源生物信息分析模块,设计并实现了一套服务于生物信息分析的系统用于分析实践,取得了良好的效果。本系统只能作为一个生物大数据分析在工程方法实践上的一个初步探索,并不能称之为一个成熟的产品。但这种探索本身具有其理论价值,并且对于本研究项目起到了巨大的作用,具有其实践价值。本系统从业务逻辑上分为数据管理,分析流程管理,作业管理和高级分析以及数据报表展示四个模块。

```
[liurui@localhost originaldata]$ ll -rt
total 56
drwxrwxr-x. 16 liurui liurui 4096 Jul 21 23:52 mallard
drwxrwxr-x. 15 liurui liurui 4096 Jul 22 03:40 spotbilled
drwxrwxr-x. 29 liurui liurui 4096 Jul 22 11:18 beijing
drwxrwxr-x. 10 liurui liurui 4096 Jul 22 15:03 otherspecies
drwxrwxr-x. 16 liurui liurui 4096 Jul 22 15:12 buce
drwxrwxr-x. 4 liurui liurui 4096 Jul 22 15:24 lianchengbai
drwxrwxr-x. 4 liurui liurui 4096 Jul 22 15:31 campbell
drwxrwxr-x. 4 liurui liurui 4096 Jul 22 15:40 fanya
drwxrwxr-x. 4 liurui liurui 4096 Jul 22 15:44 gaoyou
drwxrwxr-x. 4 liurui liurui 4096 Jul 22 15:46 jinding
drwxrwxr-x. 4 liurui liurui 4096 Jul 22 15:49 shanma
drwxrwxr-x. 3 liurui liurui 4096 Jul 22 15:54 taihugoose
drwxrwxr-x. 3 liurui liurui 102 Jul 22 15:58 barheadedgoose
drwxrwxr-x. 4 liurui liurui 4096 Aug 7 11:53 cherryvalley
drwxrwxr-x. 28 liurui liurui 4096 Aug 29 17:55 shaoxing
[liurui@localhost originaldata]$ cd mallard/
[liurui@localhost mallard]$ ll -rt
total 56
drwxrwxr-x. 2 liurui liurui 4096 Jul 21 20:47 fh_female24_23
drwxrwxr-x. 2 liurui liurui 4096 Jul 21 21:04 fh_female25_24
drwxrwxr-x. 2 liurui liurui 4096 Jul 21 21:22 fh_male18_17
drwxrwxr-x. 2 liurui liurui 4096 Jul 21 21:39 fh_male19_18
drwxrwxr-x. 2 liurui liurui 4096 Jul 21 21:58 fh_male22_21
drwxrwxr-x. 2 liurui liurui 4096 Jul 21 22:27 fh_male26_25
drwxrwxr-x. 2 liurui liurui 4096 Jul 21 22:45 hz_female11_69
drwxrwxr-x. 2 liurui liurui 4096 Jul 21 23:02 hz_female12_70
drwxrwxr-x. 2 liurui liurui 4096 Jul 21 23:17 hz_female13_71
drwxrwxr-x. 2 liurui liurui 4096 Jul 21 23:35 hz_female14_72
drwxrwxr-x. 2 liurui liurui 4096 Jul 21 23:50 hz_male10_68
drwxrwxr-x. 2 liurui liurui 4096 Jul 22 00:04 hz_male9_67
drwxrwxr-x. 3 liurui liurui 4096 Jul 22 14:34 fh_female21_58
drwxrwxr-x. 3 liurui liurui 4096 Jul 22 14:57 fh_male23_22
[liurui@localhost mallard]$ cd fh_female24_23/
[liurui@localhost fh_female24_23]$ ll -rt
total 11227060
-rw-rw-r--. 1 liurui liurui 28436 Jul 21 20:38 24_23.base.png
-rw-rw-r--. 1 liurui liurui 11222 Jul 21 20:38 24_23.quality.png
-rw-rw-r--. 1 liurui liurui 5564369177 Jul 21 20:53 24_23_1.fq.gz
-rw-rw-r--. 1 liurui liurui 5932095810 Jul 21 21:04 24_23_2.fq.gz
```

图 4-1 本项目原始数据存放截图

图中展示 18 个群体的原始测序数据文件,其中 otherspecies 中包括 6 个群体。mallard (绿头) 等群体包含个体测序数据。

以鸭基因组的进化分析项目为例, 我们使用本系统的分析流程管理模块可以方便的进行数据处理, 并且可以根据处理结果调整参数, 有效的组织了数据, 记录了参数。首先原始数据fastq存放在linux服务器上如图 4-1。

本项目连同两个外群一共18个代表群体, 其中有89个个体测序数据。首先要进行比对, 然后探测SNP和indels。处理的过程基本按照千人基因组的分析实践, 要经过至少8道工序的处理。1: 用bowtie/bwa进行比对, 生成bam文件。2: 用picard对每个bam文件增加group信息并排序。3: 用picard将每个排序后的文件去PCR重复。4: 执行realignment的第一步预处理。5: 执行realignment。6: 用GATK call SNP。鉴定SNP的过程逻辑虽然很简单, 但是其

```
[liurui@localhost pipelinescriptsforD2L]$ ll
total 112
drwxrwxr-x. 2 liurui liurui 8192 Aug 9 11:15 1_getbam
drwxrwxr-x. 2 liurui liurui 8192 Aug 7 11:41 2_sortedbam
drwxrwxr-x. 2 liurui liurui 12288 Aug 8 22:52 3_rmdup
drwxrwxr-x. 2 liurui liurui 12288 Aug 10 09:38 4_realignment_step1
drwxrwxr-x. 2 liurui liurui 12288 Aug 13 17:07 5_realignment_step2D2L
drwxrwxr-x. 2 liurui liurui 12288 Aug 18 12:08 6_add_bai_frouniq
drwxrwxr-x. 2 liurui liurui 10 Aug 17 17:03 6_callsnp
drwxrwxr-x. 2 liurui liurui 8192 Sep 18 09:30 6_uniqmap
drwxrwxr-x. 3 liurui liurui 4096 Aug 22 12:11 7_callsnp
drwxrwxr-x. 2 liurui liurui 4096 Aug 23 20:07 8_phase
drwxrwxr-x. 2 liurui liurui 4096 Aug 24 13:57 mergefor4pop
[liurui@localhost pipelinescriptsforD2L]$ cd 1_getbam/
[liurui@localhost 1_getbam]$ ll -t *.sh
-rwxrwxr-x. 1 liurui liurui 799 Aug 6 22:41 1_getbam_D2L.sh.cherryvalleyScript.sh
-rwxrwxr-x. 1 liurui liurui 715 Jul 30 15:16 1_getbam_D2L.sh.gaoyouScript.sh
-rwxrwxr-x. 1 liurui liurui 743 Jul 30 15:16 1_getbam_D2L.sh.campbellScript.sh
-rwxrwxr-x. 1 liurui liurui 715 Jul 30 15:16 1_getbam_D2L.sh.shanmaScript.sh
-rwxrwxr-x. 1 liurui liurui 681 Jul 30 15:16 1_getbam_D2L.sh.fanyaScript.sh
-rwxrwxr-x. 1 liurui liurui 729 Jul 30 15:16 1_getbam_D2L.sh.jindingScript.sh
-rwxrwxr-x. 1 liurui liurui 799 Jul 30 15:15 1_getbam_D2L.sh.lianchengbaiScript.sh
-rwxrwxr-x. 1 liurui liurui 771 Jul 30 15:15 1_getbam_D2L.sh.taihugooseScript.sh
-rwxrwxr-x. 1 liurui liurui 840 Jul 30 15:15 1_getbam_D2L.sh.hz_male25_83Script.sh
-rwxrwxr-x. 1 liurui liurui 840 Jul 30 15:15 1_getbam_D2L.sh.hz_male24_82Script.sh
```

图 4-2 对应各步数据处理工序的脚本

工作量繁重, 手工编写命令脚本容易出错, 参数不易记录。可以将每一步的命令抽象为将输入文件经过计算处理之后生成输出文件 (geneprof等集成框架正是图形化了这些过程)。而处理的过程都是相同的, 只是输入和输出不同, 所以只需对每一步命令编辑一个命令模板, 自动的复制命令为多个拷贝, 每份拷贝的输入和输出根据文件的组织结构替换为相应的数据文件。这就是本系统分析流程管理模块最核心的创新之处。分析流程模块对约定方式存储的输入数据处理之后会生成约定存储方式的输出数据, 可以做为下一个分析流程的输入数据。这种以设计好约定的方式处理数据不但极大地节约了成本, 而且方便了数据管理。我们将图 4-1 所示的数据的路径以参数的形式输入自动化系统, 以指令的方式告知系统要对数据进行上述过程的处理, 则系统会为每一步自动生成命令脚本 (参数通过系统调控)。如图 4-2 的命令脚本对应上述的各个工序。整个过程有自动化系统控制, 包括脚本生成, 目录管理。

随后通过自动化系统发出指令, 按照系统资源自动画的批量的执行脚本。作业管理模块会自动记录我们对数据经行处理的每一个步骤, 包括参数, 输入数据, 输出数据, 所调用的脚本及软件, 开始运行时间与运行结束时间等信息。同时系统还会监控程序的运行状态, 管理各项工序的日志信息。这样系统就记录了分析过程的详细信息, 可以保证追踪所有数据的来龙去脉, 同时代替人来监控程序的执行 (图 4-3), 从而将用户从机械性的工作当中解放出

来，可以更多的去思考生物学问题。当所有处理工作结束之后，系统会自动通过邮件的方式告知用户并且展示运行报告。实现了通过web界面管理数据以及分析流程的目标。

id	logicalpurpose	scriptname	foldername	inputdata	outputdata	output	startdate	finishdate	state
1111	bowtie2beijinggetbam	1_getbam.sh.barheadedgooseScript.sh	/home/liurui/pipeli	/home/liurui	/home/liurui	(N...	2016-07-30 15:29:44	2016-07-30 15:50:21	2
1112	bowtie2beijinggetbam	1_getbam.sh.taihuagooseScript.sh	/home/liurui/pipeli	/home/liurui	/home/liurui	(N...	2016-07-30 15:50:21	2016-07-30 21:37:14	2
1113	bowtie2beijinggetbam	1_getbam.sh.lianchengbaiScript.sh	/home/liurui/pipeli	/home/liurui	/home/liurui	(N...	2016-07-30 21:37:14	2016-07-31 08:24:37	2
1114	bowtie2beijinggetbam	1_getbam.sh.jindingScript.sh	/home/liurui/pipeli	/home/liurui	/home/liurui	(N...	2016-07-31 08:24:37	2016-07-31 16:50:55	2
1115	bowtie2beijinggetbam	1_getbam.sh.fanyaScript.sh	/home/liurui/pipeli	/home/liurui	/home/liurui	(N...	2016-07-31 16:50:55	2016-08-01 00:52:46	2
1116	bowtie2beijinggetbam	1_getbam.sh.shannaScript.sh	/home/liurui/pipeli	/home/liurui	/home/liurui	(N...	2016-07-30 15:29:44	2016-07-30 15:39:56	2
1117	bowtie2beijinggetbam	1_getbam.sh.campbellScript.sh	/home/liurui/pipeli	/home/liurui	/home/liurui	(N...	2016-07-30 15:39:56	2016-07-31 03:48:06	2
1118	bowtie2beijinggetbam	1_getbam.sh.gaoyouScript.sh	/home/liurui/pipeli	/home/liurui	/home/liurui	(N...	2016-07-31 03:48:06	2016-07-31 13:46:39	2
1119	bowtie2beijinggetbam	1_getbam.sh.44487_368Script.sh	/home/liurui/pipeli	/home/liurui	/home/liurui	(N...	2016-07-31 13:46:39	2016-07-31 17:05:54	2

图 4-3 通过 web 界面监控数据处理各项工序的执行情况

通过 web 界面监控各项工序的执行情况。logicalpuprose 记录了该分析的文字注释, scriptname 和 foldername 记录了脚本存放的文件夹以及脚本的名称, inputdata, outputdat 分别记录绝对路径的输入和输出数据, scriptcontent 记录各项参数, startdate, finishdate 分别记录程序运行的起止时间, state 记录程序运行状态: 1 表示正在运行, 2 表示正常结束, -1 表示程序运行出现错误, 0 表示等待运行。

得到的记录SNP的vcf文件最终会以信息冗余度最低信息完整度最高和方便读写操作的原则存入mysql数据表。这部分工作就交由系统的数据管理模块。由分析流程管理模块处理之后的数据顺利地与管理模块对接。对于常用的数据 (比如SNP, 基因注释, 选择信号区域信息等), 以mysql数据库或数据表格等方式按照统一标准存储。以mysql数据表存储信息相比以文件的方式存储有许多显而易见的好处。首先, 可以轻易快速的提取指定的记录。其次, 对不同个体不同群体的变异数据经行比较时, 关系数据库提供的内连接和外连接操作轻易的解决了在文件上难以操作的困难。再次, 当需要追加信息时, 可以通过增加表的属性来追加信息, 而对文件来说只能重新生成一个新的文件。而且关系数据库灵活的查询语句可以让研究人员以更加随意的方式组织整理数据。这些特性也极大的方便了开发小程序进行高级分析的灵活性。另外, 这种存储方式也可以方便研究者以多线程的方式来读写数据进行数据处理, 极大提高了数据分析的速度和效率。后面的高级分析模块会以例子的方式详细介绍。

高级分析模块架构是在系统对数据按约定方式的组织基础之上, 针对本项目的个性化需求开发的各种程序, 其中很多处理过程是相同的, 比如在选择分析当中都需要以滑窗的方式探测基因组的选择信号, 早期选择和 $d_{a\hat{d}i}$ 的分析都需要提供祖先基因型信息和SNP的侧翼序列信息。因此很多功能可以写成模块或函数实现代码复用, 供各个不同的分析流程调用。可以方便的开发各种分析程序分析数据并且对数据进行图形化甚至是交互方式的图形化展示。下面以探测野鸭当中分化早期受选择区域的分析和通过 $d_{a\hat{d}i}$ 分析鸭的进化历史为例, 具体的展示一下该模块。高级分析模块实现的分析都是文献中提到的分析方法, 将分析的所有考虑的细节, 繁琐的处理过程都写在了程序里面, 将常用的处理写成特定的模块, 比如从VCF文件提取相应的数据, 从基因组fastq文件提取相应位置的序列等。任何需要这种步骤的分析都可以调用该模块, 增加了程序复用性。目前开发的分析包括使用 $d_{a\hat{d}i}$ 模拟群体历史, 探测全基因组的选择信号, 以及鉴定受选择区间, 查找受选择区间所包含以及附近的基因, SNP的功能区间分类等。GO富集分析, 以及批量生成图片展示分析结果等。

在探测全基因组选择信号时, 我们常用滑窗的方法。对此不同的选择信号可以用统一的架构, 用一个专门的模块caculator实现不同选择信号的计算方法, 当使用不同的选择信号, 只需指定不同的caculator即可完成不同的选择信号的探测 (hp, F_{ST} , 早期选择信号, identity

score, LSBL, PBS等)。其中早期选择信号需要SNP的context序列信息, 和祖先基因型信息。对于每个SNP, 程序会自动查找其参考基因祖上的位置, 调出其context序列, 在数据库的该物种的SNP数据库中添加该信息, 再根据设定的外群查找对应位点的SNP, 如果没有查找到该SNP则通过该外群的bam文件查找该位点的覆盖度, 如果该位点的覆盖度达到要求则认为外群在该位点固定位参考基因的碱基类型。

在 $\partial a \partial i$ 的模拟当中也需要SNP的context和祖先基因型信息, 如果信息已经存在(比如之前进行过早期选择信号的探测, 则信息就存在了), 则直接调用该信息, 如果不存在则自动调用同样的方法填充信息之后在提取生成 $\partial a \partial i$ 需要的输入文件。本系统的开发使用Git代码版本工具将代码管理起来, 小幅迭代的方式完善程序到充分考虑所有细节程度。并且由于使用Git代码版本管理工具进行模块化开发, 使得本程序可以进行多人协同开发, 完成更加复杂而庞大的分析工作。

第五章 结论、讨论与展望

大多数基因组区域都是非编码的,并且大多数 DNA 序列的变异也出现在非编码区域。近期越来越多的研究显示非编码区的变异对于进化起到重要作用 (Carneiro et al., 2014; Groenen et al., 2012; Rubin et al., 2010)。基因组组装的两只野鸭的基因组和北京鸭的基因组的比较中发现野鸭比北京鸭拥有更多的 TE 序列暗示出野鸭和家鸭表型差异的背后可能有很大的调控模式的差异。对 35 只野鸭和 114 只家鸭的全基因组测序,我分别在野鸭和家鸭中检测到 40,519,559 个 SNP 和 20,676,377 个 SNP。其中 66.17%和 65.88%个 SNP 分布在非编码区,高于在蛋白编码区的比例。我计算在受选择区域中非编码区域中的数量。在野鸭早期选择 434 个受选择区域中,39.5% (4.29Mb) 的区域位于编码区,其中 292 个可能包含 miRNA。进一步转录活性的分析显示一些在受选择区域中的非编码区域的变异是具有调控活性的(比如 *MRPS27* 的 3'-UTR 区域的 C→T, A→T, C→T 的变异,和 *EFNA5* 上游的 A→G)。在绿头野鸭和斑嘴野鸭的比较中,我还发现很大比例 (4386 个位点中的 2946 个) 的差异固定位点位于非编码区。类似的,我在驯化过程中受选择的区域里也发现很大比例 (4.84Mb 中的 1.56 Mb) 的非编码区域,其中 65 个受选择区域包含 miRNA。这些发现,结合之前的报道,暗示出非编码遗传变异在进化过程中的重要角色。不仅家鸭和野鸭存在表型和行为上的很大差异,不同家鸭品种之间也存在很大的差异。因此要进一步弄清表型差异背后的遗传基础,对家鸭的驯化历史的更加详尽的分析是必不可少的。

揭示物种形成过程中的遗传结构对于理解生物多样性的起源至关重要。随着物种形成方面基因组研究的累积,逐渐揭示出近缘物种基因组上的分化全景图 (Ellegren et al., 2012; Soria-Carrasco et al., 2014; Turner et al., 2005)。然而,驱动基因组分化的因素仍然存在争议。理解这样的问题需要处在不同物种形成阶段的全基因组数据,尤其是物种形成早期阶段 (Burri et al., 2015)。有趣的是,我推测绿头野鸭与斑嘴野鸭的分化时间仅仅两万年左右。而广泛用于物种形成过程研究的两种姬鹀的分化时间更短 (Nadachowska-Brzyska et al., 2013)。因此,对这两个野鸭群体的分析为探索物种形成过程的基因组特性提供新的材料。我比较 d_f , F_{ST} , π 和 Tajima's D 的值,发现野鸭和姬鹀显示出不同的基因组分化景观。比如,两野鸭品种拥有更少的差异固定位点 (4, 386),并且 80%富集在很小的基因组范围之内,然而两个姬鹀有比之多 54 倍的差异固定位点,25%分布在较大的基因组范围之内 (姬鹀基因组的 2.7%)。更进一步,我发现野鸭基因组高分化区域的 Tajima's D 与其全基因组均值相比拟,但姬鹀基因组的高分化区域内的 Tajima's D 相比于其全基因组背景值的下降更加明显。另外,相比于其基因组背景,野鸭基因组分化区域中有更高比例的区域受正选择,暗示出正选择可能促使了基因组岛的形成。我将进一步对更多的野鸭群体展开群体遗传学以及基因组学的分析将有助于扩展对物种形成的认识。

通过全基因组测序的分析,可以得到四点结论。首先,组装获得了两个野鸭的基因组序列,进一步比较发现野鸭基因组包含比北京鸭更多的 TE 序列。其次,通过全基因组重测序的分析全面绘制了野鸭和家鸭的遗传变异图谱。对遗传变异的分析显示家鸭起源于绿头野鸭和斑嘴野鸭之外的另一个可能已经灭绝的种系,并且绿头野鸭和斑嘴野鸭的祖先和家鸭的祖先群体大约在十多万年前左右就已经分化。第三,本人通过分析认为绿头野鸭和斑嘴野鸭

的祖先在与家鸭分化早期受益于适应性选择使得其有效群体大小在末次冰河时期并未减少,并且他们在近期分化为绿头野鸭和斑嘴野鸭两个品种,而其祖先群体在早期受到的自然选择可能驱动了该分化过程。并且详细描绘了其基因组分化的全景图。最后我发现鸭的驯化过程中,在神经系统,求偶行为饲喂行为等行为方面和脂类,糖类,以及蛋白质的代谢合成等方面相关的基因受到选择。据此我推测,家鸭的驯化过程与鸡的驯化过程可能不同,家鸭很有可能最早可能因其观赏性作用被驯化或者作为宠物饲养,而在人类提供充裕的食物情况下对脂类,糖类,以及蛋白质的代谢合成相关的基因也受到了选择。

展望未来工作,我认为在鸭的进化分析上面仍然有很多值得进一步研究分析的地方。首先,扩大分析的群体范围,在世界范围内收集野鸭和家鸭品种将进一步完善从基因组层面对于家鸭起源的认识和理解。其次,在本次研究当中有很多受选择的区域有基因渗入的迹象(结果未在文中展示)。基因渗入也是目前研究的一个热点问题,对于理解群体进化的过程,驯化以及物种形成的过程都具有重要意义,因而非常值得进一步的深入研究。第三,近年来平衡选择的研究也更加深入,在很多物种上都取得了越来越好的效果 (Linnenbrink et al., 2011; Segurel et al., 2012)。而通过本研究分析发现鸭的群体历史非常适宜进行平衡选择的分析。最后,目前的进化研究主要集中在单个分立的受选择位点的探测上,而基因组之间的广泛联系,相互作用和共进化的问题一直限于理论方法等的限制并没有得到很好的研究,由于各鸭群体之间分化关系有远有近,富于变化。所以非常适宜通过共进化的分析揭示基因组之间的相互联系。

参考文献

- Agrawal, N., Frederick, M.J., Pickering, C.R., Bettgowda, C., Chang, K., Li, R.J., Fakhry, C., Xie, T.X., Zhang, J., and Wang, J., et al. (2011). Exome sequencing of head and neck squamous cell carcinoma reveals inactivating mutations in NOTCH1. *SCIENCE* 333, 1154-1157.
- Ai, H., Fang, X., Yang, B., Huang, Z., Chen, H., Mao, L., Zhang, F., Zhang, L., Cui, L., and He, W., et al. (2015). Adaptation and possible ancient interspecies introgression in pigs identified by whole-genome sequencing. *NAT GENET* 47, 217-225.
- Albarella, U. Alternate fortunes? The role of domestic ducks and geese from Roman to Medieval times in Britain.
- Axelsson, E., Ratnakumar, A., Arendt, M.L., Maqbool, K., Webster, M.T., Perloski, M., Liberg, O., Arnemo, J.M., Hedhammar, A., and Lindblad-Toh, K. (2013). The genomic signature of dog domestication reveals adaptation to a starch-rich diet. *NATURE* 495, 360-364.
- Bosse, M., Megens, H.J., Frantz, L.A., Madsen, O., Larson, G., Paudel, Y., Duijvesteijn, N., Harlizius, B., Hagemeijer, Y., and Crooijmans, R.P., et al. (2014). Genomic analysis reveals selection for Asian genes in European pigs following human-mediated introgression. *NAT COMMUN* 5, 4392.
- Bosse, M., Megens, H.J., Madsen, O., Paudel, Y., Frantz, L.A., Schook, L.B., Crooijmans, R.P., and Groenen, M.A. (2012). Regions of homozygosity in the porcine genome: consequence of demography and the recombination landscape. *PLOS GENET* 8, e1003100.
- Burri, R., Nater, A., Kawakami, T., Mugal, C.F., Olason, P.I., Smeds, L., Suh, A., Dutoit, L., Bures, S., and Garamszegi, L.Z., et al. (2015). Linked selection and recombination rate variation drive the evolution of the genomic landscape of differentiation across the speciation continuum of *Ficedula* flycatchers. *GENOME RES* 25, 1656-1665.
- Carneiro, M., Rubin, C.J., Di Palma, F., Albert, F.W., Alfoldi, J., Barrio, A.M., Pielberg, G., Rafati, N., Sayyab, S., and Turner-Maier, J., et al. (2014). Rabbit genome analysis reveals a polygenic basis for phenotypic change during domestication. *SCIENCE* 345, 1074-1079.
- Christley, S., Lu, Y., Li, C., and Xie, X. (2009). Human genomes as email attachments. *BIOINFORMATICS* 25, 274-275.
- Compeau, P.E., Pevzner, P.A., and Tesler, G. (2011). How to apply de Bruijn graphs to genome assembly. *NAT BIOTECHNOL* 29, 987-991.
- Conrad, D.F., Jakobsson, M., Coop, G., Wen, X., Wall, J.D., Rosenberg, N.A., and Pritchard, J.K. (2006). A worldwide survey of haplotype variation and linkage disequilibrium in the human genome. *NAT GENET* 38, 1251-1260.
- Davies, S.M., Lopez, S.M., Narsai, R., Shearwood, A.M., Razif, M.F., Small, I.D., Whelan, J., Rackham, O., and Filipovska, A. (2012). MRPS27 is a pentatricopeptide repeat domain protein required for the translation of mitochondrially encoded proteins. *FEBS LETT* 586, 3555-3561.
- DePristo, M.A., Banks, E., Poplin, R., Garimella, K.V., Maguire, J.R., Hartl, C., Philippakis, A.A., Del, A.G., Rivas, M.A., and Hanna, M., et al. (2011). A framework for variation discovery and

- genotyping using next-generation DNA sequencing data. *NAT GENET* 43, 491-498.
- Durand, E.Y., Patterson, N., Reich, D., and Slatkin, M. (2011). Testing for ancient admixture between closely related populations. *MOL BIOL EVOL* 28, 2239-2252.
- Eid, J., Fehr, A., Gray, J., Luong, K., Lyle, J., Otto, G., Peluso, P., Rank, D., Baybayan, P., and Bettman, B., et al. (2009). Real-time DNA sequencing from single polymerase molecules. *SCIENCE* 323, 133-138.
- Ellegren, H., Smeds, L., Burri, R., Olason, P.I., Backstrom, N., Kawakami, T., Kunstner, A., Makinen, H., Nadachowska-Brzyska, K., and Qvarnstrom, A., et al. (2012). The genomic landscape of species divergence in *Ficedula* flycatchers. *NATURE* 491, 756-760.
- Faino, L., and Thomma, B.P. (2014). Get your high-quality low-cost genome sequence. *TRENDS PLANT SCI* 19, 288-291.
- Frantz, L.A., Schraiber, J.G., Madsen, O., Megens, H.J., Cagan, A., Bosse, M., Paudel, Y., Crooijmans, R.P., Larson, G., and Groenen, M.A. (2015). Evidence of long-term gene flow and selection during domestication from analyses of Eurasian wild and domestic pig genomes. *NAT GENET*.
- Goecks, J., Nekrutenko, A., and Taylor, J. (2010). Galaxy: a comprehensive approach for supporting accessible, reproducible, and transparent computational research in the life sciences. *GENOME BIOL* 11, R86.
- Green, R.E., Krause, J., Briggs, A.W., Maricic, T., Stenzel, U., Kircher, M., Patterson, N., Li, H., Zhai, W., and Fritz, M.H., et al. (2010). A draft sequence of the Neandertal genome. *SCIENCE* 328, 710-722.
- Groenen, M.A., Archibald, A.L., Uenishi, H., Tuggle, C.K., Takeuchi, Y., Rothschild, M.F., Rogel-Gaillard, C., Park, C., Milan, D., and Megens, H.J., et al. (2012). Analyses of pig genomes provide insight into porcine demography and evolution. *NATURE* 491, 393-398.
- Halbritter, F., Vaidya, H.J., and Tomlinson, S.R. (2012). GeneProf: analysis of high-throughput sequencing experiments. *NAT METHODS* 9, 7-8.
- Huang, Y., Li, Y., Burt, D.W., Chen, H., Zhang, Y., Qian, W., Kim, H., Gan, S., Zhao, Y., and Li, J., et al. (2013). The duck genome and transcriptome provide insight into an avian influenza virus reservoir species. *NAT GENET* 45, 776-783.
- Jacobs, F.M., Greenberg, D., Nguyen, N., Haeussler, M., Ewing, A.D., Katzman, S., Paten, B., Salama, S.R., and Haussler, D. (2014). An evolutionary arms race between KRAB zinc-finger genes ZNF91/93 and SVA/L1 retrotransposons. *NATURE* 516, 242-245.
- Karlsson, E.K., Baranowska, I., Wade, C.M., Salmon, H.N., Zody, M.C., Anderson, N., Biagi, T.M., Patterson, N., Pielberg, G.R., and Kulbokas, E.R., et al. (2007). Efficient mapping of mendelian traits in dogs through genome-wide association. *NAT GENET* 39, 1321-1328.
- Kiple, K.F., and Ornelas, K.C. (2000). *The Cambridge world history of food* (Cambridge, UK, Cambridge University Press).
- Li, C., Jiao, S., Wang, G., Gao, Y., Liu, C., He, X., Zhang, C., Xiao, J., Li, W., and Zhang, G., et al. (2015). The Immune Adaptor ADAP Regulates Reciprocal TGF-beta1-Integrin Crosstalk to

- Protect from Influenza Virus Infection. *PLOS PATHOG* 11, e1004824.
- Li, M., Tian, S., Jin, L., Zhou, G., Li, Y., Zhang, Y., Wang, T., Yeung, C.K., Chen, L., and Ma, J., et al. (2013). Genomic analyses identify distinct patterns of selection in domesticated pigs and Tibetan wild boars. *NAT GENET* 45, 1431-1438.
- Li, R., Fan, W., Tian, G., Zhu, H., He, L., Cai, J., Huang, Q., Cai, Q., Li, B., and Bai, Y., et al. (2010). The sequence and de novo assembly of the giant panda genome. *NATURE* 463, 311-317.
- Li, R., Zhu, H., Ruan, J., Qian, W., Fang, X., Shi, Z., Li, Y., Li, S., Shan, G., and Kristiansen, K., et al. (2010). De novo assembly of human genomes with massively parallel short read sequencing. *GENOME RES* 20, 265-272.
- Liedvogel, M., Maeda, K., Henbest, K., Schleicher, E., Simon, T., Timmel, C.R., Hore, P.J., and Mouritsen, H. (2007). Chemical magnetoreception: bird cryptochrome 1a is excited by blue light and forms long-lived radical-pairs. *PLOS ONE* 2, e1106.
- Linnenbrink, M., Johnsen, J.M., Montero, I., Brzezinski, C.R., Harr, B., and Baines, J.F. (2011). Long-term balancing selection at the blood group-related gene *B4galnt2* in the genus *Mus* (Rodentia; Muridae). *MOL BIOL EVOL* 28, 2999-3003.
- Lushbough, C.M., and Brendel, V.P. (2010). An overview of the BioExtract Server: a distributed, Web-based system for genomic analysis. *ADV EXP MED BIOL* 680, 361-369.
- Makalowski, W., and Boguski, M.S. (1998). Evolutionary parameters of the transcribed mammalian genome: an analysis of 2,820 orthologous rodent and human sequences. *Proc Natl Acad Sci U S A* 95, 9407-9412.
- Martin, S.H., Dasmahapatra, K.K., Nadeau, N.J., Salazar, C., Walters, J.R., Simpson, F., Blaxter, M., Manica, A., Mallet, J., and Jiggins, C.D. (2013). Genome-wide evidence for speciation with gene flow in *Heliconius* butterflies. *GENOME RES* 23, 1817-1828.
- Mason, I.L. (1984). *Evolution of domesticated animals* (London, Longman).
- McDonald, J.H., and Kreitman, M. (1991). Adaptive protein evolution at the *Adh* locus in *Drosophila*. *NATURE* 351, 652-654.
- Mizuno, M., Yamada, K., Takei, N., Tran, M.H., He, J., Nakajima, A., Nawa, H., and Nabeshima, T. (2003). Phosphatidylinositol 3-kinase: a molecule mediating BDNF-dependent spatial memory formation. *Mol Psychiatry* 8, 217-224.
- Mostovoy, Y., Levy-Sakin, M., Lam, J., Lam, E.T., Hastie, A.R., Marks, P., Lee, J., Chu, C., Lin, C., and Dzakula, Z., et al. (2016). A hybrid approach for de novo human genome sequence assembly and phasing. *NAT METHODS* 13, 587-590.
- Nadachowska-Brzyska, K., Burri, R., Olason, P.I., Kawakami, T., Smeds, L., and Ellegren, H. (2013). Demographic divergence history of pied flycatcher and collared flycatcher inferred from whole-genome re-sequencing data. *PLOS GENET* 9, e1003942.
- Nadachowska-Brzyska, K., Li, C., Smeds, L., Zhang, G., and Ellegren, H. (2015). Temporal Dynamics of Avian Populations during Pleistocene Revealed by Whole-Genome Sequences. *CURR BIOL* 25, 1375-1380.

- Narzisi, G., and Mishra, B. (2011). Comparing de novo genome assembly: the long and short of it. *PLOS ONE* 6, e19175.
- Nekrutenko, A., and Taylor, J. (2012). Next-generation sequencing data interpretation: enhancing reproducibility and accessibility. *NAT REV GENET* 13, 667-672.
- Neron, B., Menager, H., Maufrais, C., Joly, N., Maupetit, J., Letort, S., Carrere, S., Tuffery, P., and Letondal, C. (2009). Mobyle: a new full web bioinformatics framework. *BIOINFORMATICS* 25, 3005-3011.
- Noh, H., Lee, H., Park, E., and Park, S. (2016). Proper closure of the optic fissure requires ephrin A5-EphB2-JNK signaling. *DEVELOPMENT* 143, 461-472.
- Panov, E.N. (1989). Hybridization and Ethological Isolation of Birds (Nauka).
- Patterson, N., Moorjani, P., Luo, Y., Mallick, S., Rohland, N., Zhan, Y., Genschoreck, T., Webster, T., and Reich, D. (2012). Ancient admixture in human history. *GENETICS* 192, 1065-1093.
- Peng, Y., Lai, Z., Lane, T., Nageswara-Rao, M., Okada, M., Jasieniuk, M., O'Geen, H., Kim, R.W., Sammons, R.D., and Rieseberg, L.H., et al. (2014a). De novo genome assembly of the economically important weed horseweed using integrated data from multiple sequencing platforms. *PLANT PHYSIOL* 166, 1241-1254.
- Peng, Y., Lai, Z., Lane, T., Nageswara-Rao, M., Okada, M., Jasieniuk, M., O'Geen, H., Kim, R.W., Sammons, R.D., and Rieseberg, L.H., et al. (2014b). De novo genome assembly of the economically important weed horseweed using integrated data from multiple sequencing platforms. *PLANT PHYSIOL* 166, 1241-1254.
- Popitsch, N., and von Haeseler, A. (2013). NGC: lossless and lossy compression of aligned high-throughput sequencing data. *NUCLEIC ACIDS RES* 41, e27.
- Reich, M., Liefeld, T., Gould, J., Lerner, J., Tamayo, P., and Mesirov, J.P. (2006). GenePattern 2.0. *NAT GENET* 38, 500-501.
- Ren, Y., Zhao, Y., Lin, D., Xu, X., Zhu, Q., Yao, J., Shu, H.B., and Zhong, B. (2016). The Type I Interferon-IRF7 Axis Mediates Transcriptional Expression of Usp25 Gene. *J BIOL CHEM* 291, 13206-13215.
- Rubin, C.J., Megens, H.J., Martinez, B.A., Maqbool, K., Sayyab, S., Schwochow, D., Wang, C., Carlborg, O., Jern, P., and Jorgensen, C.B., et al. (2012). Strong signatures of selection in the domestic pig genome. *Proc Natl Acad Sci U S A* 109, 19529-19536.
- Rubin, C.J., Zody, M.C., Eriksson, J., Meadows, J.R., Sherwood, E., Webster, M.T., Jiang, L., Ingman, M., Sharpe, T., and Ka, S., et al. (2010). Whole-genome resequencing reveals loci under selection during chicken domestication. *NATURE* 464, 587-591.
- Sabeti, P.C., Schaffner, S.F., Fry, B., Lohmueller, J., Vavilily, P., Shamovsky, O., Palma, A., Mikkelsen, T.S., Altshuler, D., and Lander, E.S. (2006). Positive natural selection in the human lineage. *SCIENCE* 312, 1614-1620.
- Sanger, F., Nicklen, S., and Coulson, A.R. (1977). DNA sequencing with chain-terminating inhibitors. *Proc Natl Acad Sci U S A* 74, 5463-5467.

- Scheinfeldt, L.B., and Tishkoff, S.A. (2013). Recent human adaptation: genomic approaches, interpretation and insights. *NAT REV GENET* 14, 692-702.
- Segurel, L., Thompson, E.E., Flutre, T., Lovstad, J., Venkat, A., Margulis, S.W., Moyse, J., Ross, S., Gamble, K., and Sella, G., et al. (2012). The ABO blood group is a trans-species polymorphism in primates. *Proc Natl Acad Sci U S A* 109, 18493-18498.
- Serjeantson, D. (2009). *Birds* (New York, Cambridge University Press).
- Session, A.M., Uno, Y., Kwon, T., Chapman, J.A., Toyoda, A., Takahashi, S., Fukui, A., Hikosaka, A., Suzuki, A., and Kondo, M., et al. (2016). Genome evolution in the allotetraploid frog *Xenopus laevis*. *NATURE* 538, 336-343.
- Soria-Carrasco, V., Gompert, Z., Comeault, A.A., Farkas, T.E., Parchman, T.L., Johnston, J.S., Buerkle, C.A., Feder, J.L., Bast, J., and Schwander, T., et al. (2014). Stick insect genomes reveal natural selection's role in parallel speciation. *SCIENCE* 344, 738-742.
- Stransky, N., Egloff, A.M., Tward, A.D., Kostic, A.D., Cibulskis, K., Sivachenko, A., Kryukov, G.V., Lawrence, M.S., Sougnez, C., and McKenna, A., et al. (2011). The mutational landscape of head and neck squamous cell carcinoma. *SCIENCE* 333, 1157-1160.
- Turner, T.L., Hahn, M.W., and Nuzhdin, S.V. (2005). Genomic islands of speciation in *Anopheles gambiae*. *PLOS BIOL* 3, e285.
- Via, S., and West, J. (2008). The genetic mosaic suggests a new role for hitchhiking in ecological speciation. *MOL ECOL* 17, 4334-4345.
- Vonholdt, B.M., Pollinger, J.P., Lohmueller, K.E., Han, E., Parker, H.G., Quignon, P., Degenhardt, J.D., Boyko, A.R., Earl, D.A., and Auton, A., et al. (2010). Genome-wide SNP and haplotype analyses reveal a rich history underlying dog domestication. *NATURE* 464, 898-902.
- Weir, B.S., and Hill, W.G. (2002). Estimating F-statistics. *ANNU REV GENET* 36, 721-750.
- Wheeler, D.A., Srinivasan, M., Egholm, M., Shen, Y., Chen, L., McGuire, A., He, W., Chen, Y.J., Makhijani, V., and Roth, G.T., et al. (2008). The complete genome of an individual by massively parallel DNA sequencing. *NATURE* 452, 872-876.
- Wu, F., Kaczynski, T.J., Sethuramanujam, S., Li, R., Jain, V., Slaughter, M., and Mu, X. (2015). Two transcription factors, Pou4f2 and Isl1, are sufficient to specify the retinal ganglion cell fate. *Proc Natl Acad Sci U S A* 112, E1559-E1568.
- Zerbino, D.R., Paten, B., and Haussler, D. (2012). Integrating genomes. *SCIENCE* 336, 179-182.
- Zeuner, F.E. (1963). *A history of domesticated animals*. (London, Hutchinson).
- Zhang, P.H., Gao, J.L., Pu, C., Feng, G., Wang, L.Z., Huang, L.Z., and Zhang, Y. (2016). A single-nucleotide polymorphism C-724 /del in the proter region of the apolipoprotein M gene is associated with type 2 diabetes mellitus. *LIPIDS HEALTH DIS* 15, 142.
- Zhuravlev, Y.N., and Kulikova, I.V. (2014). Waterfowl Population Structure: Phylogeographic Inference. *Achievements in the Life Sciences* 8, 123-127.

致谢

很荣幸能有机会来到我的导师李宁老师的研究团队，是机缘巧合更是缘分。在这里我收获的不仅是专业技能，更有为人处世的方方面面。作为一个只有高中生物水平的电子信息背景的学生，能在生物学院将本课题顺利完成。离不开李宁老师时时刻刻的点拨，鼓励与鞭策。李老师学识渊博，治学严谨，对问题的判断极具洞察力，思想深刻，在科研上敢于开创，高瞻远瞩，不局限于科学本身，更时刻希望能够通过科学技术造福社会。李老师心系学生，不仅给我们创造了非常良好的科研环境还经常带我们进行打篮球等体育锻炼，丰富我们艰苦科研之外的业余生活。

本课题的后半段是在黄银花老师的指导下完成的。由于自己的基础薄弱，黄老师投入了很大的心力才带领我完成了课题的最后部分。黄老师的信心，对科学研究的执着和热情，身先士卒的精神给予了我极大的力量。虽然取得了很大的进步，但是我知道距离黄老师的要求和期望还有很大的距离。能有机会做这样的课题是李老师和黄老师对我的信任，是自己莫大的荣幸。

感谢课题组的胡晓湘老师，赵毅强老师在我学习和生活上给予的指导和帮助，以及在实验室管理，信息组建设上的操劳。

感谢赵要风老师，任立明老师，张然老师，费菁老师，冯丽华老师的关心和帮助。

感谢李佳师兄，顾晓荣师兄，彭德志师兄，陈黎师姐，王宏师兄，李金秀师姐，贾博师兄，魏晶晶师姐，刘晓娟师姐，谈成师兄，王宏师兄给予的指导和帮助。

感谢荣恩光，刘文杰，王小雪，胡家祥，路畅，邢艳玲，宁梦菲，王宇哲，彭业博，杨瑞飞，安晶，梁作翔，许文杰，张春媛，刘琪的帮助。

感谢我的父母最无私的支持。感谢所有亲人的关心和支持。

感谢我的朋友陈敏惠夫妇的大力支持和帮助。

感谢扬州家禽所的朱文奇老师，李慧芳老师提供样品和照片。


感谢 BGI 范广益，刘伟庆，陈春海在野鸭测序和基因组拼接中给予的帮助和支持。

感谢所有以上提及或未提及的帮助过我的人。

附录

图 S1 通过*∂a∂i* 模拟对 IM 模型的迁徙率参数推断的分布

A) B) 为绿头野鸭和斑嘴野鸭群体之间的迁徙率。C) D) 为绿头野鸭和家鸭之间的迁徙率。E) F) 为斑嘴野鸭和家鸭之间的迁徙率。








图 S2 群体基因组参数在所有 scaffolds 上的分布情况 (向后连续 10 页将全部 40 kb 以上的 scaffolds 展示)
scaffolds 按长度从大到小排列。图中展示的基因组参数有 Tajima's D, 差异固定密度 df , 群体分化指数 F_{ST} ,
SNP 的数量, 核苷酸多样性 (π), 杂合度 (zHp)。


Scaffolds from KB742382.1 to KB742483.1




Scaffolds from KB742484.1 to KB742596.1




Scaffolds from KB742597.1 to KB742716.1




Scaffolds from KB742717.1 to KB742828.1




Scaffolds from KB742830.1 to KB742939.1




Scaffolds from KB742940.1 to KB743052.1




Scaffolds from KB743053.1 to KB743178.1




Scaffolds from KB743179.1 to KB743304.1




Scaffolds from KB743306.1 to KB743433.1




Scaffolds from KB743434.1 to KB743564.1




Scaffolds from KB743565.1 to KB743711.1




Scaffolds from KB743712.1 to KB743877.1




Scaffold from KB743878.1 to KB744050.1




Scaffolds from KB744056.1 to KB744237.1




Scaffolds from KB744239.1 to KB744466.1




Scaffolds from KB744474.1 to KB744722.1




Scaffolds from KB744724.1 to KB745078.1



Scaffolds from KB745082.1 to KB745696.1



Scaffolds from KB745717.1 to KB747243.1



Scaffolds from KB747245.1 to KB820867.1






表 S3 基因组岛的分布与野鸭祖先群体当中受选择的区域的比较 (向后延续 5 页展示全部 scaffolds 的情况)
比较的参数包括差异固定密度, F_{ST} , S , zHp


Scaffolds from KB742382.1 to KB742819.1




Scaffolds from KB742821.1 to KB743291.1



Scaffolds from KB743292.1 to KB743850.1



Scaffolds from KB743851.1 to KB744652.1



Scaffolds from KB744656.1 to KB820867.1




表 S1 用于克隆致因变异所在片段的引物

变异位点附近的基因	上下游引物序列 (5'-3')
EFNA5	F: GGGGTACCAAGCATACAAAATGAAAGGACAAAT
	R: CCCTCGAGTCAAACCTGTGGGA ACTCTGGGAAT
EFNA5	F: GGGGTACCTTCCTTTGGAGTGGGTTTCACTGAC
	R: CCCTCGAGCCCCATAAAAGAAGCAGTGAGAAGC
LYST	F: GGGGTACCACTGGAGTTCAATGTGGTCAGCAAA
	R: CCCTCGAGGTTAAGTCTAAAGCATTATATTTAT
MRPS27	F: CCCTCGAGTACTGGA ACTCAAAGACTACCATAA
	R: TTGCGGCCGCTGATTTCTATCCACACATACTTTAC
GRIK1	F: GGGGTACCCAGCACCTTTCCCATCTCAGAGTAC
	R: CCCTCGAGTTTCTCAGTTTTCTTGGGGACAGGT
ISL1	F: CCCTCGAGTCCATCCTCTATCAAGTCTGAAGCG
	R: TTGCGGCCGCGACAAAACCACATAGAATTAGACAT

表 S4 野鸭祖先群体受选择基因的 GO 富集分析

GO Accession	GO Term Name	P-value	Nr	Size	gene Symbols
GO:0042517	positive regulation of tyrosine phosphorylation of Stat3 protein	6.29E-05	4	12	<i>ISL1</i> <i>IL31RA</i> <i>CRLF1</i> <i>IL6ST</i>
GO:0032925	regulation of activin receptor signaling pathway	0.000382	2	2	<i>FGF10</i> <i>SMAD7</i>
GO:0051482	positive regulation of cytosolic calcium ion concentration involved in phospholipase C-activating G-protein coupled signaling pathway	0.000387	3	8	<i>EDN1</i> <i>RFXP3</i> <i>LPAR1</i>
GO:0009597	detection of virus	0.001131	2	3	<i>SERINC5</i> <i>DDX58</i>
GO:0070779	D-aspartate import	0.001131	2	3	<i>SLC1A1</i> <i>SLC1A3</i>
GO:0003338	metanephros morphogenesis	0.002232	2	4	<i>FGF10</i> <i>WNT7B</i>
GO:0051938	L-glutamate import	0.002232	2	4	<i>SLC1A1</i> <i>SLC1A3</i>
GO:2001240	negative regulation of extrinsic apoptotic signaling pathway in absence of ligand	0.003441	3	16	<i>FGF10</i> <i>GDNF</i> <i>CX3CR1</i>
GO:0032725	positive regulation of granulocyte macrophage colony-stimulating factor production	0.003672	2	5	<i>ISL1</i> <i>DDX58</i>
GO:0060541	respiratory system development	0.003672	2	5	<i>FGF10</i> <i>SPRY2</i>
GO:0007368	determination of left/right symmetry	0.003701	5	53	<i>AP1B1</i> <i>PCSK5</i> <i>FGF10</i> <i>DPCD</i> <i>IFT74</i>
GO:0021522	spinal cord motor neuron differentiation	0.004119	3	17	<i>ISL1</i> <i>PTCHI</i> <i>LMO4</i>
GO:0060425	lung morphogenesis	0.004119	3	17	<i>FGF10</i> <i>WNT7B</i> <i>SPRY2</i>
GO:0035235	ionotropic glutamate	0.004872	3	18	<i>GRIN3A</i>

	receptor signaling pathway					<i>GRIA4</i>
						<i>GRIN2A</i>
GO:0055010	ventricular cardiac muscle tissue morphogenesis	0.004872	3	18		<i>ISL1</i>
						<i>SMAD7</i>
						<i>PTCD2</i>
GO:0009953	dorsal/ventral pattern formation	0.005176	4	36		<i>PTCH1</i>
						<i>CHRD</i>
						<i>EDN1</i>
GO:0010801	negative regulation of peptidyl-threonine phosphorylation	0.005437	2	6		<i>SPRY2</i>
						<i>SMAD7</i>
GO:0042428	serotonin metabolic process	0.005437	2	6		<i>RNF180</i>
						<i>GRIN2A</i>
GO:0060428	lung epithelium development	0.005437	2	6		<i>FGF10</i>
						<i>WNT7B</i>
GO:0019221	cytokine-mediated signaling pathway	0.006291	4	38		<i>FER IL6ST</i>
						<i>GHR</i>
						<i>CX3CR1</i>
GO:0006289	nucleotide-excision repair	0.006613	3	20		<i>POLL</i>
						<i>FANCC</i>
						<i>RAD23B</i>
GO:0030593	neutrophil chemotaxis	0.006613	3	20		<i>ITGA9</i>
						<i>ITGA1</i>
						<i>PDE4D</i>
GO:0050680	negative regulation of epithelial cell proliferation	0.006904	4	39		<i>PTCH1</i>
						<i>MCC IFT74</i>
GO:0010460	positive regulation of heart rate	0.007514	2	7		<i>SLC1A1</i>
						<i>EDN1</i>
GO:0048016	inositol phosphate-mediated signaling	0.007514	2	7		<i>ITPR2</i>
						<i>EDN1</i>
GO:0060449	bud elongation involved in lung branching	0.007514	2	7		<i>FGF10</i>
						<i>SPRY2</i>
GO:0035108	limb morphogenesis	0.009839	3	23		<i>PCSK5</i>
						<i>FGF10</i>
						<i>PTCH1</i>
GO:0001676	long-chain fatty acid metabolic process	0.00989	2	8		<i>SLC27A6</i>
						<i>SLC27A3</i>
GO:0006835	dicarboxylic acid transport	0.00989	2	8		<i>SLC1A1</i>
						<i>SLC1A3</i>
GO:0070102	interleukin-6-mediated signaling pathway	0.00989	2	8		<i>FER IL6ST</i>
GO:0070493	thrombin receptor signaling pathway	0.00989	2	8		<i>F2R</i>
						<i>IQGAP2</i>

GO:0009611	response to wounding	0.012416	3	25	<i>F2R</i> <i>SLC1A3</i> <i>GRIN2A</i>
GO:0001516	prostaglandin biosynthetic process	0.012553	2	9	<i>PTGS2</i> <i>EDN1</i>
GO:0031290	retinal ganglion cell axon guidance	0.012553	2	9	<i>ISL1 EFNA5</i>
GO:0035025	positive regulation of Rho protein signal transduction	0.012553	2	9	<i>F2R LPAR1</i>
GO:0061029	eyelid development in camera-type eye	0.012553	2	9	<i>INHBA</i> <i>MAP3K1</i>
GO:0089711	L-glutamate transmembrane transport	0.012553	2	9	<i>SLC1A1</i> <i>SLC1A3</i>
GO:0006816	calcium ion transport	0.013378	5	72	<i>GRIN3A</i> <i>ITPR2</i> <i>SLC24A2</i> <i>PLCZ1</i> <i>GRIN2A</i>
GO:0008544	epidermis development	0.015344	3	27	<i>FGF10</i> <i>PTCH1</i> <i>IFT74</i>
GO:0015813	L-glutamate transport	0.01549	2	10	<i>SLC1A1</i> <i>SLC1A3</i>
GO:0021591	ventricular system development	0.01549	2	10	<i>DPCD TTN</i>
GO:0043616	keratinocyte proliferation	0.01549	2	10	<i>FGF10</i> <i>PTCH1</i>
GO:0044262	cellular carbohydrate metabolic process	0.01549	2	10	<i>GLB1</i> <i>LDHB</i>
GO:0051642	centrosome localization	0.01549	2	10	<i>PARD3</i> <i>SEMA6A</i>
GO:2001241	positive regulation of extrinsic apoptotic signaling pathway in absence of ligand	0.01549	2	10	<i>INHBA</i> <i>WWOX</i>
GO:0030326	embryonic limb morphogenesis	0.01636	4	50	<i>DLX5</i> <i>PTCH1</i> <i>DLX6 ALX1</i>
GO:0032496	response to lipopolysaccharide	0.017487	4	51	<i>FER PLCG2</i> <i>F2R HSF1</i>
GO:0030317	sperm motility	0.018628	3	29	<i>DDX4</i> <i>DPCD</i> <i>DNAJA1</i>
GO:0001519	peptide amidation	0.019573	1	1	<i>PAM</i>

GO:0001941	postsynaptic organization	membrane	0.019573	1	1	<i>GDNF</i>
GO:0002001	renin secretion into blood stream		0.019573	1	1	<i>PCSK5</i>
GO:0002282	microglial cell activation involved in immune response		0.019573	1	1	<i>CX3CR1</i>
GO:0002316	follicular B cell differentiation		0.019573	1	1	<i>PLCG2</i>
GO:0002438	acute inflammatory response to antigenic stimulus		0.019573	1	1	<i>IL31RA</i>
GO:0006518	peptide metabolic process		0.019573	1	1	<i>PAM</i>
GO:0006742	NADP catabolic process		0.019573	1	1	<i>NUDT12</i>
GO:0007343	egg activation		0.019573	1	1	<i>PLCZ1</i>
GO:0007589	body fluid secretion		0.019573	1	1	<i>EDN1</i>
GO:0009449	gamma-aminobutyric acid biosynthetic process		0.019573	1	1	<i>SLC1A3</i>
GO:0009798	axis specification		0.019573	1	1	
GO:0010157	response to chlorate		0.019573	1	1	<i>PTCH1</i>
GO:0014733	regulation of skeletal muscle adaptation		0.019573	1	1	<i>CMYA5</i>
GO:0015977	carbon fixation		0.019573	1	1	<i>DDX4</i>
GO:0019677	NAD catabolic process		0.019573	1	1	<i>NUDT12</i>
GO:0021784	postganglionic parasympathetic fiber development		0.019573	1	1	<i>GDNF</i>
GO:0021919	BMP signaling pathway involved in spinal cord dorsal/ventral patterning		0.019573	1	1	<i>CHRD</i>
GO:0030167	proteoglycan catabolic process		0.019573	1	1	<i>ADAMTS12</i>
GO:0030185	nitric oxide transport		0.019573	1	1	<i>EDN1</i>
GO:0031345	negative regulation of cell projection organization		0.019573	1	1	<i>SPRY2</i>
GO:0031583	phospholipase D-activating G-protein coupled receptor signaling pathway		0.019573	1	1	<i>EDN1</i>
GO:0031622	positive regulation of fever generation		0.019573	1	1	<i>PTGS2</i>
GO:0031651	negative regulation of heat generation		0.019573	1	1	<i>ARRDC3</i>
GO:0032482	Rab protein signal transduction		0.019573	1	1	<i>AATK</i>

GO:0032730	positive regulation of interleukin-1 alpha production	0.019573	1	1	<i>ISL1</i>
GO:0033007	negative regulation of mast cell activation involved in immune response	0.019573	1	1	<i>FER</i>
GO:0034103	regulation of tissue remodeling	0.019573	1	1	<i>THBS4</i>
GO:0034447	very-low-density lipoprotein particle clearance	0.019573	1	1	<i>VLDLR</i>
GO:0035745	T-helper 2 cell cytokine production	0.019573	1	1	<i>IL31RA</i>
GO:0035887	aortic smooth muscle cell differentiation	0.019573	1	1	<i>SMARCA2</i>
GO:0036119	response to platelet-derived growth factor	0.019573	1	1	<i>FER</i>
GO:0038028	insulin receptor signaling pathway via phosphatidylinositol 3-kinase	0.019573	1	1	<i>FER</i>
GO:0038095	Fc-epsilon receptor signaling pathway	0.019573	1	1	<i>FER</i>
GO:0038154	interleukin-11-mediated signaling pathway	0.019573	1	1	<i>IL6ST</i>
GO:0042089	cytokine biosynthetic process	0.019573	1	1	<i>PCSK5</i>
GO:0042313	protein kinase C deactivation	0.019573	1	1	<i>EDN1</i>
GO:0042659	regulation of cell fate specification	0.019573	1	1	<i>LMO4</i>
GO:0042883	cysteine transport	0.019573	1	1	<i>SLC1A1</i>
GO:0043056	forward locomotion	0.019573	1	1	<i>TTN</i>
GO:0043179	rhythmic excitation	0.019573	1	1	<i>EDN1</i>
GO:0043438	acetoacetic acid metabolic process	0.019573	1	1	<i>TYRP1</i>
GO:0044252	negative regulation of multicellular organismal metabolic process	0.019573	1	1	<i>ARRDC3</i>
GO:0045123	cellular extravasation	0.019573	1	1	<i>ITGA1</i>
GO:0046439	L-cysteine metabolic process	0.019573	1	1	<i>CDO1</i>
GO:0046456	icosanoid biosynthetic process	0.019573	1	1	<i>PLA2G4A</i>

GO:0046880	regulation of follicle-stimulating hormone secretion	0.019573	1	1	<i>INHBA</i>
GO:0048144	fibroblast proliferation	0.019573	1	1	<i>WNT7B</i>
GO:0048880	sensory system development	0.019573	1	1	<i>ISL1</i>
GO:0050674	urothelial cell proliferation	0.019573	1	1	<i>FGF10</i>
GO:0050677	positive regulation of urothelial cell proliferation	0.019573	1	1	<i>FGF10</i>
GO:0050865	regulation of cell activation	0.019573	1	1	<i>LMO4</i>
GO:0050904	diapiesis	0.019573	1	1	<i>FER</i>
GO:0051171	regulation of nitrogen compound metabolic process	0.019573	1	1	
GO:0060419	heart growth	0.019573	1	1	<i>TTN</i>
GO:0060436	bronchiole morphogenesis	0.019573	1	1	<i>FGF10</i>
GO:0060482	lobar bronchus development	0.019573	1	1	<i>WNT7B</i>
GO:0060496	mesenchymal-epithelial cell signaling involved in lung development	0.019573	1	1	<i>FGF10</i>
GO:0060560	developmental growth involved in morphogenesis	0.019573	1	1	<i>WNT7B</i>
GO:0060661	submandibular salivary gland formation	0.019573	1	1	<i>FGF10</i>
GO:0060879	semicircular canal fusion	0.019573	1	1	<i>FGF10</i>
GO:0060913	cardiac cell fate determination	0.019573	1	1	<i>ISL1</i>
GO:0061115	lung proximal/distal axis specification	0.019573	1	1	<i>FGF10</i>
GO:0061485	memory T cell proliferation	0.019573	1	1	<i>DOCK8</i>
GO:0061580	colon epithelial cell migration	0.019573	1	1	<i>ARSB</i>
GO:0070075	tear secretion	0.019573	1	1	<i>FGF10</i>
GO:0070106	interleukin-27-mediated signaling pathway	0.019573	1	1	<i>IL6ST</i>
GO:0070352	positive regulation of white fat cell proliferation	0.019573	1	1	<i>FGF10</i>
GO:0071879	positive regulation of adrenergic receptor signaling pathway	0.019573	1	1	<i>ARRDC3</i>
GO:0072060	outer medullary collecting duct development	0.019573	1	1	<i>WNT7B</i>
GO:0072108	positive regulation of	0.019573	1	1	<i>GDNF</i>

	mesenchymal to epithelial transition involved in metanephros morphogenesis					
GO:0072236	metanephric loop of Henle development	0.019573	1	1		<i>WNT7B</i>
GO:0090032	negative regulation of steroid hormone biosynthetic process	0.019573	1	1		<i>PDE8B</i>
GO:0090327	negative regulation of locomotion involved in locomotory behavior	0.019573	1	1		<i>ARRDC3</i>
GO:0098506	polynucleotide dephosphorylation	3 0.019573	1	1		<i>APT</i>
GO:0098542	defense response to other organism	0.019573	1	1		<i>IL31RA</i>
GO:1900044	regulation of protein K63-linked ubiquitination	0.019573	1	1		<i>SASH1</i>
GO:1900134	negative regulation of renin secretion into blood stream	0.019573	1	1		<i>F2R</i>
GO:1901258	positive regulation of macrophage colony-stimulating factor production	0.019573	1	1		<i>ISL1</i>
GO:1901360	organic cyclic compound metabolic process	0.019573	1	1		<i>RNF180</i>
GO:1901509	regulation of endothelial tube morphogenesis	0.019573	1	1		<i>ADAMTS12</i>
GO:1901563	response to camptothecin	0.019573	1	1		<i>PRKAA1</i>
GO:1901898	negative regulation of relaxation of cardiac muscle	0.019573	1	1		<i>PDE4D</i>
GO:1902203	negative regulation of hepatocyte growth factor receptor signaling pathway	0.019573	1	1		<i>ADAMTS12</i>
GO:1902498	regulation of protein autoubiquitination	0.019573	1	1		<i>SASH1</i>
GO:1902548	negative regulation of cellular response to vascular endothelial growth factor stimulus	0.019573	1	1		<i>ADAMTS12</i>
GO:1903556	negative regulation of tumor necrosis factor superfamily cytokine	0.019573	1	1		<i>CD274</i>

	production					
GO:1903712	cysteine	transmembrane	0.019573	1	1	<i>SLC1A1</i>
	transport					
GO:1904188	negative	regulation of	0.019573	1	1	<i>FBLN1</i>
	transformation of host cell					
	by virus					
GO:1904293	negative	regulation of	0.019573	1	1	<i>USP25</i>
	ERAD pathway					
GO:2000287	positive	regulation of	0.019573	1	1	<i>DMRT2</i>
	myotome development					
GO:2001113	negative	regulation of	0.019573	1	1	<i>ADAMTS12</i>
	cellular response to					
	hepatocyte growth factor					
	stimulus					
GO:0071560	cellular	response to	0.020405	3	30	<i>WWOX</i>
	transforming growth factor					<i>SMAD7</i>
	beta stimulus					<i>SOX5</i>
GO:0015908	fatty acid transport		0.022141	2	12	<i>SLC27A6</i>
						<i>SLC27A3</i>
GO:0045471	response to ethanol		0.022141	2	12	<i>GRIN3A</i>
						<i>GRIN2A</i>
GO:0007409	axonogenesis		0.023836	4	56	<i>DLX5 CCK</i>
						<i>SLITRK5</i>
GO:0042472	inner ear morphogenesis		0.026718	4	58	<i>FGF10</i>
						<i>DLX5 DLX6</i>
						<i>SPRY2</i>
GO:0031532	actin	cytoskeleton	0.02841	3	34	<i>FGF10</i>
	reorganization					<i>PARVG FER</i>
GO:0008285	negative	regulation of cell	0.0295	9	220	<i>SMARCA2</i>
	proliferation					<i>FGF10</i>
						<i>PTCH1</i>
						<i>INHBA</i>
						<i>ITGA1</i>
						<i>SPRY2 F2R</i>
						<i>HSF1</i>
GO:0060037	pharyngeal	system	0.029754	2	14	<i>ISL1 PTCH1</i>
	development					
GO:0060322	head development		0.029754	2	14	<i>DLX5 DLX6</i>
GO:0007613	memory		0.030635	3	35	<i>PLK2</i>
						<i>SLC24A2</i>
						<i>GRIN2A</i>
GO:0060021	palate development		0.031417	4	61	<i>DLX5</i>
						<i>INHBA</i>
						<i>DLX6 ALX1</i>

GO:0001657	ureteric bud development	0.03295	3	36	<i>GDNF</i> <i>CRLF1</i> <i>SMAD7</i>
GO:0032436	positive regulation of proteasomal ubiquitin-dependent protein catabolic process	0.03295	3	36	<i>RNF180</i> <i>DAB2</i> <i>SMAD7</i>
GO:0009395	phospholipid catabolic process	0.033895	2	15	<i>PLA2G4A</i> <i>PLCG2</i>
GO:0000132	establishment of mitotic spindle orientation	0.038246	2	16	<i>FGF10</i> <i>SPRY2</i>
GO:0008589	regulation of smoothened signaling pathway	0.038246	2	16	<i>FGF10</i> <i>PTCH1</i>
GO:0010862	positive regulation of pathway-restricted SMAD protein phosphorylation	0.038246	2	16	<i>INHBA</i> <i>DAB2</i>
GO:0033137	negative regulation of peptidyl-serine phosphorylation	0.038246	2	16	<i>SMAD7</i> <i>PDE4D</i>
GO:0051145	smooth muscle cell differentiation	0.038246	2	16	<i>FGF10</i> <i>WNT7B</i>
GO:0002067	glandular epithelial cell differentiation	0.038764	1	2	<i>IL31RA</i>
GO:0002248	connective tissue replacement involved in inflammatory response wound healing	0.038764	1	2	<i>F2R</i>
GO:0003100	regulation of systemic arterial blood pressure by endothelin	0.038764	1	2	<i>EDN1</i>
GO:0003266	regulation of secondary heart field cardioblast proliferation	0.038764	1	2	<i>ISL1</i>
GO:0006435	threonyl-tRNA aminoacylation	0.038764	1	2	
GO:0006537	glutamate biosynthetic process	0.038764	1	2	<i>SLC1A3</i>
GO:0006564	L-serine biosynthetic process	0.038764	1	2	<i>PSAT1</i>
GO:0006610	ribosomal protein import into nucleus	0.038764	1	2	<i>IPO11</i>
GO:0007260	tyrosine phosphorylation of STAT protein	0.038764	1	2	<i>F2R</i>
GO:0016332	establishment or	0.038764	1	2	<i>WNT7B</i>

	maintenance of polarity of embryonic epithelium					
GO:0019058	viral life cycle	0.038764	1	2		<i>PCSK5</i>
GO:0019371	cyclooxygenase pathway	0.038764	1	2		<i>PTGS2</i>
GO:0021514	ventral spinal cord interneuron differentiation	0.038764	1	2		<i>LMO4</i>
GO:0021524	visceral motor neuron differentiation	0.038764	1	2		<i>ISL1</i>
GO:0021545	cranial nerve development	0.038764	1	2		<i>SLC1A3</i>
GO:0021559	trigeminal nerve development	0.038764	1	2		<i>ISL1</i>
GO:0021773	striatal medium spiny neuron differentiation	0.038764	1	2		<i>INHBA</i>
GO:0021997	neural plate axis specification	0.038764	1	2		<i>PTCH1</i>
GO:0030431	sleep	0.038764	1	2		<i>GRIN2A</i>
GO:0031223	auditory behavior	0.038764	1	2		<i>SLC1A3</i>
GO:0032513	negative regulation of protein phosphatase type 2B activity	0.038764	1	2		<i>CMYA5</i>
GO:0032731	positive regulation of interleukin-1 beta production	0.038764	1	2		<i>ISL1</i>
GO:0032770	positive regulation of monooxygenase activity	0.038764	1	2		<i>GDNF</i>
GO:0033058	directional locomotion	0.038764	1	2		<i>GRIN2A</i>
GO:0034436	glycoprotein transport	0.038764	1	2		<i>VLDLR</i>
GO:0035026	leading edge cell differentiation	0.038764	1	2		<i>DAB2</i>
GO:0035106	operant conditioning	0.038764	1	2		<i>PDE8B</i>
GO:0035815	positive regulation of renal sodium excretion	0.038764	1	2		<i>EDN1</i>
GO:0038109	Kit signaling pathway	0.038764	1	2		<i>FER</i>
GO:0042503	tyrosine phosphorylation of Stat3 protein	0.038764	1	2		<i>FER</i>
GO:0042693	muscle cell fate commitment	0.038764	1	2		<i>FGF10</i>
GO:0042701	progesterone secretion	0.038764	1	2		<i>INHBA</i>
GO:0044337	canonical Wnt signaling pathway involved in positive regulation of apoptotic process	0.038764	1	2		
GO:0046642	negative regulation of alpha-beta T cell	0.038764	1	2		<i>CBLB</i>

	proliferation					
GO:0046877	regulation of saliva secretion	0.038764	1	2		<i>FGF10</i>
GO:0048023	positive regulation of melanin biosynthetic process	0.038764	1	2		<i>TYRP1</i>
GO:0048807	female genitalia morphogenesis	0.038764	1	2		<i>FGF10</i>
GO:0048861	leukemia inhibitory factor signaling pathway	0.038764	1	2		<i>IL6ST</i>
GO:0051252	regulation of RNA metabolic process	0.038764	1	2		<i>NOVA1</i>
GO:0051771	negative regulation of nitric-oxide synthase biosynthetic process	0.038764	1	2		<i>EDN1</i>
GO:0055002	striated muscle cell development	0.038764	1	2		<i>TTN</i>
GO:0060078	regulation of postsynaptic membrane potential	0.038764	1	2		<i>GRIN2A</i>
GO:0060164	regulation of timing of neuron differentiation	0.038764	1	2		<i>SOX5</i>
GO:0060166	olfactory pit development	0.038764	1	2		<i>DLX5</i>
GO:0060279	positive regulation of ovulation	0.038764	1	2		<i>INHBA</i>
GO:0060437	lung growth	0.038764	1	2		<i>SPRY2</i>
GO:0060535	trachea cartilage morphogenesis	0.038764	1	2		<i>WNT7B</i>
GO:0060585	positive regulation of prostaglandin-endoperoxide synthase activity	0.038764	1	2		<i>EDN1</i>
GO:0060667	branch elongation involved in salivary gland morphogenesis	0.038764	1	2		<i>FGF10</i>
GO:0060689	cell differentiation involved in salivary gland development	0.038764	1	2		<i>CLCN2</i>
GO:0060915	mesenchymal cell differentiation involved in lung development	0.038764	1	2		<i>FGF10</i>
GO:0061005	cell differentiation involved in kidney development	0.038764	1	2		<i>PTCH1</i>
GO:0061033	secretion by lung epithelial cell involved in lung growth	0.038764	1	2		<i>FGF10</i>

GO:0070104	negative regulation of interleukin-6-mediated signaling pathway	0.038764	1	2	<i>IL6ST</i>
GO:0070384	Harderian gland development	0.038764	1	2	<i>FGF10</i>
GO:0071236	cellular response to antibiotic	0.038764	1	2	<i>PLA2G4A</i>
GO:0071338	positive regulation of hair follicle cell proliferation	0.038764	1	2	<i>FGF10</i>
GO:0071657	positive regulation of granulocyte colony-stimulating factor production	0.038764	1	2	<i>ISL1</i>
GO:0072053	renal inner medulla development	0.038764	1	2	<i>WNT7B</i>
GO:0072054	renal outer medulla development	0.038764	1	2	<i>WNT7B</i>
GO:0072061	inner medullary collecting duct development	0.038764	1	2	<i>WNT7B</i>
GO:0072203	cell proliferation involved in metanephros development	0.038764	1	2	<i>PTCH1</i>
GO:0090285	negative regulation of protein glycosylation in Golgi	0.038764	1	2	<i>ACER2</i>
GO:0097154	GABAergic neuron differentiation	0.038764	1	2	<i>INHBA</i>
GO:1902774	late endosome to lysosome transport	0.038764	1	2	<i>VPS41</i>
GO:1904237	positive regulation of substrate-dependent cell migration cell attachment to substrate	0.038764	1	2	<i>FBLN1</i>
GO:2000370	positive regulation of clathrin-mediated endocytosis	0.038764	1	2	<i>DAB2</i>
GO:2001181	positive regulation of interleukin-10 secretion	0.038764	1	2	<i>CD274</i>
GO:2001202	negative regulation of transforming growth factor-beta secretion	0.038764	1	2	<i>FBLN1</i>
GO:0008284	positive regulation of cell proliferation	0.040257	9	233	<i>ISL1 FGF10 ACER2 WNT7B</i>

					<i>IL31RA</i>
					<i>GDNF</i>
					<i>EDN1</i>
					<i>CRLF1</i>
					<i>IL6ST</i>
GO:0010628	positive regulation of gene expression	0.040326	8	197	<i>NFIL3</i>
					<i>WNT7B</i>
					<i>INHBA</i>
					<i>PRKAA1</i>
					<i>SPRY2</i>
					<i>FBLN1</i>
					<i>DDX58</i>
					<i>TLE1</i>
GO:0048538	thymus development	0.040422	3	39	<i>FGF10</i>
					<i>LMO4</i>
GO:0048167	regulation of synaptic plasticity	0.042796	2	17	<i>PLK2</i>
					<i>GRIN2A</i>
GO:0003007	heart morphogenesis	0.043087	3	40	<i>ISL1 PTCH1</i>
					<i>TTN</i>
GO:0043588	skin development	0.043087	3	40	<i>ARRDC3</i>
					<i>SLITRK5</i>
GO:0007612	learning	0.045837	3	41	<i>SLC24A2</i>
					<i>AMPH</i>
					<i>GRIN2A</i>
GO:0000281	mitotic cytokinesis	0.047537	2	18	<i>SNX18</i>

个人简历

姓名：刘睿 性别：男 民族：汉 电子邮箱：vitogump@163.com

教育经历：

2007~2011 陕西师范大学 物理学与信息技术学院 电子信息科学与技术 理学学士

2011~2016 中国农业大学 生物学院 生物化学与分子生物学 理学博士

学术经历及获奖情况：

2014 年起 参加国家自然科学基金面上项目“鸭抗流感免疫项目 miRNAs 的鉴定及其功能研究” (项目号 31471176)。

2014 年 第 34 届 ISAG 会议分会场做口头报告

2015 年 中国农业大学博士二等学业奖学金